CHAPTER · CLUSTERING

군집분석
Model-based 와 Model-free

반응변수 y 없이 비슷한 관측치끼리 묶기 : 확률모형 (GMM) 으로 묶을까 , 거리로 묶을까 ? 몇 개로 묶을까 ? 묶은 뒤에는 무엇을 할까 ?

모형 해석 (VIP · PDP) 다음 시간 · R 패키지 : mclust · cluster · stats · 데이터 : faithful, USArrests, 시뮬레이션

OVERVIEW

학습 목표

1 두 가지 관점

확률분포를 가정하는 model-based 와 거리만 쓰는 model-free 군집분석의 차이를 설명할 수 있다 .

2 GMM 과 mclust

정규혼합모형 , EM 알고리즘 , 공분산 구조 (λ, A, D) 에 따른 14 개 모형과 BIC 를 이용한 모형 선택을 이해한다 .

3 k-means · PAM · 계층적

세 방법의 목적함수와 알고리즘 , 각각이 잘하는 것과 못하는 것을 구분하고 R 로 수행한다 .

4 군집 수와 활용

Elbow · 실루엣 · gap 통계량으로 군집 수를 추정하고 , 전문가 판단과 예측 성능으로 최종 결정한다 .

INTRODUCTION

군집분석 : 정답 (y) 이 없는 학습

지금까지는 y 를 예측하는 지도학습 (회귀 · 분류). 군집분석은 $x_1, \ldots, x_p$ 만 보고 "비슷한 관측치끼리" 묶는 비지도학습이다 .

고객 세분화

구매 패턴이 비슷한 고객끼리 묶어 군집마다 다른 마케팅

유전체 · 의학

발현 패턴이 비슷한 유전자 , 증상이 비슷한 환자 아형 (subtype) 발견

문서 · 이미지

주제가 비슷한 문서 , 비슷한 이미지 묶기 → 탐색과 요약

좋은 군집이란

- 군집 안 : 서로 가깝다 (동질성)
- 군집 사이 : 서로 멀다 (분리)
- 그리고 그 묶음이 의미가 있다 (해석)

어려운 점

- 정답이 없어 테스트 오차로 평가할 수 없다
- " 가깝다" 의 정의 (거리 , 분포) 에 따라 결과가 달라진다
- 군집 수 K 도 데이터에서 정해야 한다

THE MAP

두 갈래 : Model-based vs Model-free

	Model-based (확률모형)	Model-free (거리 기반)
가정	각 군집 = 하나의 확률분포 (보통 다변량 정규)	분포 가정 없음 . 거리 (비유사도) 만 정의
결과	소속 확률 τ_{ik} (soft) → 가장 큰 확률로 배정	각 관측치를 하나의 군집에 배정 (hard)
군집 모양	공분산 구조로 타원의 크기 · 모양 · 방향을 조절	방법과 거리에 따라 암묵적으로 결정
군집 수 선택	우도 기반 정보기준 BIC (모형과 함께 선택)	Elbow, 실루엣 , gap 통계량 등 휴리스틱
대표 방법	가우시안 혼합모형 (GMM)	k-means, PAM (k-medoids), 계층적 군집
R	mclust::Mclust()	kmeans(), cluster::pam(), hclust()

연결고리 : k-means 는 "분산이 모두 같은 구형 GMM" 의 극한 → 두 갈래는 생각보다 가깝다 (Part 1 끝에서)

PART 1

Model-based: 가우시안 혼합모형

각 군집을 정규분포 하나로 보고 , 데이터 전체를 그 혼합으로 설명한다 — R mclust

가우시안 혼합모형 (Gaussian Mixture Model)

$$f(x) = \sum_{k=1}^{K} \pi_k \cdot \varphi(x;\, \mu_k,\, \Sigma_k), \qquad \pi_k \geq 0,\ \ \sum_k \pi_k = 1$$

π 혼합 비율 π_k

전체 중 군집 k 의 비율 (사전확률)

μ 평균 μ_k

군집 k 의 중심 위치 (p 차원)

Σ 공분산 Σ_k

군집 k 의 크기 · 모양 · 방향 (p × p) → 뒤에서 자세히

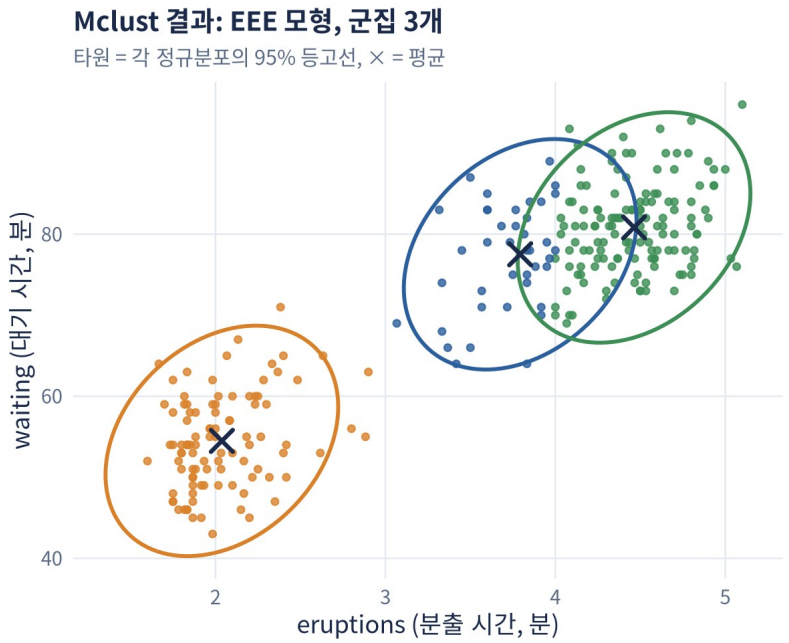
$$\tau_{ik} = \pi_k\, \varphi(x_i;\, \mu_k,\, \Sigma_k) \;/\; \sum_l \pi_l\, \varphi(x_i;\, \mu_l,\, \Sigma_l)$$

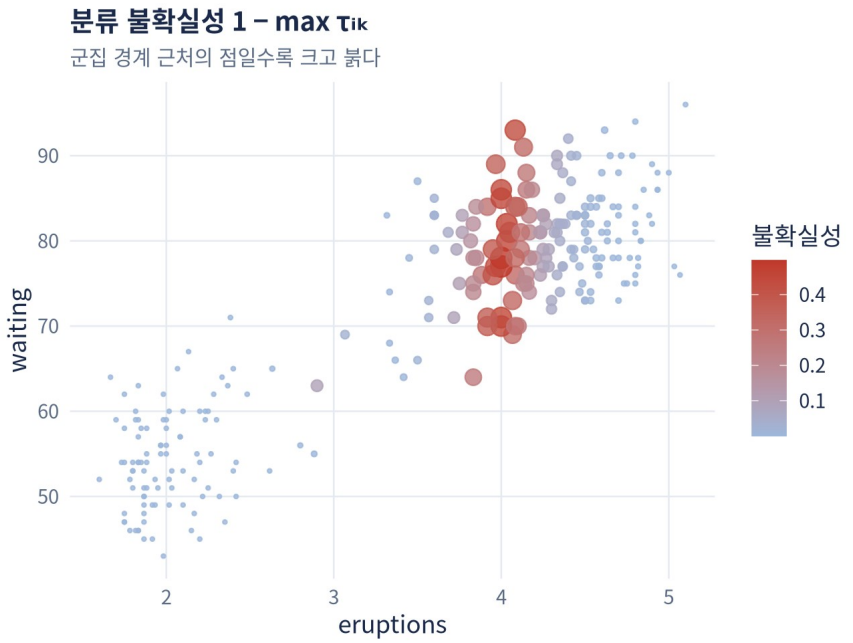
소속 확률 τ_{ik}: 관측치 i 가 군집 k 에서 나왔을 사후확률 (베이즈 정리). 가장 큰 τ_{ik} 의 군집으로 배정 , $1 - \max_k \tau_{ik}$ = 불확실성

추정할 모수 : (π_k, μ_k, Σ_k), $k = 1, \ldots, K$. 군집 수 K 와 Σ_k 의 구조는 모형 선택의 대상 (mclust 에서는 K 를 G 라고 부른다)

EXAMPLE

예 : Old Faithful 간헐천 (faithful, n = 272)





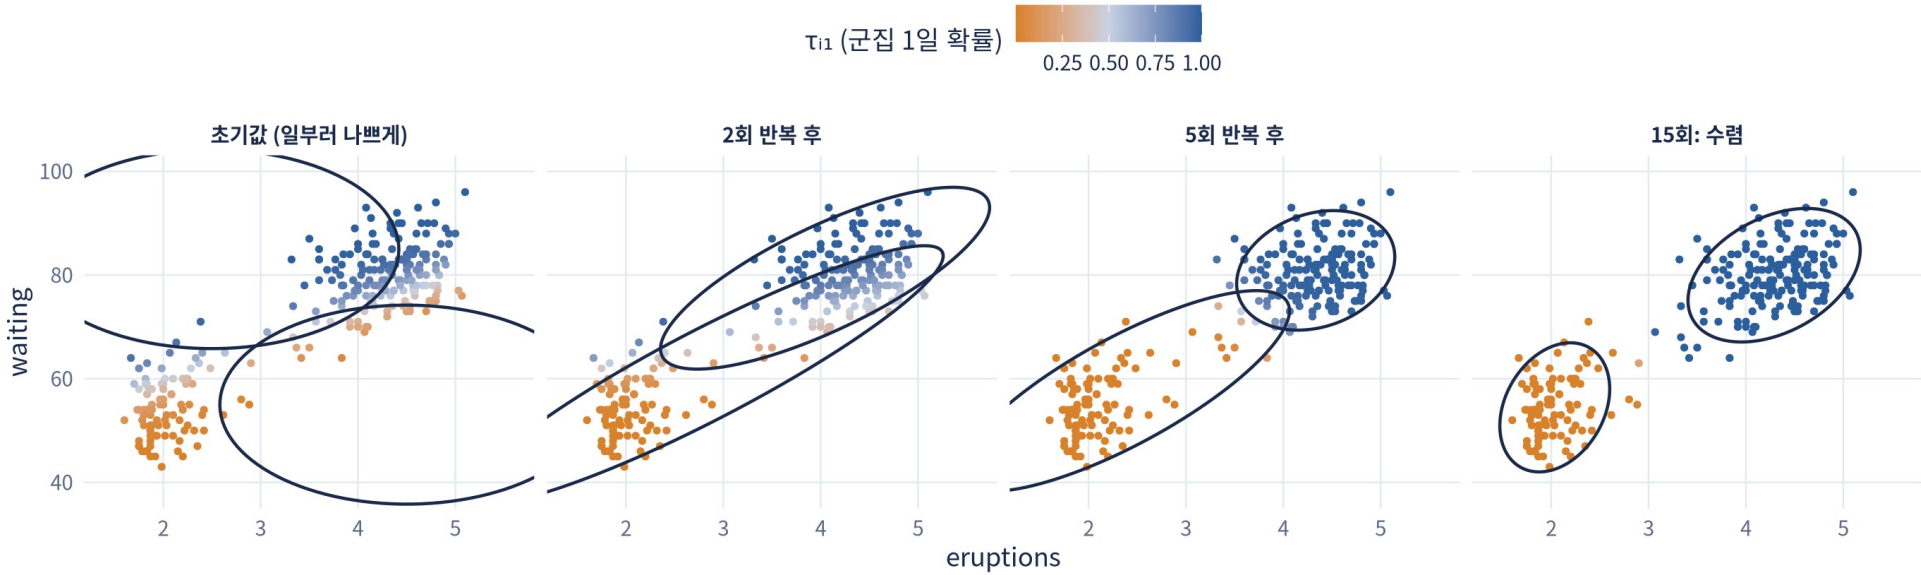
결과

- BIC 가 고른 모형 : EEE, G = 3
- 모수 11 개 , log L = −1126.3
- 불확실성 > 0.1 인 관측치 58 개 (최대 0.497)
- 긴 분출 무리가 둘로 나뉨

Soft clustering 의 장점 : 경계에 있는 관측치를 “애매하다”고 말해 준다

k-means 는 모든 관측치를 하나의 군집에 확정 배정하지만 , GMM 은 τ_{ik} 로 얼마나 확실한지 알려 준다 . 오른쪽 붉은 점들 = 군집 2 와 3 의 경계

EM 알고리즘 : 소속을 모르니 번갈아 추정한다



E E-step: 소속 확률 계산

현재 (π, μ, Σ) 로 모든 i, k 에 대해 τ_{ik} 계산 → "누가 어느 군집일 확률이 얼마인가"

M M-step: 가중 추정

τ_{ik} 를 가중치로 $\pi_k = \Sigma_i \tau_{ik}/n$, $\mu_k =$ 가중평균 , $\Sigma_k =$ 가중공분산 → 우도가 항상 증가

2 성분 EM 직접 구현 : log L = −1973.5 (초기) → −1269.1 (2 회) → −1182.6 (5 회) → −1130.3 (수렴). 국소 최적 위험 → mclust 는 계층적 군집으로 초기값을 정한다

COVARIANCE STRUCTURE

공분산 분해 : 크기 · 모양 · 방향을 따로 조절한다

$$\Sigma_k = \lambda_k \cdot D_k A_k D_k^T \qquad \text{(Banfield \& Raftery, 1993)}$$

λ 부피 (volume)

타원의 크기 . λ_k 가 군집마다 같으면 E, 다르면 V

A 모양 (shape)

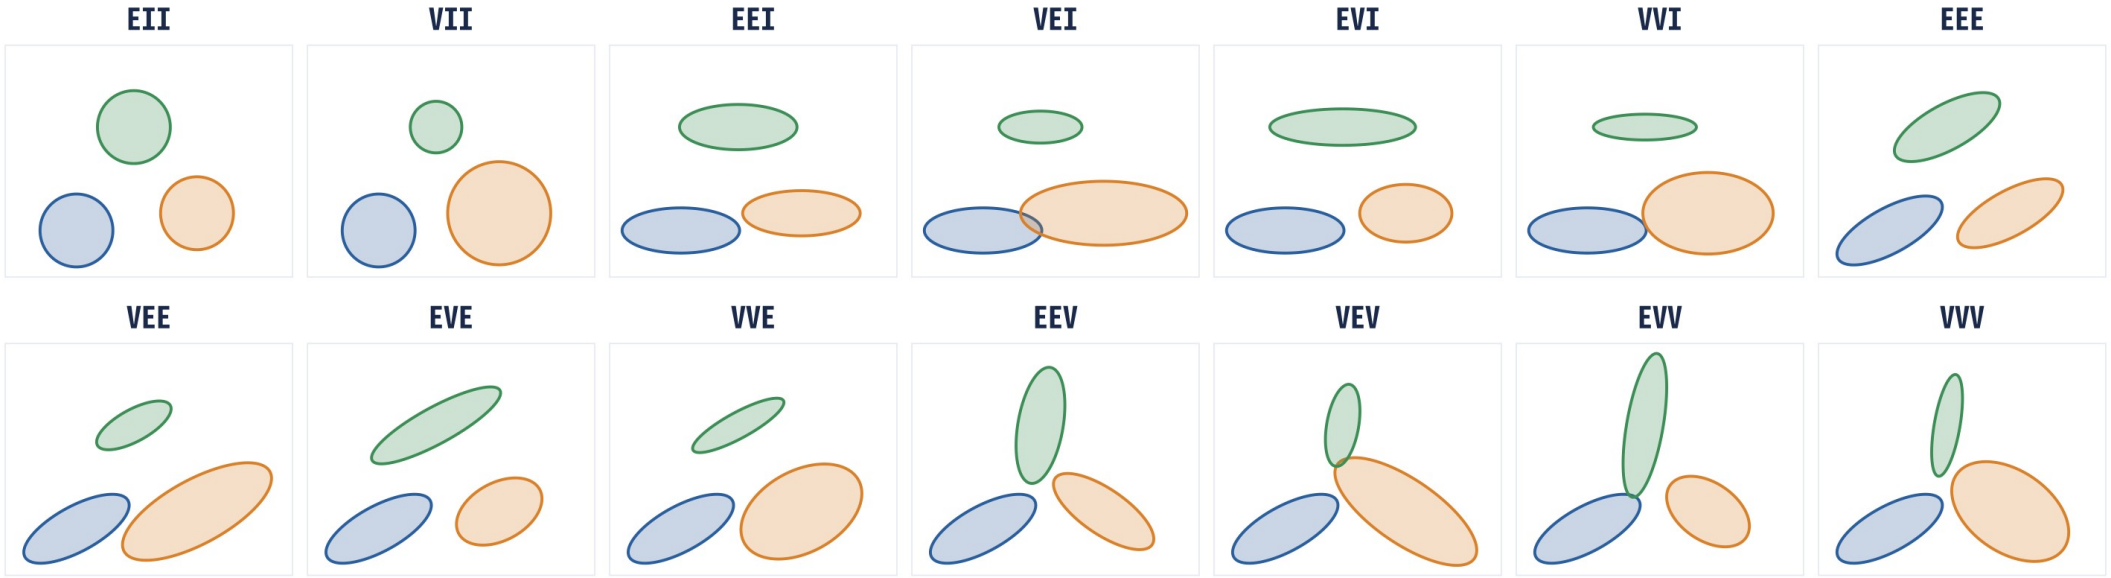
고유값의 비율 = 얼마나 길쭉한가 . 구형이면 I, 같으면 E, 다르면 V

D 방향 (orientation)

고유벡터 = 타원의 기울기 . 좌표축과 평행 I, 같으면 E, 다르면 V

모형 이름 = 세 글자 (부피 · 모양 · 방향)
예) EII: 같은 크기의 구 → k-means 와 비슷 · VVI: 크기 · 모양이 다른 축 평행 타원 · EEE: 모두 같은 타원 (LDA 와 같은 가정) · VVV: 완전히 자유

mclust 의 14 가지 공분산 모형



p = 10, K = 3 일 때 모수 개수	EII	VVI	EEE	VVV
평균 30 + 공분산 + 혼합비율 2	33	62	87	197

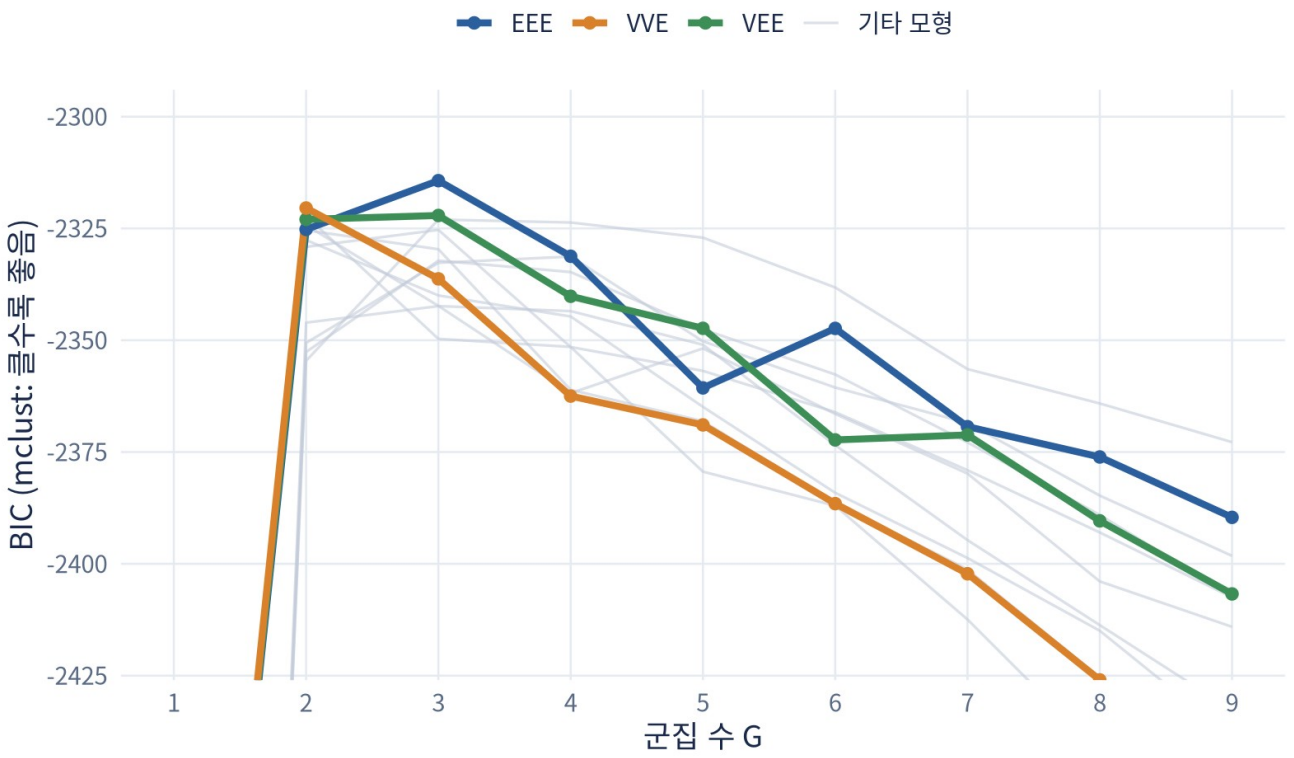
구형 2 · 대각 4 · 일반 8 개 . 제약이 적을수록 유연하지만 모수가 급격히 늘어난다 (VVV 는 p^2 에 비례)
→ 적합도와 복잡도의 균형을 BIC 로 판단

같은 색 = 같은 군집 . 각 패널은 군집 3 개를 그린 개념도

MODEL SELECTION

BIC 로 공분산 모형과 군집 수를 동시에 고른다

$$\mathrm{BIC} = 2 \cdot \log \hat{L} \; - \; \nu \cdot \log n \qquad (\nu = \text{모수 개수 , mclust 정의 : 클수록 좋다 })$$



순위	모형 , G	BIC	차이
1	EEE, 3	−2314.3	0
2	VVE, 2	−2320.4	−6.1
3	VEE, 3	−2322.1	−7.8

읽는 법

- 14 개 모형 × G = 1~9 → 126 개 후보 중 최대 BIC
- 교재의 BIC(−2logL + ν log n, 작을수록 좋음) 와 부호가 반대 !
- 차이 2~6: 어느 정도 , 6~10: 강한 증거 , 10 이상 : 매우 강한 증거 (Kass & Raftery)

BIC ≠ MEANING

BIC 최적이 곧 “의미 있는 군집”은 아니다

1 faithful 의 경우

간헐천 연구자들은 짧은 분출 · 긴 분출 두 유형을 안다 . BIC 는 3 개를 골랐지만 , 3 번째 성분은 긴 분출 무리를 둘로 나눈 것이고 2 위 (VVE, 2) 와 차이는 6.1 뿐

2 왜 이런 일이 ?

BIC 는 밀도 f(x) 를 잘 근사하는 성분 수를 고른다 . 군집 하나가 정규분포가 아니면 (치우침 등) 성분 여러 개로 그 모양을 맞춘다 → 성분 수 ≠ 군집 수일 수 있다

3 ICL: 겹치는 성분에 벌점

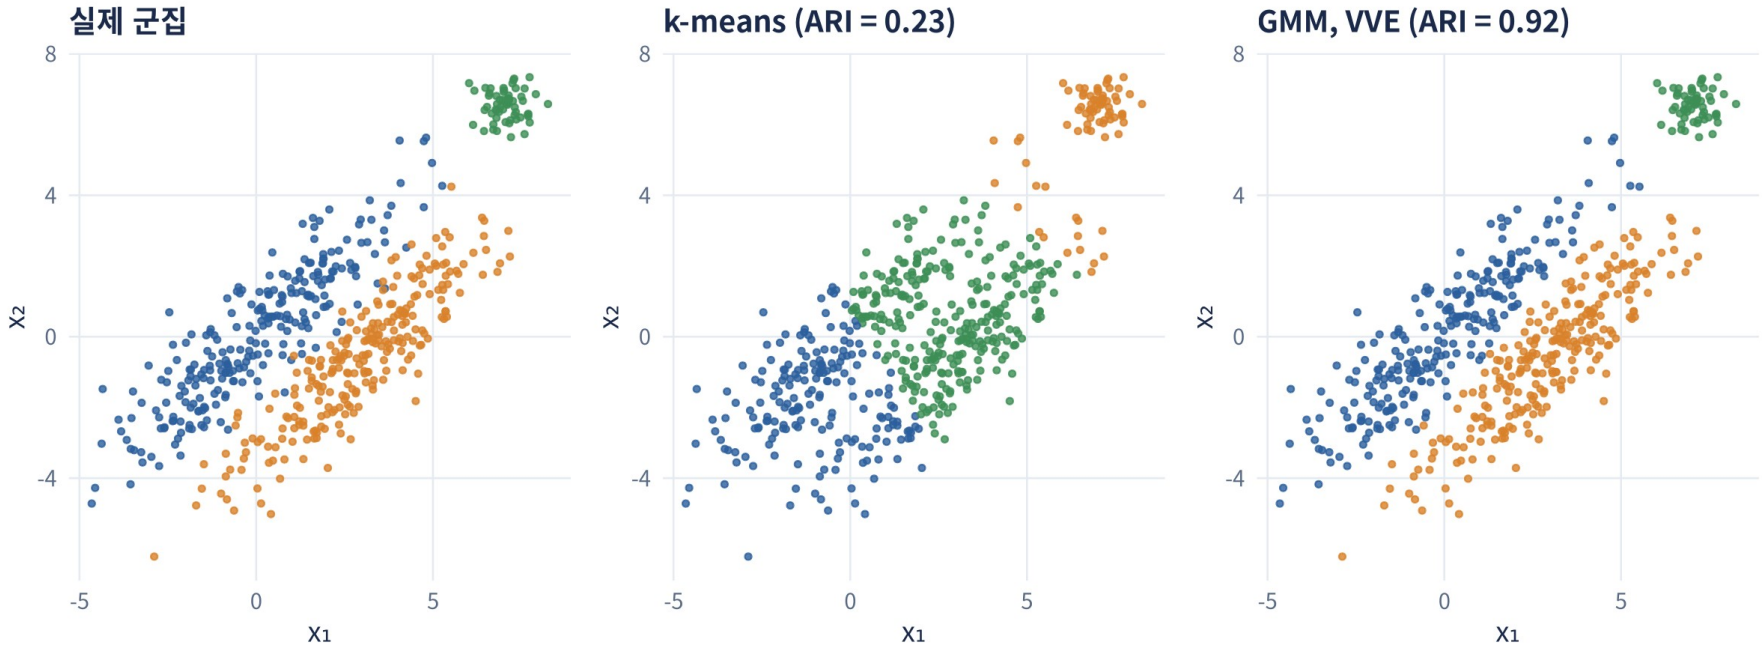
ICL = BIC − 분류 엔트로피 벌점 . faithful 에서 mclustICL() 은 VVE, G = 2 를 선택 → 연구자가 아는 두 유형과 일치

4 실무에서는

BIC 상위 몇 개 모형을 함께 보고 , 차이가 작으면 해석이 쉬운 (군집 수가 적은) 쪽을 고려 . 최종 판단은 분야 지식과 함께 (Part 3)

k-means = 분산이 같은 구형 GMM 의 극한

$\Sigma_k = \sigma^2 I$ (EII), π_k 동일 , $\sigma^2 \to 0$ 이면 τ_{ik} 는 가장 가까운 평균에서 1, 나머지 0 → EM 이 그대로 k-means 알고리즘이 된다 . 그래서 k-means 는 크기가 비슷한 둥근 군집을 가정하는 셈



길쭉하고 크기가 다른 군집 : k-means ARI 0.23 vs GMM(VVE) ARI 0.92. ARI = 실제 군집과의 일치도 (1 = 완전 일치 , 0 = 우연 수준)

R 실습 : mclust 패키지

R CONSOLE

```
library(mclust)
m <- Mclust(faithful)                # 14 개 모형 x G = 1:9
summary(m)                           # EEE, G = 3
plot(m, what = "BIC")                # BIC 곡선
plot(m, what = "classification")     # 군집과 타원
plot(m, what = "uncertainty")        # 불확실성

m$parameters$mean                    # 군집별 평균
head(m$z)                            # tau_ik (소속 확률)
m$classification                     # 최종 배정

# 모형 · 군집 수를 지정해서
m2 <- Mclust(faithful, G = 2, modelNames = "VVE")
summary(mclustBIC(faithful))         # BIC 상위 3 개
summary(mclustICL(faithful))         # ICL 기준
```

G

후보 군집 수 (기본 1:9)

modelNames

후보 공분산 모형 ("EII", "VVV" 등)

$z

n × G 소속 확률 행렬 τ_{ik}

$uncertainty

$1 - \max_k \tau_{ik}$

predict(m, newdata)

새 관측치의 군집과 확률

PART 2

Model-free: k-means · PAM · 계층적

분포 가정 없이 거리만으로 묶는다 — 무엇을 최소화하고, 어떻게 찾는가

DISTANCE

출발점 : 무엇을 “가깝다” 고 할 것인가

유클리드

$d(x_i, x_j) = \{ \Sigma_l (x_{il} - x_{jl})^2 \}^{\wedge}½$

가장 기본 . k-means 가 암묵적으로 사용

맨해튼

$d(x_i, x_j) = \Sigma_l |x_{il} - x_{jl}|$

이상치에 덜 민감 . PAM 에서 자주 사용

상관 기반

$d(x_i, x_j) = 1 - cor(x_i, x_j)$

값의 크기보다 패턴 (모양) 이 비슷한지 . 유전자 발현

Gower

변수 유형별 거리를 [0, 1] 로 맞춰 평균

수치 + 범주가 섞인 데이터 . cluster::daisy()

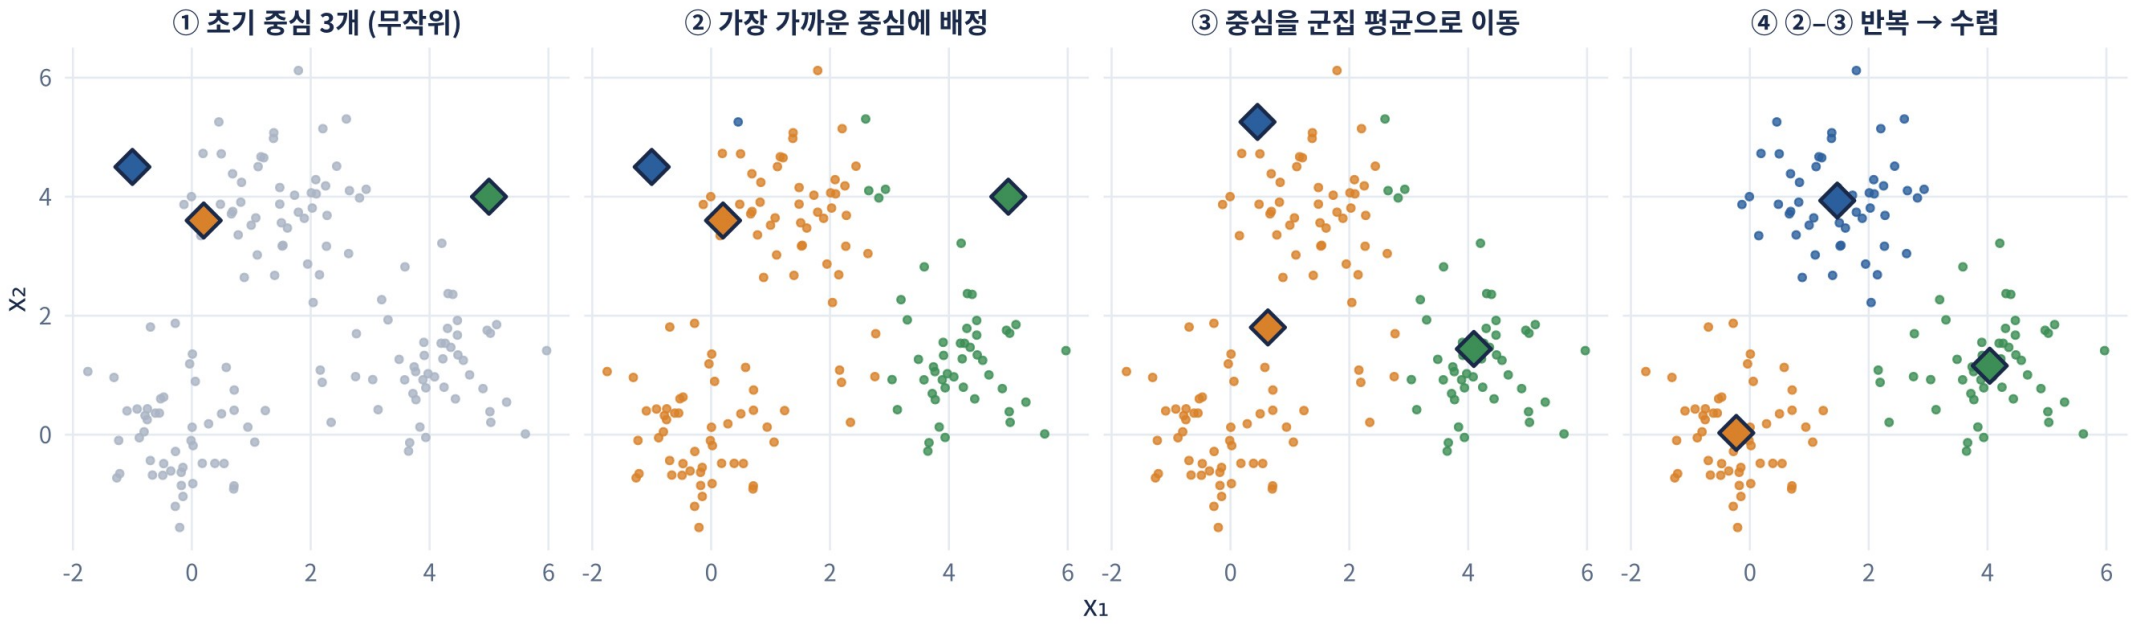
표준화 (scale) 는 거의 필수

소득 (만 원 단위) 과 나이 (세) 를 그대로 쓰면 거리는 사실상 소득만으로 정해진다 → scale() 로 평균 0, 표준편차 1

단 , 표준화도 “모든 변수를 똑같이 중요하게 본다” 는 선택이다 . 분야 지식으로 변수 선택 · 가중치를 정하는 것이 먼저

k-means: 군집 내 제곱합을 최소화

$$\min \; W = \sum_{k=1}^{K} \sum_{i \in C_k} \| x_i - \bar{x}_k \|^2 \qquad (\bar{x}_k = \text{군집 } k \text{의 평균, centroid})$$



Lloyd 알고리즘 : ② 배정 단계와 ③ 중심 갱신 단계 모두 W 를 줄이므로 반드시 수렴한다 . 하지만 전역 최소가 아닌 국소 최소일 수 있다

k-means 를 쓸 때 주의할 점

1 초기값에 따라 결과가 다르다

nstart = 20~50: 여러 초기값으로 돌려 W 가 가장 작은 결과 선택 . k-means++ 초기화 (멀리 떨어진 점을 중심으로) 도 널리 쓰임

2 둥글고 비슷한 크기를 선호

제곱 유클리드 거리 → 구형 · 비슷한 분산의 군집을 가정한 셈 . 길쭉하거나 크기가 다른 군집은 잘못 나눈다 (앞의 ARI 0.23)

3 평균 → 이상치에 민감

멀리 떨어진 점 몇 개가 중심을 끌어당기거나 군집 하나를 통째로 차지 (다음 슬라이드)

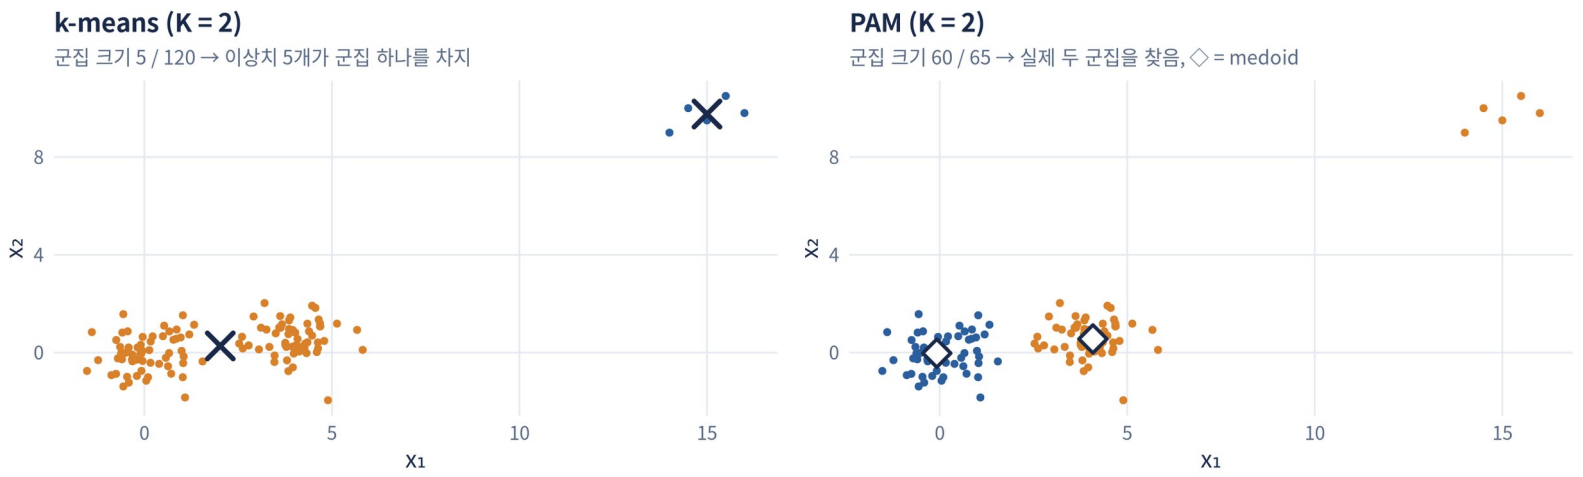
4 수치형 변수 · 유클리드만

평균을 계산해야 하므로 범주형 변수나 다른 거리는 쓸 수 없다 → PAM

장점 : 단순하고 매우 빠르다 (O(nKp) per iteration) → 대용량 데이터의 기본 선택

PAM: 중심을 실제 관측치 (medoid) 로

$$\min \ \Sigma_k \Sigma_{i \in C_k} d(x_i, m_k), \qquad m_k \in \{x_1, \ldots, x_n\} \ (\text{medoid} = \text{군집의 대표 관측치})$$



알고리즘

- BUILD: 비용을 가장 줄이는 관측치를 차례로 medoid 로
- SWAP: medoid 와 일반 관측치를 바꿔 비용이 줄면 교환 , 더 이상 없을 때까지

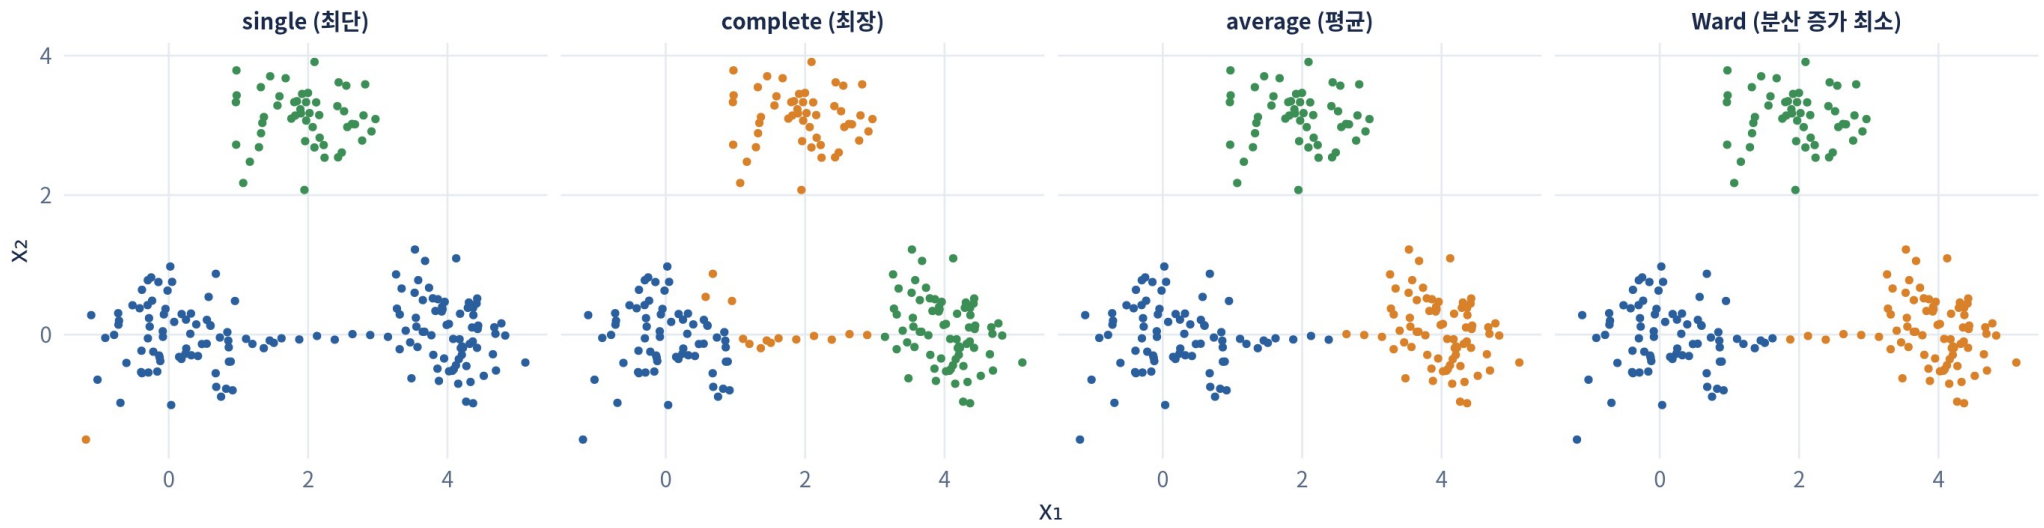
장점 : 어떤 비유사도도 OK, 이상치에 강건 , medoid 로 해석 쉬움

단점 : n 이 크면 느림 → clara() (표본으로 PAM)

HIERARCHICAL

계층적 군집 : 가까운 것부터 차례로 합친다

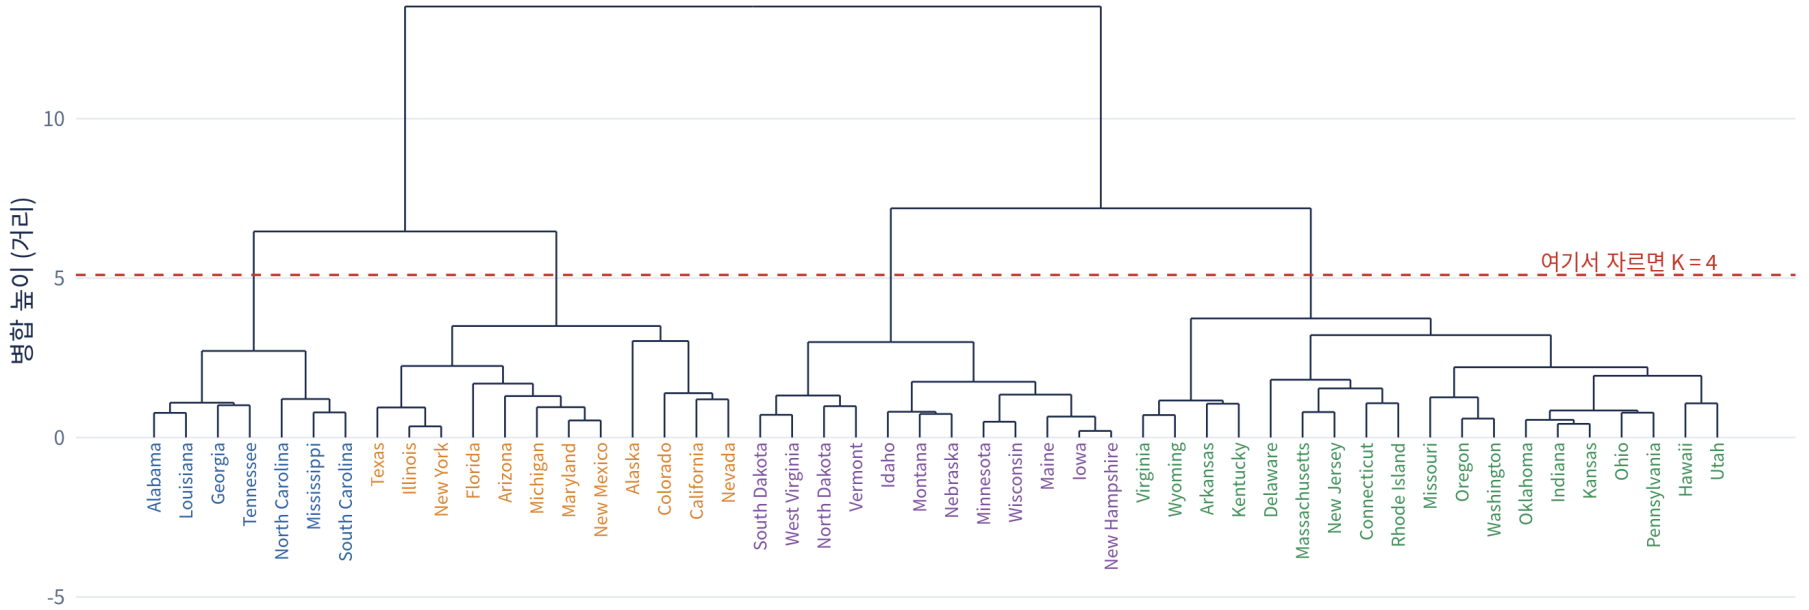
1. 관측치 n 개를 각각 군집으로 시작
2. 가장 가까운 두 군집을 합친다
3. 군집 간 거리를 다시 계산 (연결 방법)
4. 하나가 될 때까지 반복 → 덴드로그램



연결 방법	single	complete	average	Ward
두 군집 사이 거리	가장 가까운 쌍	가장 먼 쌍	모든 쌍의 평균	합쳤을 때 W 증가량

DENDROGRAM

덴드로그램 읽기 : USArrests (50 개 주 , 표준화 , Ward)



군집	n	Murder	Assault	UrbanPop	Rape
1	7	14.7	251	54	21.7
2	12	11.0	264	77	33.6
3	19	6.2	142	71	19.2
4	12	3.1	76	52	11.8

군집별 평균 (원래 단위). 1 = 남부 고살인 , 2 = 도시형 고범죄 , 3 = 중간 , 4 = 농촌 저범죄

읽는 법

- 높이 = 합쳐질 때의 거리 . 늦게 합쳐질수록 서로 다른 무리
- 수평선으로 자르는 높이가 K 를 정한다 (cutree) → 한 번 적합으로 모든 K
- 한 번 합친 것은 되돌릴 수 없고 , n × n 거리 행렬이 필요

R 실습 : kmeans · pam · hclust

R CONSOLE

```
X <- scale(USArrests)              #  표준화

# k-means:  여러 초기값
set.seed(1)
km <- kmeans(X, centers = 4, nstart = 25)
km$cluster; km$centers; km$tot.withinss

# PAM:  어떤 비유사도도 가능
library(cluster)
pm <- pam(X, k = 4)                #  유클리드
pm$medoids                         #  대표 관측치
pg <- pam(daisy(df, metric = "gower"),
          k = 4, diss = TRUE)      #  혼합형 변수
```

R CONSOLE

```
#  계층적 군집
d  <- dist(X)                              #  거리 행렬
hc <- hclust(d, method = "ward.D2")
plot(hc, cex = 0.6)                        #  덴드로그램
rect.hclust(hc, k = 4)                     #  4 개로 자른 상자
cl <- cutree(hc, k = 4)                    #  군집 번호

#  군집 프로파일 :  해석의 출발점
aggregate(USArrests, list(cl = cl), mean)
table(cl, km$cluster)                      #  방법 간 비교
```

hclust 의 "ward.D2" 가 Ward 방법의 정확한 구현 ("ward.D" 는 제곱하지 않은 거리를 사용)

PART 3

군집은 몇 개인가 ?

Elbow · 실루엣 · gap 통계량 — 그리고 결국 분야 전문가

군집 수 K 를 고르는 방법들

1 Elbow

K 에 따른 W_K 를 그려 감소가 갑자기 완만해지는 "팔꿈치" . W_K 는 K 가 커지면 항상 감소하므로 최소값으로 고를 수 없다 . 꺾임이 애매한 경우가 많음

2 실루엣

s(i) = (b(i) − a(i)) / max{a(i), b(i)}. a: 자기 군집 평균 거리 , b: 가장 가까운 다른 군집의 평균 거리 . 1 에 가까울수록 잘 배정 . 평균 s(i) 가 최대인 K

3 Gap 통계량

W_K 의 감소가 "군집 구조가 전혀 없는 데이터" 에서 기대되는 감소보다 얼마나 큰가 (Tibshirani et al., 2001) → 다음 슬라이드

Model-based 라면 : BIC (ICL)

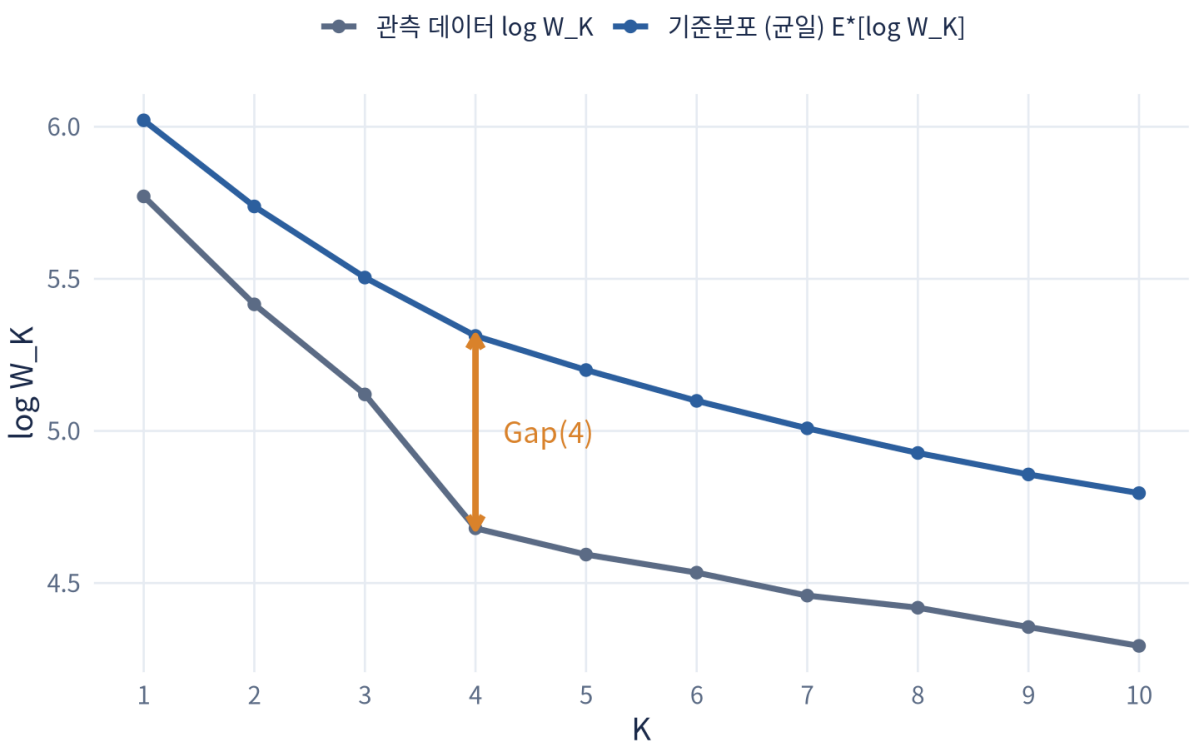
우도가 있으므로 정보기준으로 K 와 공분산 구조를 함께 선택 (Part 1)

그 밖에

Calinski-Harabasz, 안정성 (재표본 후 같은 군집이 나오는가) 등 . NbClust 패키지는 30 개 지수를 한꺼번에 계산

Gap 통계량 : “ 구조 없는 데이터” 와 비교한다

$$\mathrm{Gap}(K) = E^*[\log W_K] - \log W_K$$



예 : 참 K = 4 인 시뮬레이션 데이터 , k-means, B = 100 (다음 슬라이드). R: cluster::clusGap(), maxSE()

1 기준분포 만들기

데이터 범위 (상자) 안의 균일분포에서 같은 크기의 데이터를 B 개 생성 (보통 B = 100 이상)

2 E*[log W_K] 계산

각 가짜 데이터에 같은 군집 방법 → log W_K 의 평균과 표준편차 sd_K, $s_K = sd_K \sqrt{(1 + 1/B)}$

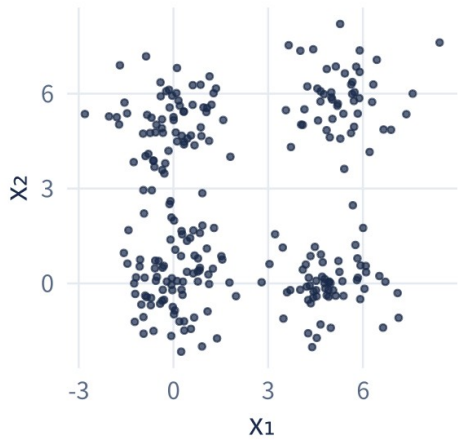
3 1-SE 규칙

$\mathrm{Gap}(K) \geq \mathrm{Gap}(K+1) - s_{K+1}$ 를 만족하는 가장 작은 K

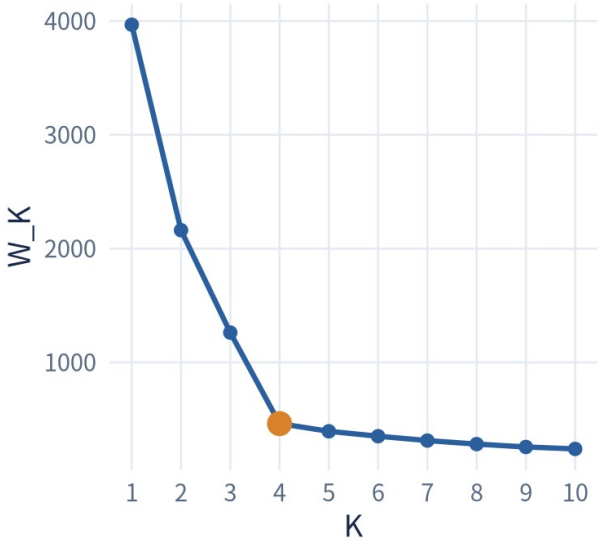
SIMULATION

구조가 뚜렷하면 세 기준이 모두 같은 답을 준다

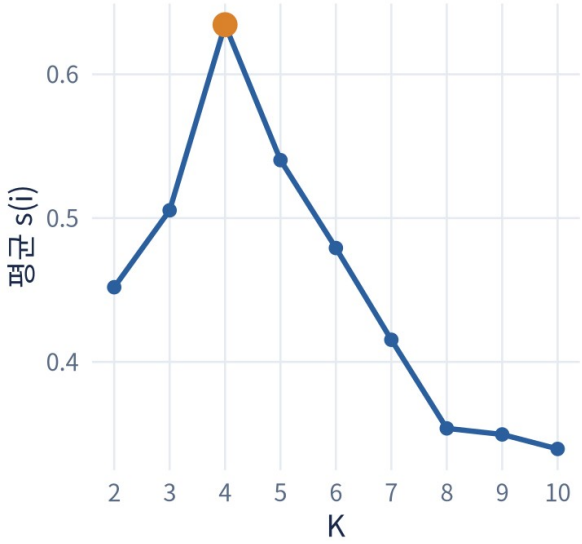
데이터 (참 K = 4)



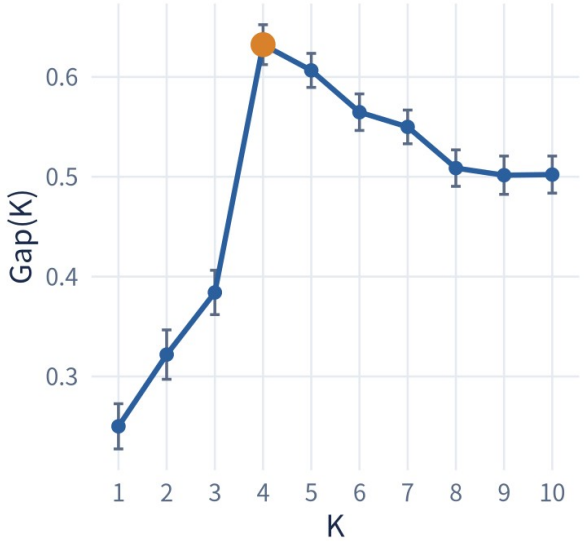
Elbow: 군집 내 제곱합 W_K



평균 실루엣 폭



Gap 통계량 (±1 SE)



K	3	4	5
Gap(K)	0.384	0.632	0.607
s_K	0.022	0.020	0.017

1-SE 규칙 : Gap(4) = 0.632 ≥ Gap(5) − s_5 = 0.590 → K = 4. Elbow 는 K = 4 에서 꺾이고 , 평균 실루엣도 K = 4 에서 최대 (0.63)

4 개 군집 (n = 80, 60, 70, 50), 각 군집은 분산 0.9 의 구형 정규분포 . kmeans(nstart = 25)

REAL DATA

실제 데이터에서는 기준마다 답이 다르다 : USArrests

기준	선택한 K	비고
Elbow (k-means W_K)	?	뚜렷한 꺾임 없음
평균 실루엣	2	0.408 (K = 2) > 0.340 (K = 4) > 0.309 (K = 3)
Gap, 1-SE 규칙	2	Gap(2) = 0.236 ≥ Gap(3) − s_3 = 0.219
Gap, 최대값	4	Gap(4) = 0.292 가 최대
mclust BIC	3	VEI 모형 , 2 위 EEI·4 와 차이 4.8

왜 다를까 ?

- 실제 데이터는 뚜렷이 떨어진 덩어리가 아니라 연속적으로 퍼져 있는 경우가 많다
- 기준마다 “좋은 군집”의 정의가 다르다

통계적 기준은 “후보”를 좁혀 줄 뿐
K = 2 (범죄 많음 / 적음) 도 , K = 4 (남부 고살인 · 도시형 고범죄 · 중간 · 농촌 저범죄) 도 데이터와 모순되지 않는다 . 어느 쪽이 쓸모 있는지는 목적과 분야 지식이 정한다

DOMAIN EXPERT

결국 중요한 것 : 분야 전문가가 인정하는 군집

1 해석 가능한가

군집별 평균 · 분포 (프로파일) 를 보고 이름을 붙일 수 있는가 ? 예 : " 남부 고살인형 " , " 농촌 저범죄형 "

2 실행 가능한가

군집마다 다른 행동 (마케팅 , 치료 , 정책) 을 할 수 있는가 ? 구분해도 할 일이 같으면 나눌 이유가 없다

3 안정적인가

표본을 바꾸거나 (bootstrap) 방법 · 초기값을 바꿔도 비슷한 군집이 나오는가 ? (fpc::clusterboot)

4 크기가 적절한가

관측치 몇 개뿐인 군집은 이상치 무리일 수 있다 . 실무에서 다룰 수 있는 개수인가

작업 방식 : 통계 기준으로 후보 K 몇 개 → 군집 프로파일 표 → 전문가와 함께 검토 → 이름 붙이기 → 확정

PART 4

군집 다음에 예측모형이 오면

예측 성능으로 군집 수를 정하고 , 군집마다 다른 모형과 변수를 본다

CLUSTER → PREDICT

군집을 예측모형의 앞단으로 쓰기

데이터

고객 특성 z
예측변수 x, 반응 y

→

① 군집

z 로 K 개 군집
(k-means, GMM 등)

→

② 군집별 모형

군집 k 의 데이터로
$\hat{y} = \hat{f}_k(x)$ 적합

→

③ 예측

새 관측치 → 군집 배정
→ 그 군집의 모형

1 K 를 예측 성능으로 정한다

이제는 "정답" 이 있다 : y 의 CV 오차가 가장 작은 K 를 고르면 된다 .
군집분석의 가장 어려운 문제 (K 선택) 를 객관적 기준으로

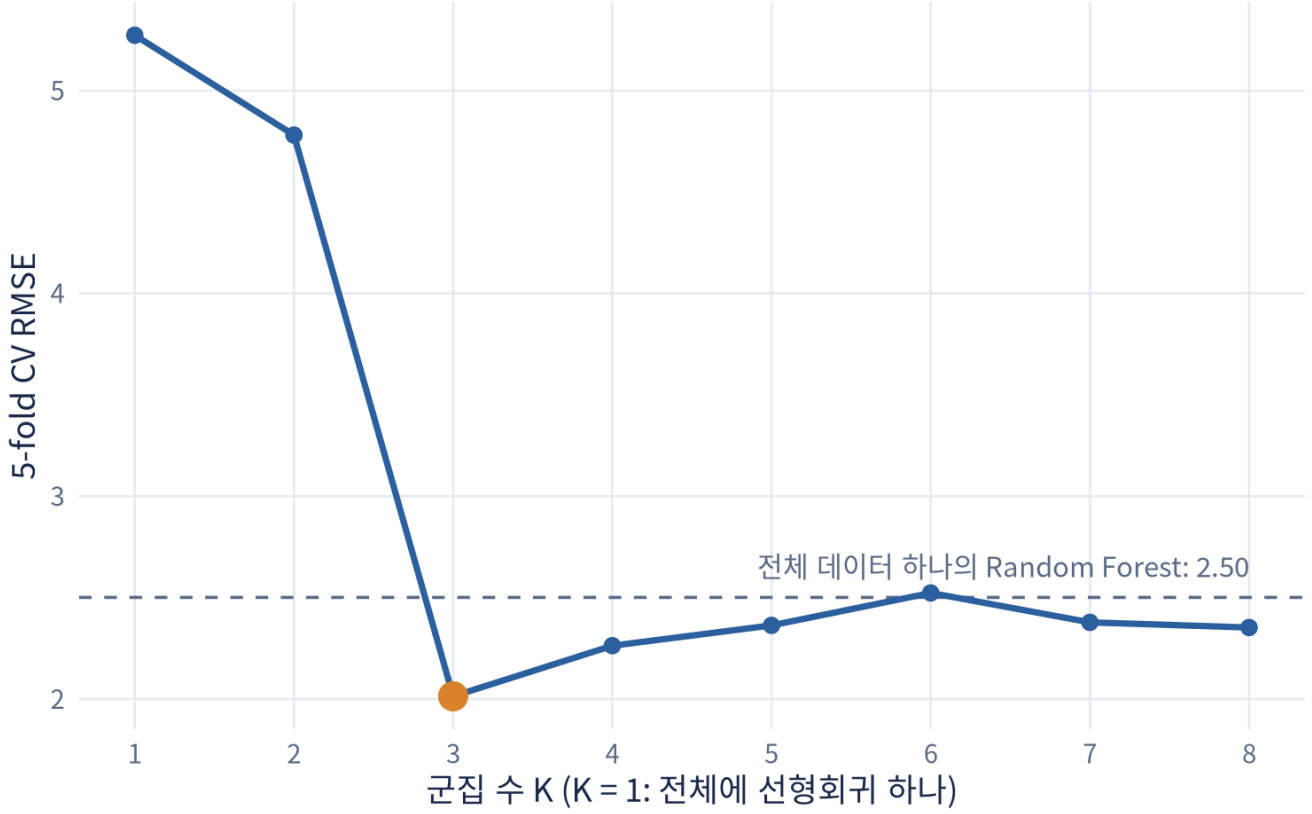
2 더 풍부한 설명

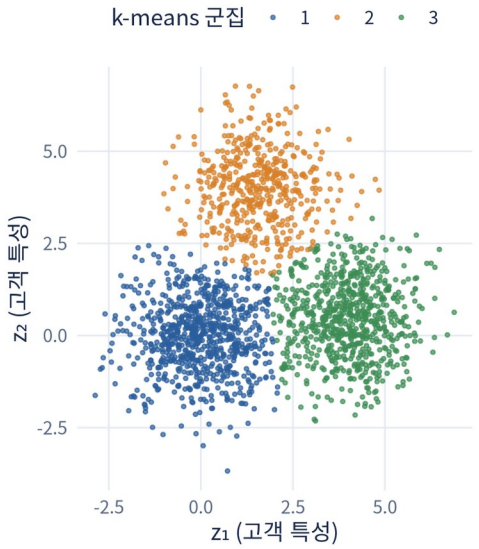
군집마다 다른 모형 (선형 / RF) 을 쓰거나 , 같은 모형이라도 군집마다 다른 변수가 중요해지면 "누구에게 무엇이 중요한가" 를 말할 수 있다

주의 : CV 의 각 fold 안에서 군집도 다시 적합해야 한다 (학습 fold 로 군집 → 테스트 fold 는 가장 가까운 중심에 배정). 밖에서 하면 정보 누수

SIMULATION

예측 성능으로 군집 수 고르기





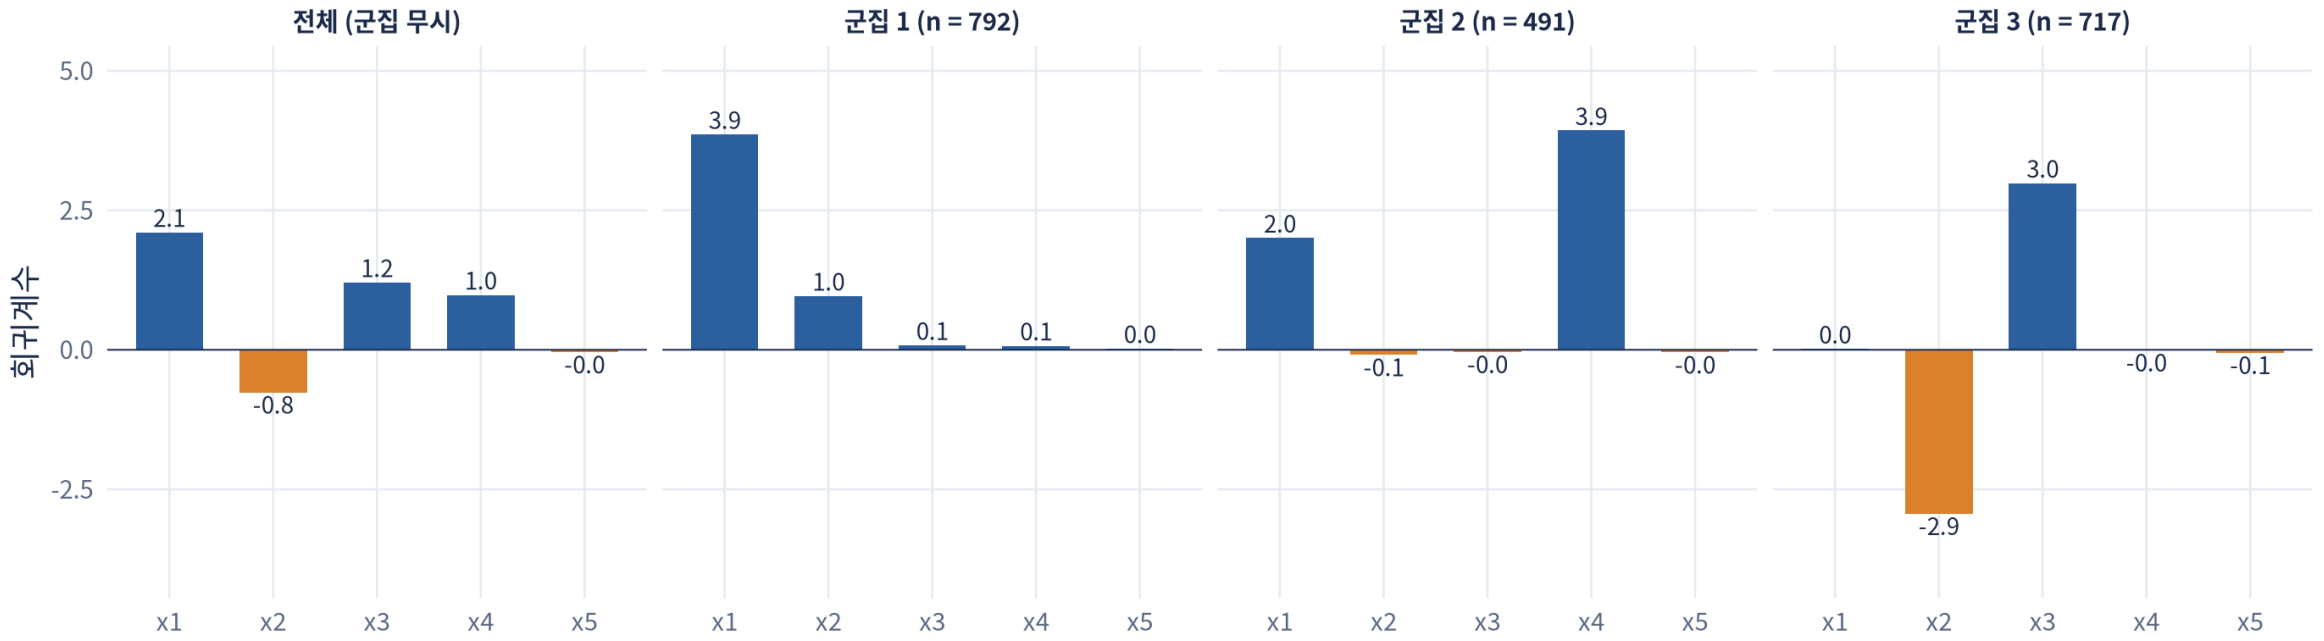
설정 (n = 2,000)

숨은 고객 집단 3 개가 z 에서 구분됨 . 집단마다 y 와 x_1~x_5 의 관계 (계수) 가 다르다

결과 : K = 1 (선형회귀 하나) 5.27 → K = 3 에서 최소 2.01. 전체 데이터에 Random Forest 하나 (z, x 모두 사용) 는 2.50

RICHER EXPLANATION

군집마다 다른 변수가 중요하다



군집 1

x_1 이 핵심 (3.9)

군집 2

x_4 (3.9) 와 x_1 (2.0)

군집 3

x_2 는 음 (−2.9), x_3 은 양 (3.0)

전체 하나

모든 계수가 평균되어 흐려짐 : x_2 −0.8

해석 : "x_2(예 : 가격) 를 올리면 판매가 조금 준다" 가 아니라 "군집 3 고객에게만 크게 줄고 나머지는 거의 영향 없다" . 군집마다 RF 등 다른 모형을 써도 되고 , 그때는 군집별 VIP · PDP 로 비교

SUMMARY

오늘의 핵심 정리

1	**GMM**	$f(x) = \Sigma\, \pi_k\, \phi(x; \mu_k, \Sigma_k)$, EM 으로 추정 , 소속 확률 τ_{ik} 로 soft clustering
2	**mclust**	$\Sigma_k = \lambda_k D_k A_k D_k^{\top}$ → 14 개 모형 . BIC(클수록 좋음) 로 모형과 G 를 함께 선택 , ICL 도 참고
3	**Model-free**	k-means (평균 , 빠름 , 구형 선호) · PAM (medoid, 강건 , 아무 거리) · 계층적 (덴드로그램 , 연결 방법)
4	**군집 수**	Elbow · 실루엣 · gap(1-SE) · BIC 는 후보를 좁힐 뿐 → 전문가가 인정하는 군집이 최종
5	**예측과 결합**	y 의 CV 오차로 K 선택 , 군집별 모형 · 중요 변수 비교로 더 풍부한 설명

흐름 : 거리 · 변수 정하기 → 방법 선택 → 후보 K → 프로파일과 전문가 검토 → (필요하면) 예측모형과 결합