CHAPTER · MISSING VALUES

결측값 처리
지우기 , 채우기 , 그리고 조심할 것

완전한 행만 쓸 때 · 열과 행을 버릴 때 · 대표값 · kNN · missForest · MICE — 그리고 Y 는 대체에 쓰지 않는다

Chapter 2(결측치 처리) 의 확장 · R: VIM · naniar · DMwR2 · missForest · missRanger · mice · 데이터 : algae, Boston, 시뮬레이션

OVERVIEW

학습 목표

1 결측이 생기는 이유

MCAR · MAR · MNAR 를 구분하고 , 메커니즘에 따라 같은 방법이 편향되기도 하고 괜찮기도 한 이유를 설명할 수 있다 .

2 버릴 것인가

완전한 행만 쓰는 경우 , 결측이 많은 열 · 행을 분석에서 빼는 경우의 기준과 비용을 판단할 수 있다 .

3 채울 것인가

대표값 · kNN · missForest(missRanger) · MICE 등 대체 방법의 원리와 장단점을 비교하고 R 로 수행한다 .

4 Y 와 평가

대체에 Y 를 쓰면 안 되는 이유 , Y 가 결측일 때의 주의점 , 결측 메커니즘에 따라 좋은 방법의 순위가 바뀌는 것을 실험으로 확인한다 .

WHY IT MATTERS

결측값을 그냥 두면 무슨 일이 생기나

1 조용히 사라지는 행

lm(), glm() 은 기본값 na.action = na.omit: 결측이 하나라도 있는 행을 말없이 버린다 . summary() 의 자유도를 보기 전에는 모른다

2 멈추는 모형

randomForest(), kmeans(), dist() 등은 NA 가 있으면 오류 . predict() 는 NA 가 있는 새 관측치에 NA 를 돌려준다 → 예측이 필요한데 답이 없다

3 결측 자체가 정보

신용평가 케이스 : Income 이 비어 있는 신청자의 불량률 57% vs 25%. 지우거나 평균으로 채우면 이 신호가 사라진다

결측 처리는 “전처리 잡일” 이 아니라 분석 결과를 바꾸는 결정이다
같은 데이터라도 결측을 어떻게 다루느냐에 따라 회귀계수의 부호 , 변수 중요도 , 예측 성능이 달라진다 .
그래서 질문 순서 : ① 왜 빠졌나 (메커니즘) ② 얼마나 , 어디에 빠졌나 (패턴) ③ 무엇을 하려는가 (추론 vs 예측) ④ 방법 선택 ⑤ 평가

THE MAP

결측 처리 방법의 지도

접근	방법	언제	이 강의
버리기	완전한 행만 사용 (listwise deletion)	MCAR, 결측이 적고 n 이 클 때	Part 2
	결측이 많은 열 (변수) / 행 (관측치) 제외	거의 비어 있는 변수 · 관측치	Part 2
단순 대체	평균 · 중앙값 · 최빈값 , 결측 지시변수	빠른 기준선 , 트리 모형과 함께	Part 3
이웃 기반	kNN 대체 , hot-deck	비슷한 관측치가 충분할 때	Part 4
모형 기반	missForest · missRanger · mixgb, 회귀 대체	비선형 · 상호작용 · 혼합형 변수	Part 5
다중 대체	MICE + Rubin 의 규칙	추론 (계수 · 표준오차) 이 목적일 때	Part 5
모형이 직접	XGBoost · LightGBM 의 결측 방향 , rpart 대리 분할	예측만이 목적이고 해당 모형을 쓸 때	Part 5

모든 방법에 공통인 두 규칙 : ① 대체 규칙은 학습 데이터에서만 배운다 ② 예측 모형의 대체에는 Y 를 쓰지 않는다 (Part 6)

PART 1

결측을 이해하기

왜 빠졌는가 (메커니즘), 얼마나 · 어디에 빠졌는가 (패턴)

MECHANISMS

결측 메커니즘 : Rubin (1976) 의 세 가지 분류

R = 결측 지시 (1 이면 결측), X_obs = 관측된 값 , X_mis = 결측된 (원래 있었을) 값

MCAR

Missing Completely At Random

$$P(R \mid X_{obs}, X_{mis}) = P(R)$$

결측이 어떤 값과도 무관 . 예 : 실험실에서 시료 일부를 실수로 떨어뜨림 , 설문지 한 장이 분실

MAR

Missing At Random

$$P(R \mid X_{obs}, X_{mis}) = P(R \mid X_{obs})$$

결측이 다른 관측된 변수로 설명됨 . 예 : 나이 든 응답자일수록 소득 문항을 비워 둠 (나이는 관측)

MNAR

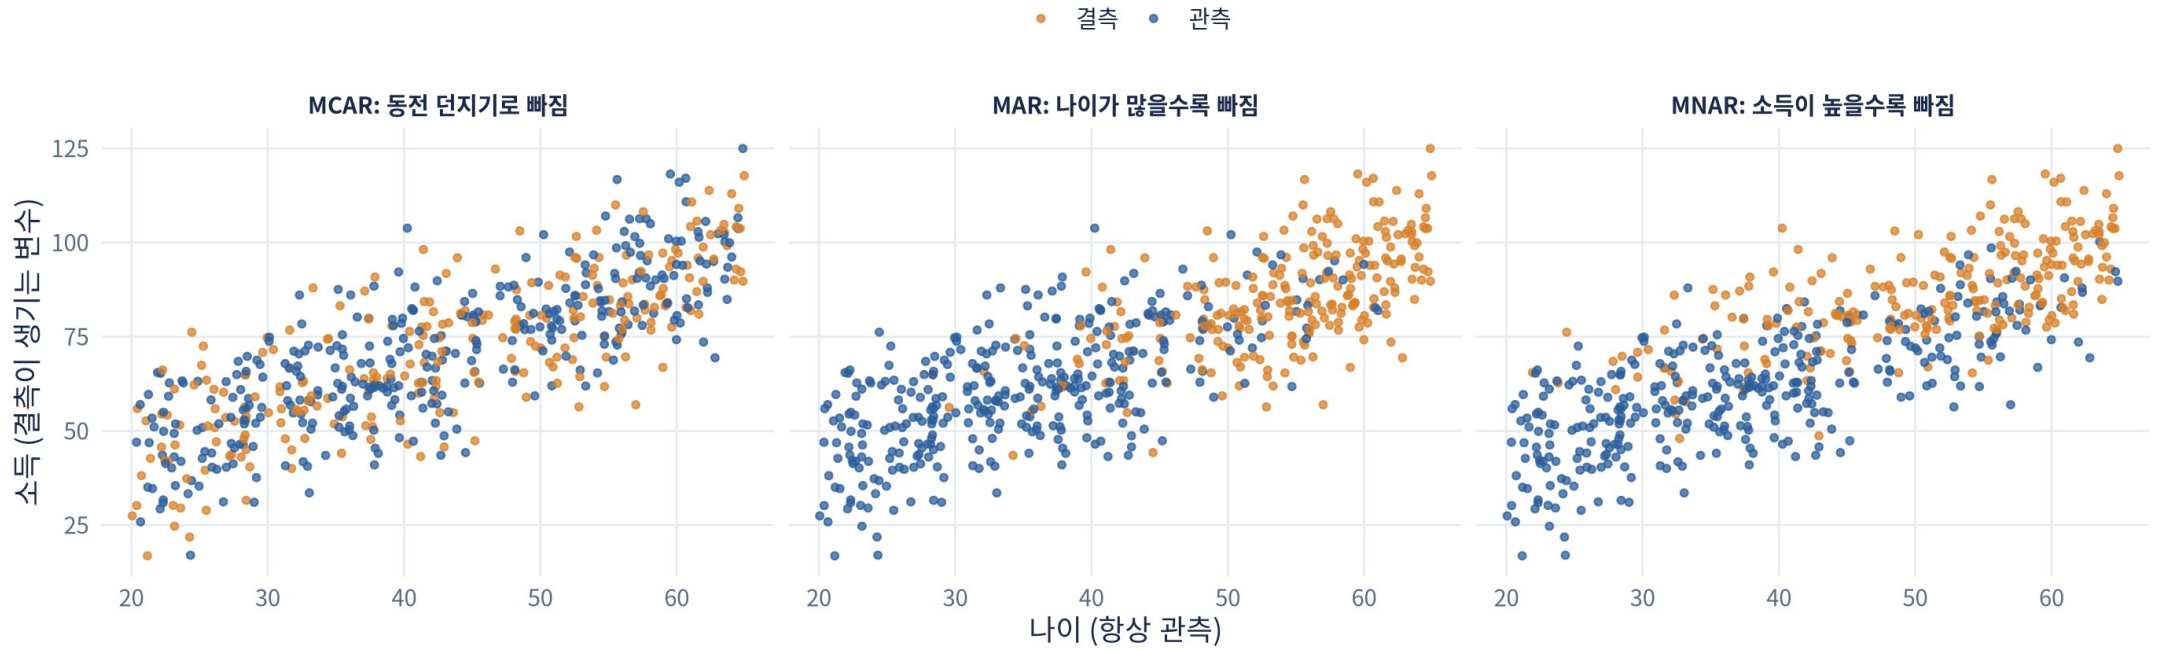
Missing Not At Random

$P(R \mid X_{obs}, X_{mis})$ **가** X_{mis} **에 의존**

결측이 그 값 자체에 의존 . 예 : 소득이 높은 사람이 소득을 숨김 , 증상이 심한 환자가 추적 관찰에서 빠짐

이름의 함정 : MAR 는 “무작위로 빠졌다” 가 아니다 . “ 관측된 변수를 조건으로 하면 무작위” 라는 뜻 → 그 변수를 대체 모형에 넣으면 편향을 고칠 수 있다

같은 40% 결측이라도 메커니즘에 따라 결과가 다르다



소득의 평균 (참값 70.95)	MCAR	MAR	MNAR
완전한 행만 사용	70.43	61.06	60.58
나이로 회귀 대체 후 평균	71.19	69.89	65.93

MCAR: 버려도 편향 없음 . **MAR:** 버리면 편향 , 나이를 쓰면 대부분 회복 . **MNAR:** 나이를 써도 회복 안 됨 — 빠진 이유가 소득 자체이므로

DIAGNOSIS

메커니즘을 데이터로 알 수 있을까 ?

1 MCAR 인지 확인

결측 여부 (R) 에 따라 다른 변수들의 분포가 같은지 비교 . 다르면 MCAR 가 아니다 . Little 의 MCAR 검정 (naniar::mcar_test)

2 MAR 의 증거

결측 지시변수를 다른 변수로 예측해 본다 (로지스틱 · 트리). 잘 예측되면 MAR 가능성 → 그 변수들을 대체 모형에 반드시 포함

3 MNAR 은 검정 불가

빠진 값을 모르니 데이터만으로는 구분할 수 없다 . 분야 지식 (“ 고소득층이 소득을 숨긴다”) 과 민감도 분석으로 판단

실무적 신호 : 결측 여부가 Y 와 관련 있는가 ?

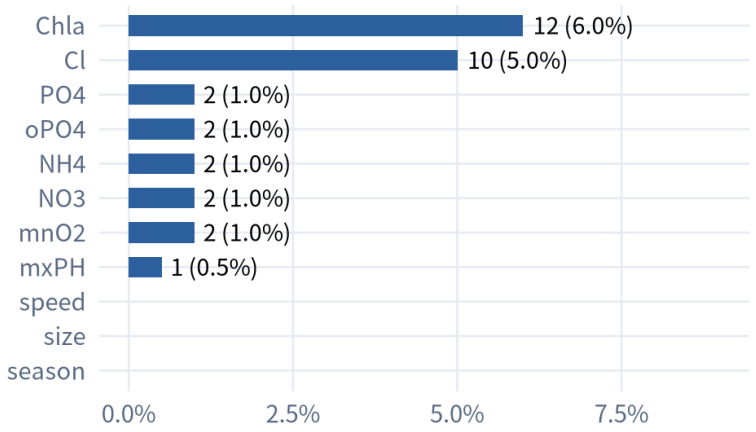
credit_data: Income 결측자의 불량률 57% vs 25%. Y 와 강하게 관련 → 결측 지시변수를 예측변수로 쓰는 것이 유리 .

(이 비교는 학습 데이터에서 하는 탐색이며 , Y 를 대체 모형에 넣는 것과는 다르다)

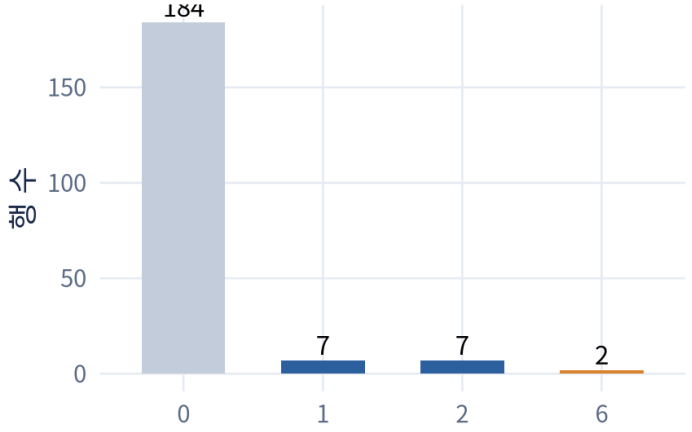
EXPLORE THE PATTERN

결측 패턴 탐색 : algae 데이터 (200 개 관측치 , 설명변수 11 개)

변수(열)별 결측 비율

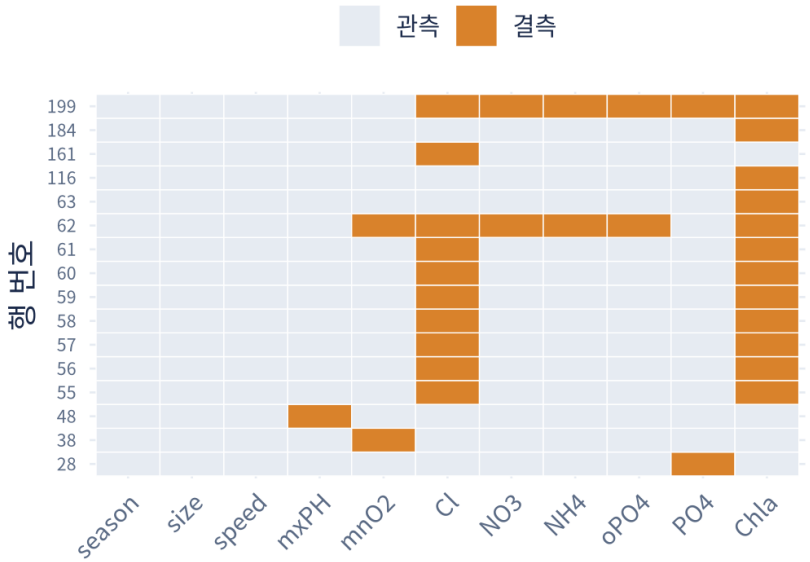


관측치(행)별 결측 개수



한 행의 결측 개수 (11개 변수 중)

결측이 있는 16개 행의 패턴



열 기준

Chla 12 개 (6%), Cl 10 개 (5%). 다른 변수는 2 개 이하

행 기준

184 개 완전 , 결측 1 개 : 7 행 , 2 개 : 7 행 , 6 개 : 2 행 (62 번 , 199 번)

패턴

55~61 번 행 : Cl 과 Chla 가 함께 빠짐 → 같은 원인 (측정일 · 장비) 일 가능성

완전한 행만 쓰면

200 → 184 개 (8% 손실)

R: 결측 패턴 탐색

R CONSOLE

```
algae <- read.table("Analysis.txt", na.strings = "XXXXXXX",
                    col.names = c("season","size","speed",
                      "mxPH","mnO2","Cl","NO3","NH4","oPO4",
                      "PO4","Chla", paste0("a", 1:7)))
X <- algae[, 1:11]
colSums(is.na(X))                  #  열별 결측 수
colMeans(is.na(X))                 #  열별 결측 비율
table(rowSums(is.na(X)))           #  행별 결측 개수
which(rowSums(is.na(X)) > 3)       # 62, 199
mean(complete.cases(X))            # 0.92

library(VIM);    aggr(X, numbers = TRUE)   #  패턴 그림
library(naniar); vis_miss(X)               #  결측 위치
                 gg_miss_upset(X)          #  함께 빠지는 조합
                 mcar_test(X[, 4:11])      # Little의 검정
```

is.na() + colSums/rowSums

열 기준 · 행 기준 결측의 기본 요약

complete.cases()

완전한 행의 논리 벡터

VIM::aggr()

결측 비율 막대 + 패턴 조합 그림

naniar

ggplot 기반 결측 시각화 · 요약 · MCAR 검정

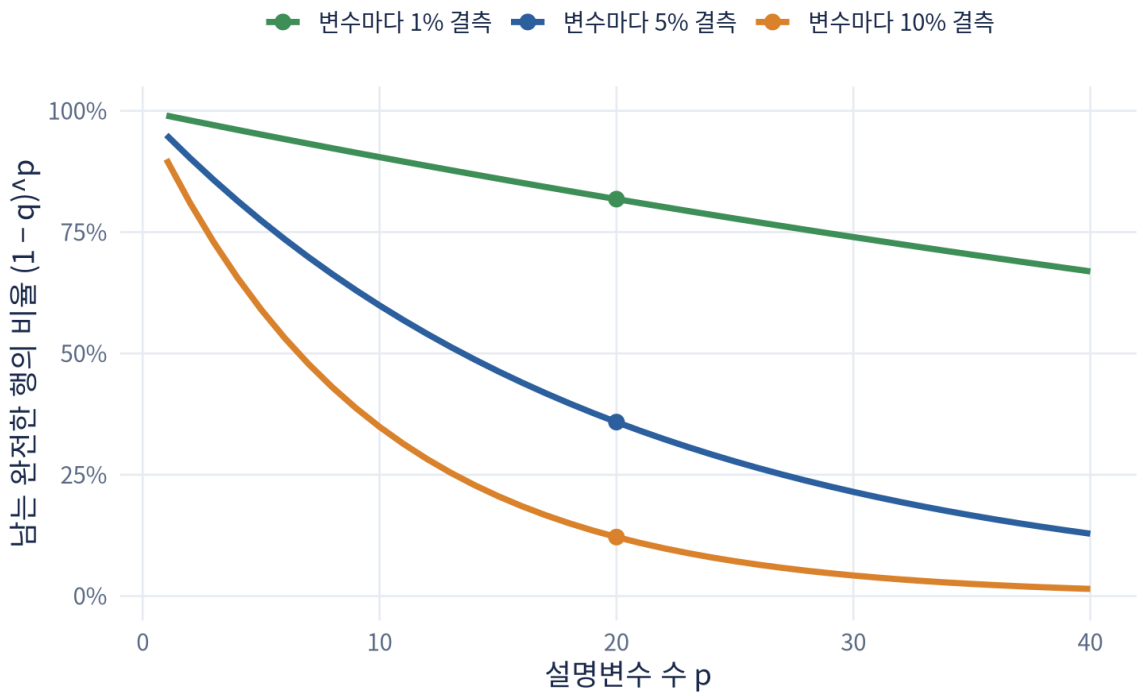
PART 2

버리기 : 행 · 열 제거

완전한 행만 쓰는 경우 , 결측이 아주 많은 변수와 관측치를 빼는 경우

COMPLETE CASES

완전한 행만 사용하기 (listwise deletion)



괜찮은 경우

- MCAR 이고 결측 행이 적을 때 (대략 5% 이하)
- n 이 충분히 커서 줄어도 괜찮을 때
- 가장 단순하고 결과 재현이 쉽다

문제

- MAR · MNAR 이면 편향 (앞의 소득 예 : 70.95 → 61.06)
- 변수가 많으면 행이 급격히 사라진다 (왼쪽 그림)

예측에서는 "테스트에서 지울 수 없다"
변수마다 5% 씩 결측 , p = 20 이면 남는 행은 $0.95^{20} = 36\%$. 학습은 완전한 행으로 해도 , 새 신청자에게 결측이 있으면 예측을 거부할 수는 없다 → 결국 대체 규칙이 필요

DROP A COLUMN?

결측 비율이 아주 높은 변수 (열) 는 빼는 것이 나을 수 있다

1 빼는 것이 나은 경우

- 예 : 60~80% 가 비어 있는 변수 . 대체값이 대부분 “만든 값” 이 된다
- 다른 변수와 정보가 겹친다 (예 : 상관이 큰 대체 변수가 있다)
- 기준은 정해진 것이 없다 . 흔히 40~50% 이상이면 검토

2 빼기 전에 확인

- 결측 여부가 Y 와 관련 있나 ? 있다면 변수는 빼더라도 결측 지시변수 (x_NA) 는 남긴다
- 분야에서 핵심 변수인가 ? (예 : 임상의 핵심 검사값)
- 다른 출처에서 채울 수 있나 ?

예	결측 비율	판단
algae Chla	6%	남기고 대체
credit Income	8.6%, 결측자 불량률 57%	남기고 대체 + Income_NA
(가상) 연봉 협상 메모	75%, Y 와 무관	제외

DROP A ROW?

결측이 아주 많은 관측치 (행) 는 분석에서 빼는 것이 나을 수 있다

행	season	size	speed	mxPH	mnO2	Cl	NO3	NH4	oPO4	PO4	Chla
62	summer	small	medium	6.4	NA	NA	NA	NA	NA	14.0	NA
199	winter	large	medium	8.0	7.6	NA	NA	NA	NA	NA	NA

1 왜 빼나

11 개 중 6 개 (55%) 가 비어 있다 . 대체하면 이 행의 절반 이상이 모형이 만든 값 → 학습에 기여하는 정보는 적고 , 잘못된 패턴을 심을 위험은 크다

2 주의

학습 데이터에서만 뺄 수 있다 . 예측 시점에 이런 신청자가 오면 ? → 기본 대체로 예측하되 “정보 부족” 표시 , 사람 검토로 넘기는 규칙을 따로 둔다

R CONSOLE

```
library(DMwR2);  manyNAs(algae, nORp = 0.2)      # 변수의 20% 넘게 빠진 행 : 62 199
algae <- algae[-manyNAs(algae), ]                # Chapter 2 교재와 같은 처리
```

PART 3

가장 간단한 대체 : 대표값

평균 · 중앙값 · 최빈값 , 그리고 결측 지시변수

SIMPLE IMPUTATION

대표값으로 채우기

평균

대칭인 수치형 변수

중앙값

치우친 변수 (소득 · 자산 · 농도). 이상치에 강건

최빈값

범주형 변수

새 범주 "missing"

범주형에서 결측 자체를 하나의 범주로

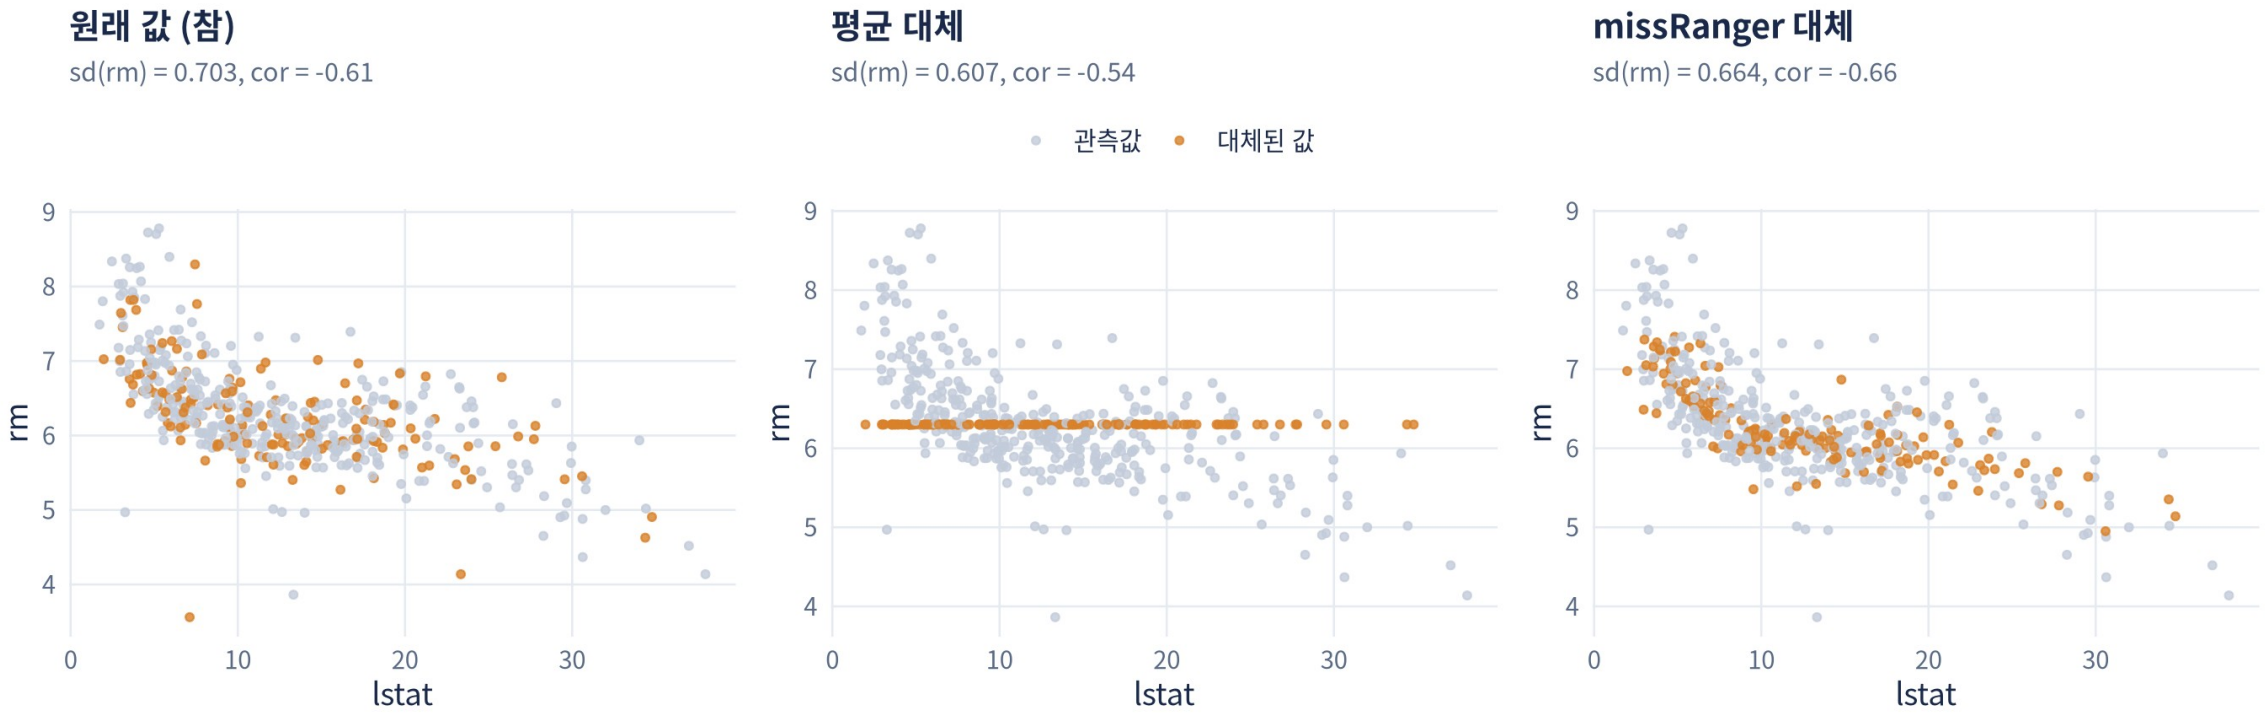
R CONSOLE

```
# 학습 데이터의 값으로 학습 · 테스트 모두 채운다
med <- sapply(train[, num.vars], median, na.rm = TRUE)
for (v in num.vars) {
  train[[v]][is.na(train[[v]])] <- med[v]
  test[[v]][is.na(test[[v]])]   <- med[v]   # 테스트 중앙값 X
}
# DMwR2::centralImputation(train)  # 중앙값 · 최빈값 한 번에
```

장점과 단점

- 가장 빠르고 재현이 쉽다 → 기준선
- 트리 모형은 대체값 근처 분할로 어느 정도 흡수
- 분산 축소 · 상관 약화 · 분포에 뾰족한 봉우리 (다음 슬라이드)

평균 대체가 데이터를 어떻게 바꾸나 (Boston, rm 의 30% MCAR)



	원래 값	평균 대체	missRanger
sd(rm)	0.703	0.607 (−14%)	0.664
cor(rm, lstat)	−0.61	−0.54	−0.66

추론에 미치는 영향 : 분산이 작아져 표준오차가 과소추정되고 상관 · 회귀계수가 0 쪽으로 줄어든다 . 모형 기반 대체도 상관을 과장할 수 있다 (−0.66) — 예측값으로 채우면 “너무 깔끔한” 값이 된다

결측 지시변수 : “ 비어 있었다” 는 사실을 남긴다

Income	→	Income (대체)	Income_NA
250		250	0
NA		125 (중앙값)	1
90		90	0
NA		125 (중앙값)	1

효과 (신용평가 케이스)

- 로지스틱 CV AUC: 중앙값 대체 0.831 → 지시변수 추가 0.837
- Income_NA 의 오즈비 3.6

1 언제 효과가 있나

결측 여부 자체가 Y 와 관련될 때 (MNAR 이거나 결측이 어떤 집단을 나타낼 때). 뒤의 실험 : MNAR 에서 평균 + 지시변수가 1 위

2 주의

추론 (회귀계수 해석) 목적에서는 편향을 만들 수 있다고 알려져 있다 . 예측에서는 유용한 경우가 많다 . 결측이 학습 · 테스트에서 같은 이유로 생긴다는 가정이 필요

CONDITIONAL IMPUTATION

한 걸음 더 : 다른 변수를 이용한 대체

1 집단별 대표값

범주별 중앙값으로 채움 . 예 : season 별 Chla 중앙값 . 간단하지만 다른 변수 정보를 일부 사용

2 회귀 대체

결측 변수를 다른 변수로 회귀 → 예측값으로 채움 . 예 : Chla ~ PO4 + oPO4 + season

3 확률적 회귀 대체

회귀 예측값 + 잔차 크기의 잡음 . 분산 축소를 줄임 (MICE 의 출발점)

R CONSOLE

```
# 회귀 대체 예 (algae, Chapter 2): PO4 와 oPO4 는 상관 0.91
fit <- lm(PO4 ~ oPO4, data = train)
i <- is.na(train$PO4) & !is.na(train$oPO4)
train$PO4[i] <- predict(fit, train[i, ])
j <- is.na(test$PO4) & !is.na(test$oPO4)
test$PO4[j]  <- predict(fit, test[j, ])   # 같은 fit
```

MAR 에서 효과

결측을 설명하는 변수를 회귀에 넣으면 MAR 의 편향을 고친다 (메커니즘 실험 : 61.06 → 69.89). 비선형 · 상호작용 · 여러 변수 동시 결측 → Part 5 의 방법들

PART 4

kNN 대체

비슷한 관측치 (이웃) 의 값을 빌려 온다

KNN IMPUTATION

kNN 대체 : 가까운 이웃 k 명의 값으로

1 거리 계산

결측이 있는 행 i 와 다른 행 사이의 거리를 둘 다 관측된 변수로만 계산 . 수치형은 표준화

2 이웃 고르기

그 변수가 관측된 행들 중 가장 가까운 k 개 (보통 k = 5~10)

3 값 빌려 오기

수치형 : 평균 · 중앙값 · 거리 가중평균 , 범주형 : 다수결

장점

- 분포 가정이 없고 다른 변수의 정보를 쓴다 (MAR 에 대응)
- 실제로 존재하는 값을 빌려 오므로 범위를 벗어난 값이 나오지 않는다
- Troyanskaya et al. (2001): 유전자 발현 자료에서 널리 쓰이기 시작

단점

- n^2 의 거리 계산 → 큰 데이터에서 느림
- 변수가 많으면 거리가 의미를 잃는다 (차원의 저주)
- 척도 · 거리 (Gower 등) · k 선택에 결과가 민감

kNN 대체를 쓸 때 정해야 할 것

1 표준화

Cl(수백 단위) 과 mxPH(7~9) 를 그대로 쓰면 거리가 Cl 로만 정해진다 . 학습 데이터의 평균 · 표준편차로 표준화

2 k 와 결합 방법

k 가 작으면 잡음 , 크면 평균 대체에 가까워짐 . 결측을 일부러 만들어 대체 오차를 비교해 고른다 (Part 7). 거리 가중평균이 흔한 선택

3 이웃은 학습 데이터에서

테스트 관측치를 채울 때 이웃 후보는 학습 데이터만 . 테스트끼리 이웃이 되면 학습 · 예측 규칙이 달라진다

R CONSOLE

```
library(DMwR2)
train.imp <- knnImputation(train[, 1:11], k = 10)                          # 거리 가중평균 (Chapter 2)
test.imp  <- knnImputation(test[, 1:11],  k = 10, distData = train[, 1:11])   # 이웃 후보 = 학습 데이터
library(VIM)
train.imp2 <- kNN(train[, 1:11], k = 5, imp_var = FALSE)                  # Gower 거리 , 범주형도 처리
```

PART 5

머신러닝 기반 대체와 다중 대체

missForest · missRanger · mixgb · MICE, 그리고 그 밖의 방법들

MISSFOREST

missForest: Random Forest 로 번갈아 채우기

1 초기값

평균 · 최빈값으로 일단 채운다

2 변수 순서

결측이 적은 변수부터 차례로

3 RF 적합

변수 j 가 관측된 행으로 x_j ~ 나머지 변수 RF 적합

4 예측해서 채움

x_j 가 결측인 행을 RF 예측값으로 교체

5 반복

모든 변수를 돌고, 바뀐 정도가 다시 커지면 멈춤

왜 인기가 있나

- 수치형 · 범주형을 함께 처리, 분포 가정 없음
- 비선형 관계와 상호작용을 자동으로 반영
- OOB 오차로 대체 정확도 추정 (NRMSE, 범주형은 PFC)

한계

- 느리다 : 변수 수 × 반복 수만큼 RF 적합
- 새 데이터에 적용하는 predict() 가 없다 (missForest 1.6 기준) → 학습 규칙을 테스트에 그대로 적용하기 어렵다
- 단일 대체 : 불확실성이 반영되지 않음

Stekhoven & Bühlmann (2012), Bioinformatics. R: missForest 패키지

FASTER & BOOSTED

missRanger 와 mixgb

missRanger (Mayer)

- missForest 와 같은 알고리즘을 빠른 ranger 로
- pmm.k > 0: 예측값 대신 가까운 관측값을 빌려 옴 (PMM) → 분포 보존
- keep_forests = TRUE + predict(): 학습 데이터로 만든 대체 모형을 테스트에 적용

mixgb (Deng & Lumley, 2023)

- XGBoost 로 연쇄 대체 , 부트스트랩 · PMM 으로 다중 대체
- 큰 데이터에서 빠르고 상호작용을 잘 잡는다
- mixgb(data, m = 5)

계산 시간 (Suh & Song, 2023 Table 2)	missForest	missRanger
6 개 데이터 , 결측 10~30%	약 20 분 ~ 175 분	수 초 ~ 약 90 초
대체 정확도 (IPM)	비슷	비슷

MULTIPLE IMPUTATION

MICE: 여러 번 채우고 , 결과를 합친다

1 연쇄 대체

변수마다 조건부 모형 (pmm, logreg 등) 으로 번갈아 채움 , maxit 회 반복

2 m 개의 데이터

무작위성을 넣어 서로 다른 완전한 데이터 m 개 (보통 5~20)

3 분석 후 결합

각 데이터로 분석 → Rubin 의 규칙으로 합침

$$\bar{Q} = (1/m)\ \Sigma\ Q_i$$
$$T = \bar{U} + (1 + 1/m)\ B$$

Ū: 데이터 안의 분산 평균 , B: 대체 간 분산 → 대체의 불확실성이 표준오차에 반영된다

언제 쓰나

- 목적이 추론일 때 : 회귀계수 , 신뢰구간 , 검정
- 단일 대체는 표준오차를 과소추정 → 유의하지 않은 것이 유의해 보인다
- van Buuren & Groothuis-Oudshoorn (2011)

예측에서는

- m 개 데이터로 각각 모형을 만들고 예측을 평균하거나 , 한 번만 채워 사용
- PMM 단일 대체 (m = 1) 는 일부러 잡음을 넣는 셈이라 예측에 불리할 수 있다 (뒤의 실험)

OTHER METHODS

그 밖에 자주 쓰는 방법들

방법	아이디어	특징 · R
Hot-deck	비슷한 관측치 (donor) 의 값을 그대로 복사	조사 통계에서 전통적 . VIM::hotdeck()
EM · Amelia	다변량 정규 가정에서 EM 으로 추정 , 부트스트랩으로 다중 대체	빠름 , 정규성 가정 . Amelia::amelia()
행렬 완성 (softImpute)	데이터 행렬이 저차원이라고 보고 낮은 계수로 근사해 빈칸 채움	추천 시스템 · 큰 수치 행렬 . softImpute::softImpute()
딥러닝	오토인코더 (MIDA), GAN(GAIN) 등으로 결측 생성	큰 데이터 · 이미지 · 복잡한 구조 . 표 데이터에서는 트리 기반이 자주 더 좋음
모형이 직접 처리	XGBoost · LightGBM: 분할마다 결측의 방향을 학습 . rpart: 대리 분할 (surrogate)	대체 불필요 . ranger 도 na.action = "na.learn" 지원
민감도 분석	MNAR 가정 (예 : 결측값이 관측값보다 δ 만큼 크다) 을 바꿔 가며 결과 비교	MNAR 이 의심될 때 결론의 견고함 확인 . mice 의 delta 조정

어떤 방법도 MNAR 을 데이터만으로 해결하지 못한다 . 모형 기반 대체는 MAR 까지를 가정한다

PART 6

Y 와 대체 : 가장 중요한 주의

예측 모형에서는 대체에 Y 를 쓰지 않는다 . Y 가 결측이면 더 조심한다

NEVER USE Y

예측 모형의 대체에는 Y 를 쓰지 않는다

1 테스트에는 Y 가 없다

실제로 예측할 때 (새 대출 신청자) 는 Y 를 모른다 . 학습 때 Y 를 넣고 만든 대체 규칙은 예측 시점에 똑같이 적용할 수 없다

2 누수

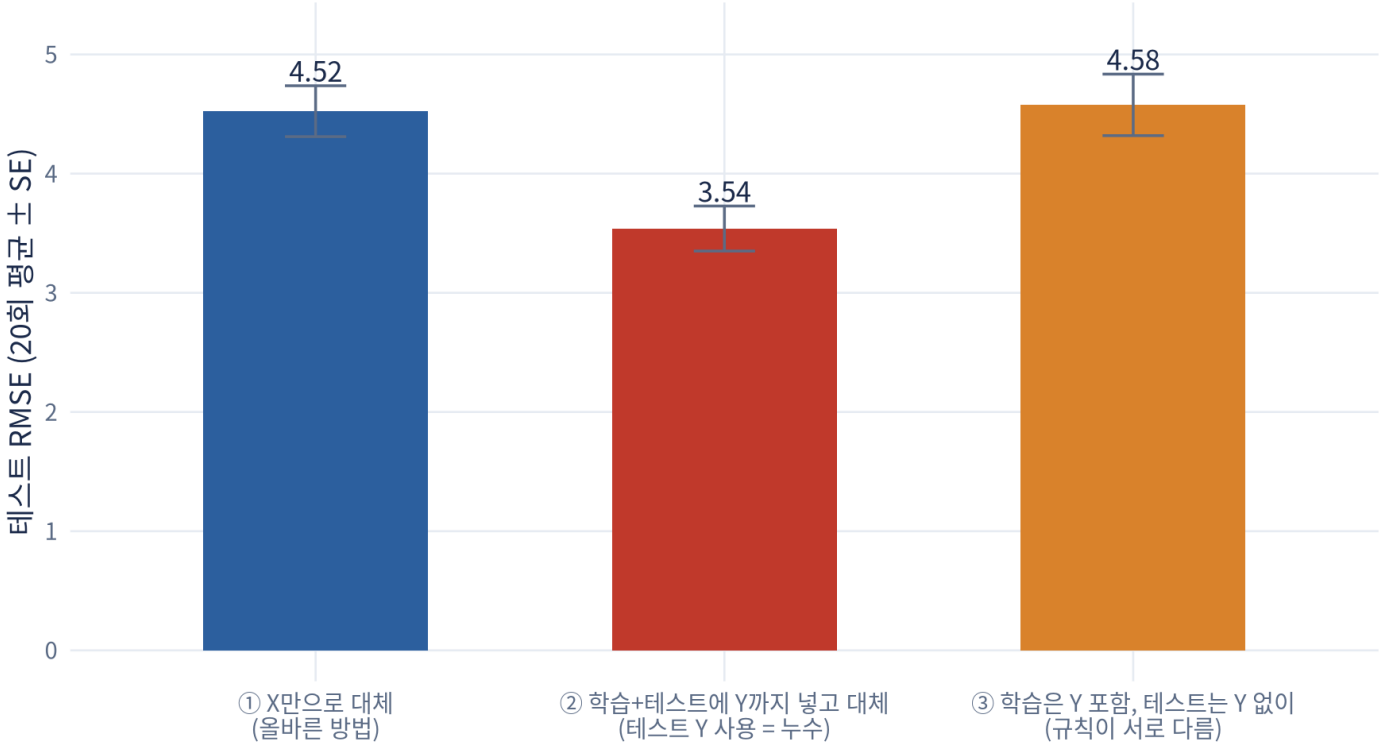
학습 + 테스트를 합쳐 Y 까지 넣고 대체하면 테스트의 Y 정보가 X 에 스며든다 → 테스트 성능이 실제보다 좋아 보인다

3 규칙의 불일치

학습은 Y 포함 , 테스트는 Y 없이 대체하면 두 데이터의 대체값이 서로 다른 규칙으로 만들어진다 → 모형이 학습한 관계가 테스트에서 어긋난다

원칙 : 대체 모형 = f(X), 학습 데이터에서 적합 → 학습 · 테스트 · 미래 데이터에 똑같이 적용
missRanger: missRanger(X_train, keep_forests = TRUE) → predict(fit, X_test)
mice: 학습 + 테스트 X 를 합치되 ignore = 테스트 행 (테스트 행은 대체 모형 적합에 쓰이지 않음), Y 열은 넣지 않는다

실험 : Y 를 대체에 쓰면 성능이 얼마나 “좋아 보이나”



설정

- Boston, medv 예측 , Random Forest
- rm · lstat · nox · dis 에 MAR(age 의존) 30% 결측
- missRanger, 20 회 반복

② 누수 : 3.54 vs ① 4.52

RMSE 가 22% 좋아 보인다 — 실제로는 얻을 수 없는 성능

③ 도 이득이 없다 (4.58): 학습에서만 Y 로 더 정확하게 채워도 테스트에서는 그 규칙을 쓸 수 없으므로 오히려 조금 나빠진다

BUT THE TEXTBOOK SAYS...

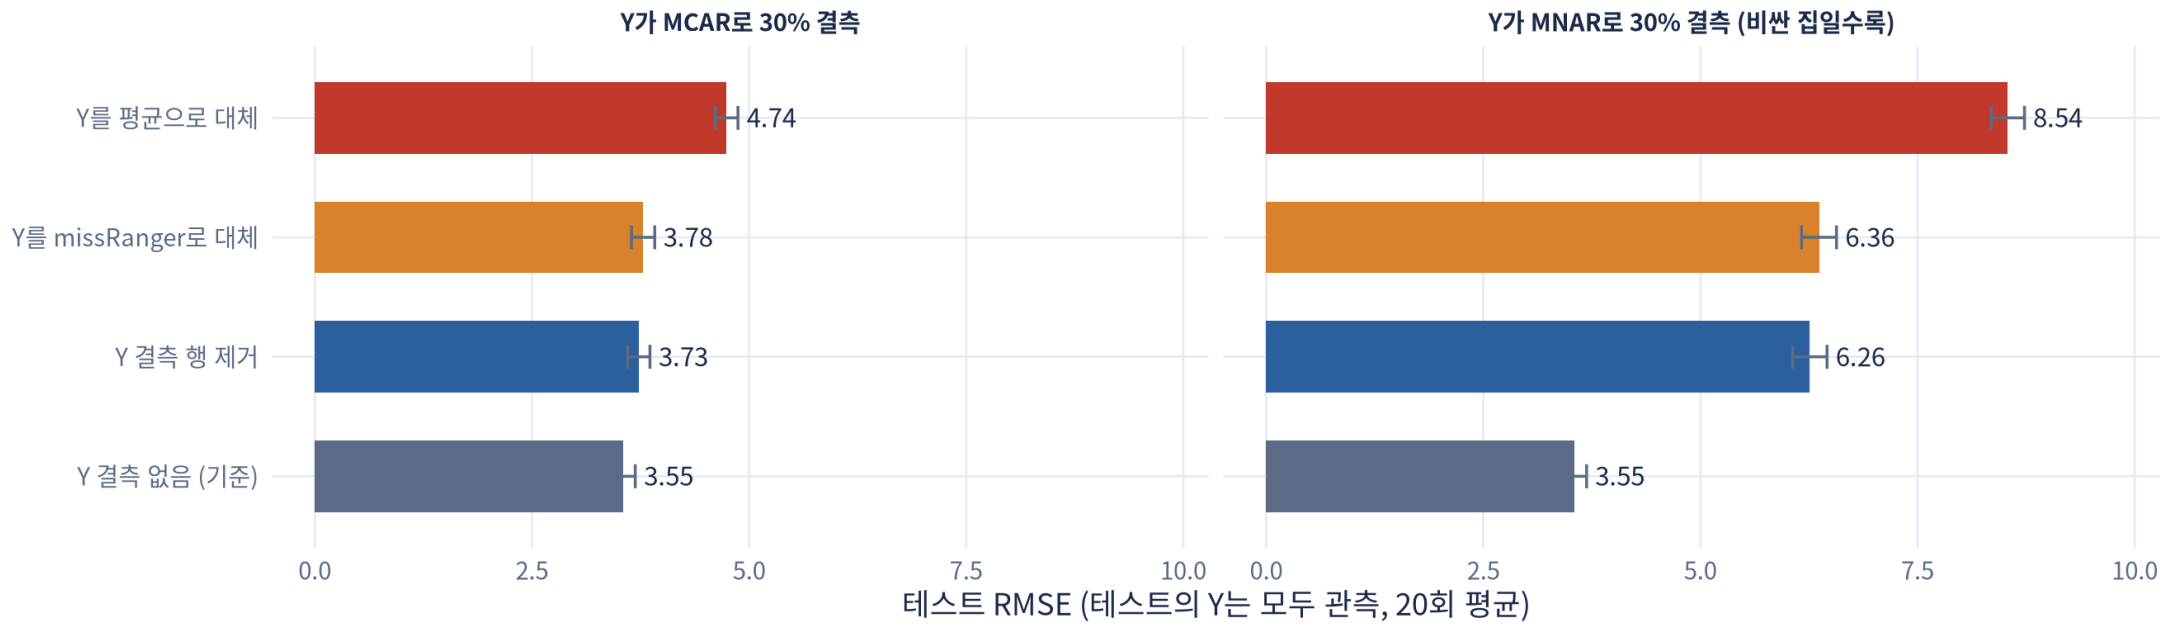
“ 다중 대체에는 Y 를 넣으라” 는 말과의 관계

	추론 · 설명 (회귀계수 , 표준오차)	예측 (배포할 모형)
목적	모집단의 관계를 편향 없이 추정	새 관측치의 Y 를 정확히 예측
대체 모형에 Y	넣는다 . 빼면 X–Y 관계가 0 쪽으로 약해진다 (Moons et al., 2006)	넣지 않는다 . 예측 시점에 Y 가 없다 (Sperrin et al., 2020)
대체 횟수	다중 대체 + Rubin 의 규칙	단일 대체로 충분한 경우가 많음
평가	추정의 편향 · 신뢰구간 포함률	테스트 · CV 성능 , 학습과 같은 규칙 적용

두 말이 모두 맞다 : 목적이 다르기 때문

이 수업처럼 예측 모형을 만드는 것이 목적이면 , 대체는 “배포할 때도 그대로 할 수 있는 절차” 여야 한다 → Y 없이 , 학습 데이터로만

Y 가 결측이면 : 대체보다 훨씬 더 조심해야 한다



MCAR: 그냥 빼면 된다

제거 3.73 ≈ missRanger 로 Y 대체 3.78. X 로 Y 를 채우면 모형이 자기 예측을 다시 배울 뿐 , 새 정보가 없다

평균 대체는 해롭다

4.74 (MCAR), 8.54 (MNAR). 가짜 Y 가 X–Y 관계를 평평하게 만든다

MNAR: 아무것도 못 고친다

비싼 집의 Y 가 빠지면 6.26 ~ 6.36 (기준 3.55). 대체로는 해결 불가 → 데이터 수집 설계의 문제

Y 결측에 대한 원칙

1 학습 : Y 가 없는 행은 지도학습에서 뺀다

X 로 Y 를 채워 학습에 넣는 것은 정보를 늘리지 않고 , 불확실성만 숨긴다

2 평가 : 대체한 Y 로 성능을 재지 않는다

테스트 · 검증 데이터의 Y 는 실제 관측값만 . 대체된 Y 로 재면 성능이 부풀려진다

3 메커니즘을 먼저 묻는다

왜 Y 가 없는가 ? 신용평가의 거절자 (reject inference), 추적 중 이탈한 환자 — 대부분 MNAR

4 다른 도구가 필요할 수 있다

생존분석 (중도절단), 준지도학습 , 선택 편향 모형 (Heckman), 추가 데이터 수집

예외 : 추론 목적의 다중 대체에서는 Y 결측 행도 대체 모형에 쓰일 수 있다 — 그래도 Y 자체를 채워 분석하는 것은 신중히

PART 7

어떤 방법이 좋은가 ?

평가 방법 , 논문 결과 , 그리고 메커니즘에 따라 바뀌는 순위

HOW TO EVALUATE

대체 방법을 평가하는 두 가지 방법

1 대체 정확도

- 완전한 데이터에 일부러 결측을 만들고 (마스킹) 대체값과 참값을 비교
- 수치형 : NRMSE, 범주형 : PFC(틀린 비율)
- Suh & Song (2023) 의 IPM: 수치형 | 참값 – 대체값 | / 범위 , 범주형 0/1 의 평균 (Gower 거리 기반)

2 예측 성능 (downstream)

- 대체 → 예측 모형 → 테스트 · CV 성능
- 실제로 관심 있는 것이 예측이라면 이것이 최종 기준
- 같은 fold, 대체는 fold 안에서 학습 부분으로만

두 기준은 다른 답을 줄 수 있다

가장 정확하게 채우는 방법이 가장 좋은 예측을 주는 것은 아니다 . 예 : 결측 여부가 Y 와 관련된 MNAR 에서는 “정확한 대체” 보다 “결측이었다는 표시” 가 예측에 더 유용 (Part 7 실험)

OUR STUDY

Suh & Song (2023): 머신러닝 기반 대체 방법 비교

Suh, H. & Song, J. (2023). A comparison of imputation methods using machine learning models. Communications for Statistical Applications and Methods, 30(3), 331–341.

설계	내용
방법 5 가지	평균 · 최빈값 , kNN, MICE (PMM), missRanger, mixgb (missForest 는 시간 문제로 missRanger 로 대체)
데이터 6 개 (혼합형)	Milk (n = 1,059), Nwtsco (3,915), Bike (17,379), Adult (30,162), Bank (30,488), WeatherAUS (56,420)
결측 비율	10%, 20%, 30%
결측 메커니즘 I	p 개 중 일부 열 (k < p) 에만 결측 — 결측이 몇몇 변수에 몰림
결측 메커니즘 II	일부 관측치에 결측이 여러 열에 흩어짐 (행마다 1 ~ p/3 개)
평가	IPM (대체 정확도) 과 계산 시간

두 메커니즘 모두 무작위 (MCAR) 로 생성 — 결측이 "어디에, 어떤 모양으로" 생기는지 (패턴) 의 차이를 비교한 연구

결과 : 결측이 생기는 방식에 따라 1 위가 달라졌다

kNN 12 · mixgb 6

메커니즘 I (일부 열에 집중): 18 개 조합 (데이터 6 × 비율 3) 의 1 위

missRanger 14

메커니즘 II (행에 흩어짐): 18 개 조합 중 1 위 횟수

비율은 덜 중요

결측 비율 (10 → 30%) 이 바뀌어도 1 위는 거의 그대로

메커니즘 I → kNN 또는 mixgb

결측이 몇 변수에 몰리면 나머지 변수는 완전 → 이웃을 정확히 찾을 수 있다 . 큰 데이터 (Adult, Bank) 에서는 mixgb

메커니즘 II → missRanger

결측이 행마다 흩어지면 거리 계산에 쓸 공통 변수가 줄어 kNN 이 약해지고 , 변수별 모형을 반복하는 방법이 유리

메시지 : " 항상 최고인 방법" 은 없다 . 결측이 어떻게 생겼는지 (패턴 · 메커니즘) 에 따라 순위가 바뀐다 → 내 데이터에서 직접 비교

EXPERIMENT · SETUP

실험 : MCAR · MAR · MNAR 에서 방법 비교 (대체 정확도 + 예측 성능)

설정

- Boston (n = 506, p = 12), 반응변수 medv
- rm · lstat · nox · dis 네 변수에 각 30% 결측
- MCAR: 무작위 / MAR: age 가 클수록 / MNAR: 자기 값이 클수록
- 70/30 분할 20 회 반복 , 예측 모형은 Random Forest (ranger)

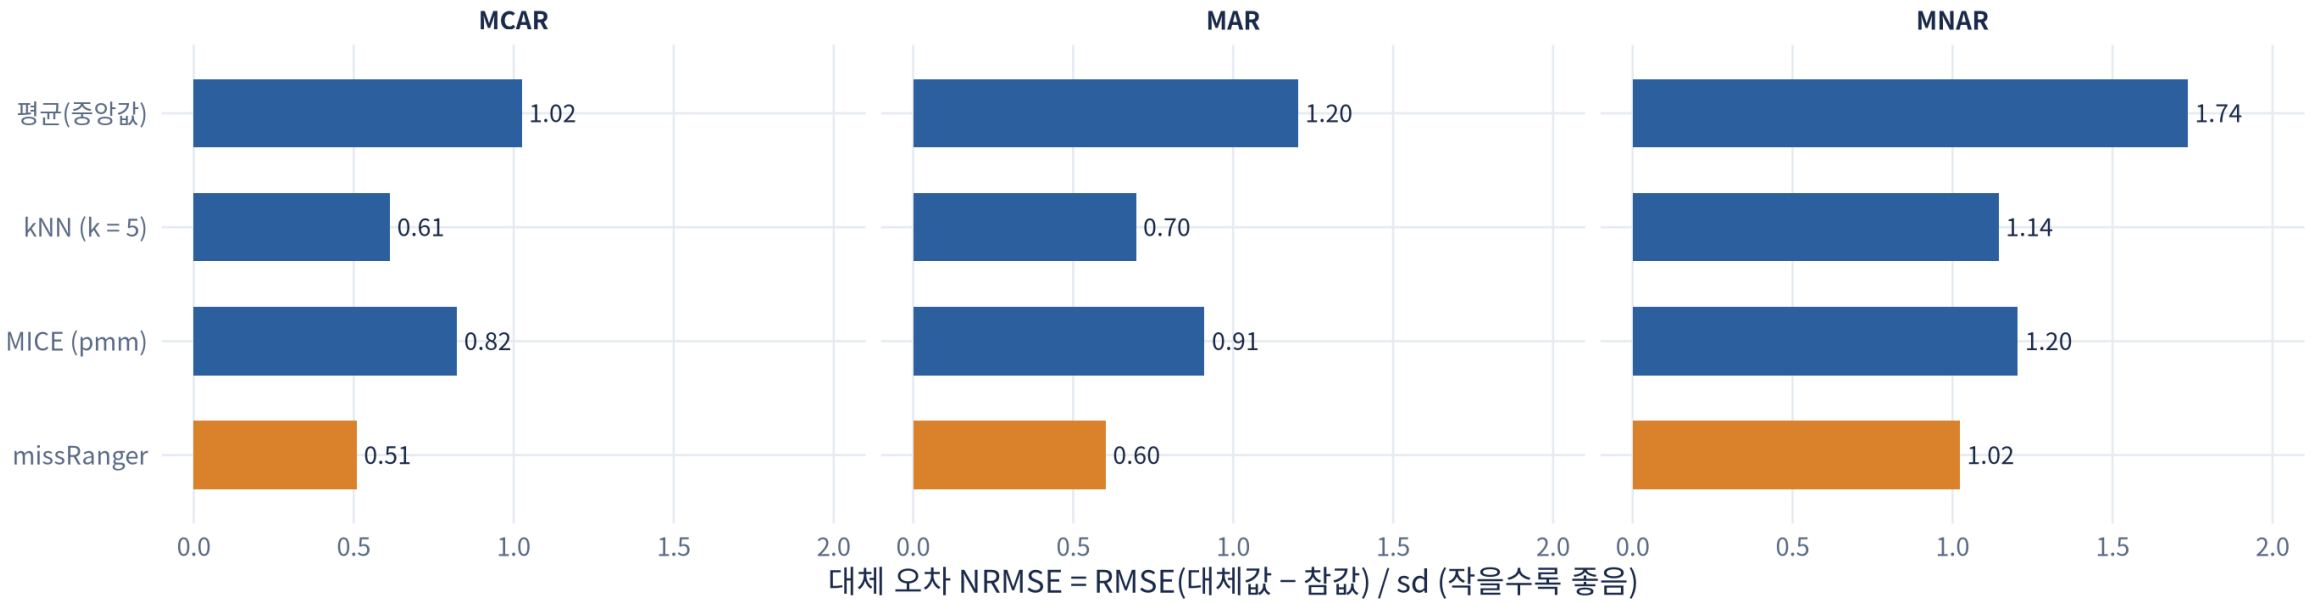
비교한 방법

- 평균 (중앙값), 평균 + 지시변수
- kNN (k = 5, 이웃은 학습 데이터에서)
- missRanger (학습으로 적합 → predict 로 테스트)
- MICE (pmm, m = 1, ignore = 테스트 행)
- XGBoost (대체 없이 NA 그대로)

모든 방법은 Y 없이 , 학습 데이터의 X 로만 대체 규칙을 배웠다
예측 성능은 “결측이 없을 때 대비 테스트 RMSE 증가량”으로 비교 (RF 기준 3.32, XGBoost 기준 3.09). mixgb 는 이 실험 환경에 설치할 수 없어 제외

EXPERIMENT · ACCURACY

결과 ① : 대체 정확도 — missRanger 가 항상 가장 정확



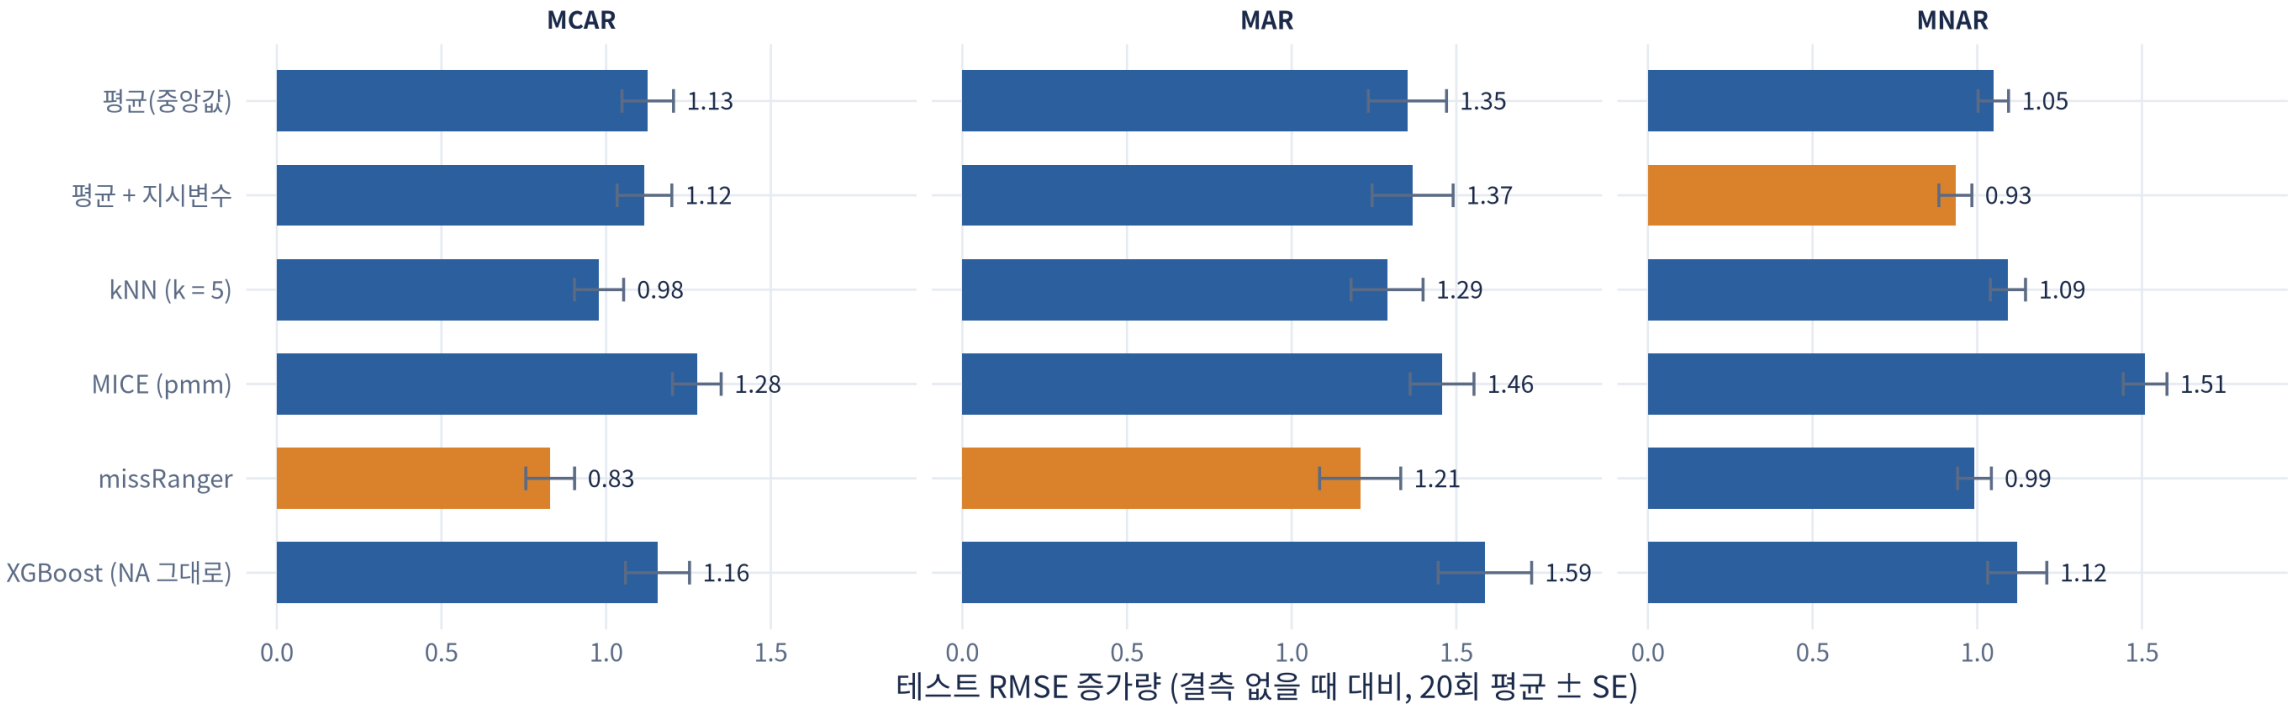
순위는 세 메커니즘에서 같다

missRanger < kNN < MICE(pmm) < 평균 . NRMSE 1 = 평균으로 채운 정도의 오차

MNAR 에서는 모두 크게 나빠진다

missRanger 0.51 (MCAR) → 1.02 (MNAR). 큰 값이 빠지면 관측된 값으로는 큰 값을 상상하지 못한다

결과 ② : 예측 성능 — 메커니즘에 따라 1 위가 바뀐다



	1 위	2 위	꼴찌
MCAR	missRanger (+0.83)	kNN (+0.98)	MICE pmm (+1.28)
MAR	missRanger (+1.21)	kNN (+1.29)	XGBoost NA (+1.59)
MNAR	평균 + 지시변수 (+0.93)	missRanger (+0.99)	MICE pmm (+1.51)

MNAR: 가장 덜 정확하게 채우는 평균 + 지시변수가 예측 1 위 . “ 비어 있었다” 는 사실이 큰 값의 신호이기 때문

LESSONS

실험과 논문에서 얻는 교훈

1 정확한 대체 ≠ 좋은 예측

missRanger 는 대체 정확도에서 항상 1 위였지만 MNAR 의 예측에서는 2 위 . 목적에 맞는 기준으로 평가

2 메커니즘 · 패턴이 순위를 바꾼다

논문 : 결측이 열에 몰리면 kNN, 행에 흩어지면 missRanger. 실험 : MNAR 에서는 지시변수

3 단일 PMM 대체는 예측에 불리

MICE(pmm, m = 1) 는 일부러 무작위성을 넣는 방법 . 다중 대체 · 추론용으로 쓰는 것이 맞다

4 모형이 직접 처리도 하나의 선택

XGBoost 의 NA 처리는 6 개 방법 중 MCAR 5 위 , MAR 6 위 , MNAR 5 위 . 편하지만 자동으로 최선은 아니다

결론 : 후보 2~3 개를 같은 CV fold 안에서 비교하고 , 결측 지시변수를 넣은 버전도 함께 시험한다

PART 8

실무 정리

R 코드와 체크리스트

R: 학습 데이터로 배우고 테스트에 적용하기

R CONSOLE

```
library(missRanger)
Xtr <- train[, x.vars];  Xte <- test[, x.vars]   # Y 제외!

# missRanger: 학습 X로 적합 -> 테스트에 predict
fit <- missRanger(Xtr, num.trees = 100, pmm.k = 0,
                  keep_forests = TRUE, seed = 1)
Xtr.imp <- fit$data
Xte.imp <- predict(fit, Xte)

# missForest: 한 데이터 안에서만 대체 (predict 없음)
library(missForest)
mf <- missForest(Xtr)
Xtr.mf <- mf$ximp;  mf$OOBerror   # 추정된 대체 오차
```

R CONSOLE

```
library(mice)
# 테스트 행은 대체 모형 적합에서 제외
all <- rbind(Xtr, Xte)
ig  <- c(rep(FALSE, nrow(Xtr)),
         rep(TRUE,  nrow(Xte)))
imp <- mice(all, m = 5, method = "pmm",
            ignore = ig, seed = 1)

# 추론: 각 데이터로 회귀 -> Rubin 결합
fits <- with(imp, lm(y ~ x1 + x2))  # 추론용
summary(pool(fits))
```

추론용 mice 예에서는 Y(여기서는 y)를 데이터에 포함해 대체하는 것이 원칙이다. 예측용 대체에서는 Y를 넣지 않는다

CHECKLIST

결측 처리 체크리스트

왜 빠졌나 ?

MCAR · MAR · MNAR 를 분야 지식으로 생각 , 결측 여부와 다른 변수 · Y 의 관계 확인

얼마나 , 어디에 ?

열별 · 행별 비율 , 함께 빠지는 패턴

버릴 것

완전한 행만 쓸지 , 거의 빈 열 · 행을 뺄지 — 테스트에서는 뺄 수 없음을 기억

결측 지시변수

결측 여부가 Y 와 관련되면 남긴다

대체 방법

기준선 (중앙값) + kNN · missRanger 등 후보를 CV 로 비교

Y 는 쓰지 않는다

예측 모형의 대체 규칙 = f(X), 학습 데이터에서만

Y 가 결측이면

지도학습에서는 뺀다 , 평가에 대체한 Y 를 쓰지 않는다 , 메커니즘을 묻는다

기록하기

어떤 규칙으로 무엇을 몇 개 채웠는지 — 배포할 때 똑같이 재현

SUMMARY

오늘의 핵심 정리

1	메커니즘	MCAR 이면 지워도 편향 없음 , MAR 은 관련 변수로 대체하면 회복 , MNAR 은 데이터만으로 해결 불가
2	버리기	완전한 행만 쓰기는 MCAR · 소량일 때만 . 거의 빈 열 · 행은 빼되 지시변수는 고려 , 테스트에서는 뺄 수 없다
3	채우기	중앙값 (기준선) → kNN → missForest · missRanger · mixgb. 추론이면 MICE 다중 대체
4	Y	예측 모형의 대체에는 Y 를 쓰지 않는다 . Y 결측은 대체하지 말고 빼고 , 메커니즘을 의심
5	평가	대체 정확도와 예측 성능은 다를 수 있다 . 결측의 패턴 · 메커니즘에 따라 순위가 바뀐다 → 내 데이터에서 CV 로

참고 : Rubin (1976) · Troyanskaya et al. (2001) · van Buuren & Groothuis-Oudshoorn (2011) · Stekhoven & Bühlmann (2012) · Suh & Song (2023) · Sperrin et al. (2020)