CHAPTER · MODEL INTERPRETATION

적합한 모형을 읽는 도구 VIP · PDP, 그리고 ICE · ALE · SHAP

모형 적합이 끝난 뒤의 질문 : 어떤 변수가 중요한가 (VIP)? 그 변수가 예측을 어떻게 바꾸나 (PDP)? 이 관측치는 왜 이렇게 예측되었나 (SHAP)?

Bagging · Boosting 다음 시간 · R 패키지 : vip · pdp · iml · shapviz · DALEX · 실습 : Bike Sharing 데이터 (ISLR2)

OVERVIEW

학습 목표

1 해석 도구의 지도

전역 (global) · 국소 (local), 중요도 · 효과 · 상호작용으로 도구들을 분류하고 , 해석과 인과의 차이를 구분한다 .

2 VIP: 변수 중요도

불순도 기반과 순열 기반 중요도의 계산 원리 , 각각의 편향과 상관된 변수에서의 주의점을 설명할 수 있다 .

3 PDP 와 그 확장

PDP 의 정의와 계산 과정을 이해하고 , ICE · ALE · H- 통계량으로 PDP 의 약점 (이질성 , 외삽) 을 보완한다 .

4 SHAP 과 실제 분석

Shapley 값으로 관측치 하나의 예측을 분해하고 , Bike Sharing 데이터에서 전체 해석 과정을 R 로 수행한다 .

WHY

적합이 끝난 다음에 남는 세 가지 질문

Random Forest · XGBoost 는 트리 수백 개의 합 → 트리 그림 한 장이나 계수표로 읽을 수 없다 . 대신 "예측함수 $\hat{f}(x)$" 를 직접 들여다보는 도구를 쓴다 .

어떤 변수가 중요한가 ?

VIP

Variable Importance Plot

변수를 망가뜨리면 (섞으면) 예측이 얼마나 나빠지나

그 변수가 예측을 어떻게 바꾸나 ?

PDP

Partial Dependence Plot

x_j 를 바꿔 가며 평균 예측값이 어떻게 움직이나

이 관측치는 왜 이렇게 예측됐나 ?

SHAP

SHapley Additive exPlanations

예측값 – 평균 예측을 변수별 기여로 나눈다

선형회귀와 비교하면 : $|t\text{ 값}|$ 의 크기 ≈ VIP, 직선 $\beta_j\hat{x}_j$ ≈ PDP. 비선형 모형에서는 "계수" 대신 이 그림들이 같은 역할을 한다 .

THE MAP

해석 도구의 지도 : 무엇을 , 어느 범위에서 설명하나

질문	전역 (모형 전체 , 모든 관측치)	국소 (관측치 하나)
어떤 변수가 중요한가 ?	순열 중요도 (VIP) · 불순도 중요도 · mean|SHAP|	SHAP 값의 크기
x_j 가 예측을 어떻게 바꾸나 ?	PDP · ALE · SHAP dependence plot	ICE 곡선 (관측치 하나의 곡선)
상호작용이 있나 ?	2 차원 PDP · H- 통계량 · ICE 의 퍼짐	—
이 예측은 왜 나왔나 ?	—	SHAP · Break-down · LIME

모형 무관 (model-agnostic)

예측함수 $\hat{f}$ 만 있으면 된다 : $\hat{f}$ 에 데이터를 넣고 나온 예측값만 사용 . RF · 부스팅 · SVM · 신경망 모두 같은 방법으로 해석 가능

모형 전용 (model-specific)

모형 내부 구조를 사용 : 트리의 불순도 감소 , 선형모형의 계수 , TreeSHAP 등 . 빠르지만 그 모형에서만 쓸 수 있다

BEFORE WE START

해석하기 전에 기억할 세 가지

1 모형이 좋아야 해석도 의미 있다

해석 도구는 “모형이 학습한 것”을 보여 준다. 테스트 성능이 나쁜 모형의 PDP는 잘못된 패턴을 그럴듯하게 보여 줄 뿐 → 먼저 성능(CV, 테스트 오차)을 확인

2 해석 ≠ 인과

PDP가 올라간다 = “모형의 예측이” 올라간다. x_j를 실제로 바꾸면 y가 바뀐다는 뜻은 아니다. 교란변수 · 누수 변수가 있으면 그림도 그대로 따라간다

3 상관된 변수는 늘 조심

설명변수끼리 강하게 상관되어 있으면 중요도가 나뉘고, PDP는 현실에 없는 조합에서 예측을 계산한다(외삽). → ALE, 변수 묶기, 하나 제거 등으로 확인

원칙 : 성능 확인 → 전역 해석 (VIP, PDP) → 이질성 · 상호작용 확인 (ICE, H) → 개별 예측 설명 (SHAP) 순서로

PART 1

VIP: 변수 중요도

어떤 변수가 예측에 가장 많이 쓰이는가 — 두 가지 계산 방법과 그 함정

복습 : 불순도 기반 중요도 (모형 전용)

$$\mathrm{Imp}(X_j) = (1/B)\ \Sigma_b\ \ \Sigma_{X_j 로 분할한 노드\ t}\ \ \Delta\mathrm{RSS}(t) \qquad (\text{분류 : Gini 감소})$$

계산

- 트리를 만들 때 각 분할이 줄인 RSS(지니) 를 기록
- 그 분할에 쓰인 변수에 공을 돌린다
- B 개 트리에 대해 합산 → 평균
- R: importance(rf) 의 IncNodePurity, xgb.importance() 의 Gain

장점과 한계

- 추가 계산 없음 : 적합하면서 바로 얻는다
- 학습 데이터 기준 → 과대적합된 분할도 중요하다고 셈
- 값의 종류가 많은 변수 (연속형 , 수준 많은 범주) 를 과대평가
- 트리 모형에서만 쓸 수 있다

왜 편향되나 ? 분할점 후보가 많을수록 순전히 우연으로 RSS 를 줄이는 분할을 찾을 기회가 많다 . 잡음 변수라도 값이 다양하면 “쓸모 있어 보인다” .

순열 중요도 : 변수 하나를 “섞어서 망가뜨려” 본다

원래 데이터 → 오차 L_o

hr	temp	hum	y
8	22	60	410
13	31	45	190
3	12	88	6
17	25	52	520

→

hr 열만 무작위로 섞기 → 오차 L_1

hr	temp	hum	y
17	22	60	410
3	31	45	190
8	12	88	6
13	25	52	520

y 와 다른 변수는 그대로 → hr 과 y 의 연결만 끊긴다

$VI_{hr} = L_1 - L_o$
크게 나빠질수록 중요한 변수

1 적합한 모형 $\hat{f}$ 로 평가
데이터의 오차 L_o 계산

RMSE, 오분류율 , 1−AUC 등

2 변수 x_j 의 열만 무작위로 섞는다 (순열)

모형은 다시 적합하지 않는다

3 섞은 데이터로 오차 L_1 계산 , 차이 $L_1 - L_o$

비율 L_1/L_o 를 쓰기도 함

4 M 번 반복해 평균 , 모든 j 에 대해

j = 1, …, p. 섞는 무작위성 때문에 반복

$VI_j = (1/M)\,\Sigma_m\,[\,L(y, \hat{f}(X^{\pi_m, j})) - L(y, \hat{f}(X))\,]$ · $X^{\pi_m, j}$: m 번째로 j 열만 섞은 데이터 · Breiman (2001), Fisher et al. (2019)

순열 중요도를 쓸 때 정해야 할 것들

1 어떤 데이터에서 섞나 ?

테스트 (또는 OOB) 데이터 권장 . 학습 데이터에서 섞으면 모형이 외워 둔 잡음 변수도 중요해 보인다 . randomForest 의 %IncMSE 는 OOB 기준

2 몇 번 섞나 ?

한 번 섞은 결과는 우연에 좌우된다 → M = 5~20 회 반복해 평균과 분포 (상자그림) 를 함께 본다 . 막대 끝이 겹치면 순위 차이는 의미 없음

3 어떤 지표로 ?

회귀 : RMSE · MAE, 분류 : 정확도 · AUC · 로그손실 . 지표가 바뀌면 순위도 바뀔 수 있다 → 분석 목적에 맞는 지표 사용

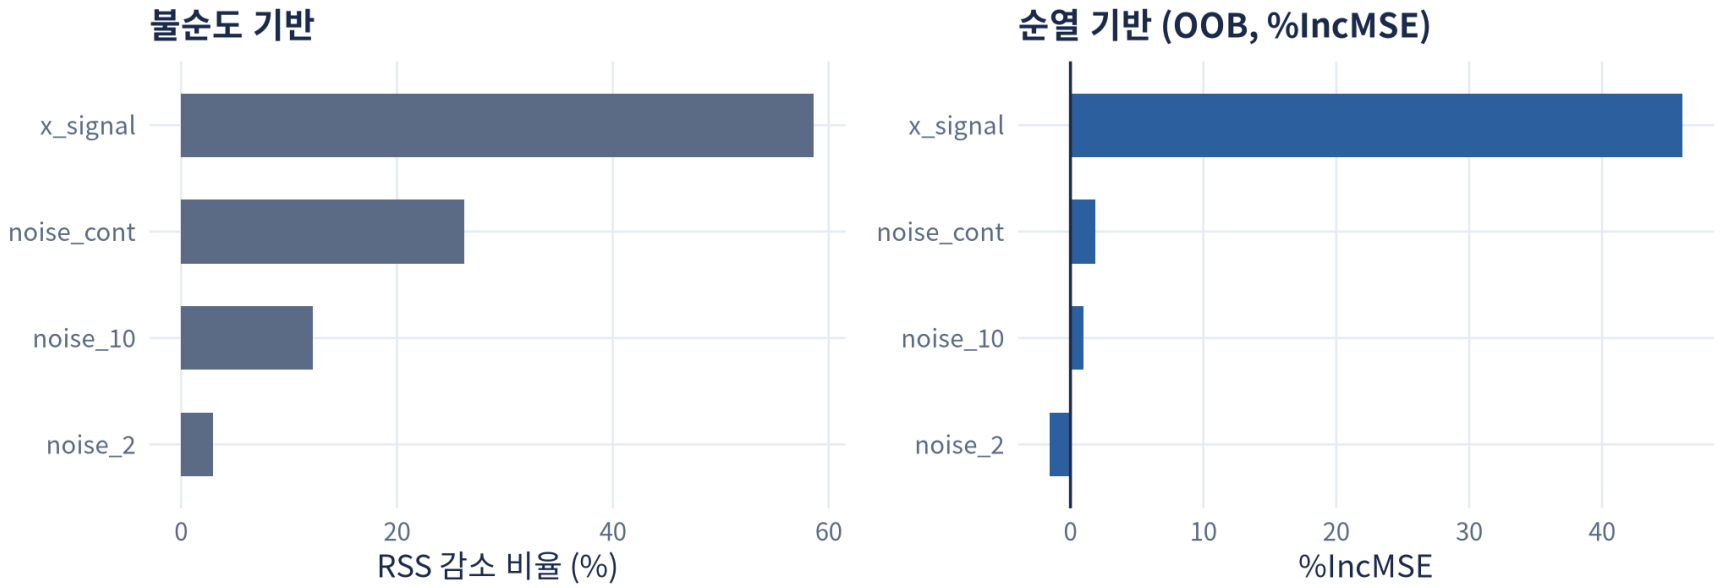
4 음수가 나오면 ?

섞었더니 오히려 좋아짐 = 그 변수는 도움이 안 되거나 잡음에 과대적합 . 0 근처는 “중요하지 않음”으로 읽는다

장점 : 모형 무관 · 해석이 쉬움 (“ 이 변수 없으면 RMSE 가 이만큼 나빠진다”) · 재적합 불필요 → 실무에서 VIP 의 기본값

SIMULATION ①

불순도 중요도의 편향 : 잡음 변수도 값이 많으면 중요해 보인다



설정 (n = 500)

- y = x_signal + ε (x_signal: 0/1)
- noise_2: 0/1, noise_10: 1~10, noise_cont: 연속형
- 잡음 3 개는 모두 y 와 무관
- randomForest 500 trees

불순도 : noise_cont 가 전체 RSS 감소의 26% 를 차지 (값 500 종류 → 우연히 좋은 분할점을 찾음)
순열 (OOB): x_signal 46.0, 잡음 변수는 − 1.6 ~ 1.8 로 0 근처 → 순열 중요도는 이 편향이 거의 없다

PITFALL

상관된 변수 : 중요도가 “나뉘고” , 섞으면 비현실적인 데이터가 생긴다

1 중요도가 나뉜다

두 변수가 거의 같은 정보를 가지면 트리는 둘을 번갈아 쓴다 . 하나를 섞어도 다른 하나가 대신하므로 각자의 중요도는 작게 나온다 → “둘 다 별로 중요하지 않다”로 잘못 읽기 쉽다

2 현실에 없는 점에서 평가

기온과 체감온도처럼 상관이 0.99 인 두 변수에서 기온만 섞으면 “기온 3°C, 체감온도 35°C” 같은 관측치가 생긴다 . 모형은 그런 데이터를 본 적이 없다 → 외삽

대처 방법

변수 묶어서 섞기

상관된 변수들을 한 묶음으로 동시에 섞어 “묶음의 중요도”를 본다 (vip: 직접 구현 , DALEX: variable_groups)

하나 빼고 다시 적합

drop-column 중요도 : 변수를 빼고 재적합한 성능 차이 . 정확하지만 재적합 비용

상관 구조를 함께 보고 해석

중요도 표만 보지 말고 상관행렬 · 산점도를 같이 본다 . 실습 (뒤) 에서 temp/atemp 로 확인

R 실습 : vip 패키지로 변수 중요도 계산하기

R CONSOLE

```
library(randomForest); library(vip)
rf.fit <- randomForest(bikers ~ ., data = train,
                       mtry = 4, importance = TRUE)

# (1) 모형 전용 : 불순도 기반
importance(rf.fit)            # %IncMSE, IncNodePurity
vip(rf.fit, type = 2)         # IncNodePurity 막대

# (2) 모형 무관 : 테스트 데이터에서 순열 중요도
pfun <- function(object, newdata)
          predict(object, newdata = newdata)
vi.perm <- vi(rf.fit, method = "permute",
              train = test, target = "bikers",
              metric = "rmse", pred_wrapper = pfun,
              nsim = 10, keep = TRUE)
vip(vi.perm, geom = "boxplot")  # 10 번 반복의 분포
```

method

"permute" (순열) · "model" (모형 전용) · "shap" · "firm" (PDP 기반)

train / target

섞을 데이터와 반응변수 . 테스트 데이터를 넣는다

metric

"rmse", "mae", "accuracy", "roc_auc" 등

pred_wrapper

새 데이터 → 예측값 벡터 . 분류는 확률 반환

nsim, keep

반복 횟수 , 반복별 결과 보관 (상자그림용)

PART 2

PDP: 부분 의존도

x_j 를 바꿔 가면 평균 예측은 어떻게 움직이는가 — 정의 , 계산 , 읽는 법 , 약점

PDP: 다른 변수의 영향을 "평균으로 지운" x_j 의 효과

$$PD_j(z) = E_{X_C}[\, f(z, X_C)\,] \approx (1/n)\, \Sigma_{i=1}^{n}\, f(z, x_C^{(i)})$$

j: 관심 변수 (보통 1~2 개), C: 나머지 변수 전체 , z: x_j 에 넣어 볼 값 , $x_C^{(i)}$: i 번째 관측치의 나머지 변수 값

1 $x_j = z$ 로 고정

모든 관측치의 x_j 를 z 로 바꾸고 나머지 변수는 그대로 둔다

2 예측해서 평균

n 개 예측값의 평균 = "x_j 가 z 일 때 모형의 평균 예측"

3 z 를 바꿔 가며 반복

격자 $z_1 < z_2 < \ldots < z_G$ 마다 반복해 선으로 잇는다 → PDP

직관 : " 다른 조건은 데이터에 있는 그대로 두고 , 모든 시간을 오전 8 시로 바꾸면 평균 대여량은 ?" — 이 질문을 z 마다 반복

계산 과정 따라가기 : 관측치 4 개 , temp 의 PDP

원래 데이터

temp	hr	hum
8	8	60
15	13	45
22	17	52
31	3	88

temp 를 모두 10 로

temp	hr	hum	$\hat{f}$
10	8	60	**210**
10	13	45	**150**
10	17	52	**260**
10	3	88	**20**

평균 → **PD(10) = 160**

temp 를 모두 30 로

temp	hr	hum	$\hat{f}$
30	8	60	**250**
30	13	45	**190**
30	17	52	**300**
30	3	88	**30**

평균 → **PD(30) = 192.5**

계산량

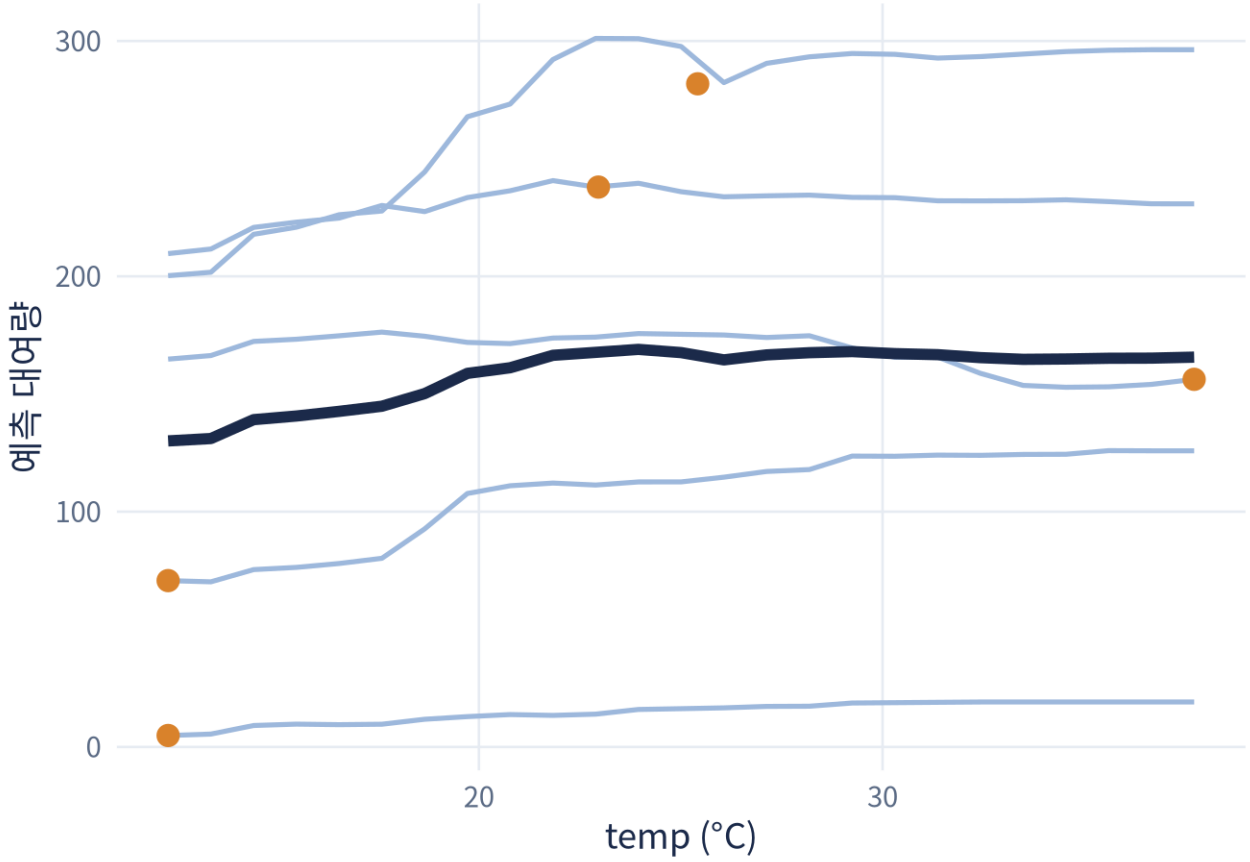
- 격자 G 개 × 관측치 n 개 = n·G 번 예측 (예 : n = 6,000, G = 50 → 30 만 번)
- 데이터가 크면 관측치 일부를 표본추출하거나 격자를 줄인다 (pdp: grid.resolution, 병렬 parallel = TRUE)

결과

PDP 위의 점 (10, 160), (30, 192.5) … temp 가 10 → 30°C 이면 평균 예측이 32.5 증가

예측값 $\hat{f}$ 은 설명을 위한 가상의 값

PDP = 관측치별 곡선 (ICE) 의 평균



Bike Sharing 데이터의 Random Forest, 학습 데이터에서 무작위로 고른 5 개 관측치

● 주황 점

실제 관측치 5 개의 (temp, 예측값)

— 연한 선 (ICE)

관측치 하나의 다른 변수는 그대로 , temp 만 바꿔 가며 예측한 곡선

— 진한 선 (PDP)

5 개 곡선을 세로로 평균한 것 . 실제로는 n 개 모두 평균

PDP 가 정확히 무엇을 추정하나 : 가법 모형이면 그 성분 그대로

$$f(x) = \beta_0 + \Sigma_j \beta_j x_j \;\Rightarrow\; PD_j(z) = \beta_j z + \text{상수}$$

선형회귀 : PDP = 기울기 β_j 인 직선 (계수의 일반화)

$$f(x) = g_j(x_j) + h(x_C) \;\Rightarrow\; PD_j(z) = g_j(z) + \text{상수}$$

가법 구조 : PDP 가 x_j 의 성분 g_j 를 정확히 복원

상호작용이 있으면 ? 예 : $f(x) = x_1 \cdot x_2$

$PD_1(z) = (1/n) \Sigma\, z \cdot x_2^{(i)} = z \cdot \bar{x_2}$. x_2 가 큰 관측치에서는 x_1 의 효과가 크고 작은 관측치에서는 작은데 , PDP 는 그 "평균 기울기" 하나만 보여준다 → 상호작용은 PDP 한 장으로 보이지 않는다 (ICE, 2D PDP 필요)

정리 : PDP 는 " x_j 를 바꿨을 때 예측의 평균적인 변화" 이다 .
가법적이면 정확한 효과 , 상호작용이 있으면 평균된 효과 , 변수끼리 상관이 강하면 외삽된 효과 — 세 번째가 가장 위험하다

PDP 읽는 법과 분류 문제에서의 PDP

1 y 축 = 평균 예측값

개별 관측치의 예측이 아니다 . 높낮이 (절대값) 보다 모양 · 변화폭을 본다 . 변화폭이 크면 그 변수의 영향이 크다

2 데이터가 있는 곳만 믿는다

x 축에 rug(관측값 표시) 나 십분위수를 함께 그린다 . 데이터가 드문 양 끝에서의 꺾임은 대부분 모형의 외삽

3 평평하다 ≠ 효과 없음

평균하면 상쇄되는 상호작용이 숨어 있을 수 있다 → ICE 로 확인 (뒤의 시뮬레이션)

4 분류 문제

$\hat{f}$ 대신 $\hat{P}(Y = k \mid x)$ 또는 logit 을 평균 . pdp::partial(prob = TRUE, which.class = "yes"). 로짓 척도면 가법 효과가 더 잘 보인다

2 차원 PDP: $PD_{jk}(z_1, z_2)$ 를 격자에서 계산해 선 (범주 × 연속) 또는 등고선 / 히트맵 (연속 × 연속) 으로 → 상호작용을 눈으로 확인

R 실습 : pdp 패키지의 partial()

R CONSOLE

```
library(pdp)
# 1 차원 PDP
pd.hr <- partial(rf.fit, pred.var = "hr",
                 train = train, grid.resolution = 24)
plot(pd.hr)
plot(partial(rf.fit, pred.var = "temp", train = train),
     rug = TRUE, train = train)       # rug: 데이터 위치

# 2 차원 PDP (범주 x 연속, 연속 x 연속)
pd.hr.wd <- partial(rf.fit, pred.var = c("hr","workingday"),
                    train = train, grid.resolution = 24)
pd.th    <- partial(rf.fit, pred.var = c("temp","hum"),
                    train = train, grid.resolution = 20)
plot(pd.th, contour = TRUE)

# 분류: 확률 척도의 PDP
partial(fit, pred.var = "x", prob = TRUE,
        which.class = "yes", train = train)
```

pred.var

관심 변수 (1 개 또는 2 개)

train

평균을 낼 데이터 (보통 학습 데이터)

grid.resolution

격자 개수 G (계산량 ∝ n·G)

ice / center

TRUE 면 ICE · centered ICE (다음 파트)

pred.fun

사용자 예측함수 (xgboost 등)

PART 3

PDP 너머 : ICE · ALE · H-통계량

평균이 숨기는 이질성 , 상관된 변수의 외삽 , 상호작용의 크기

ICE: 평균하기 전의 곡선을 모두 그린다

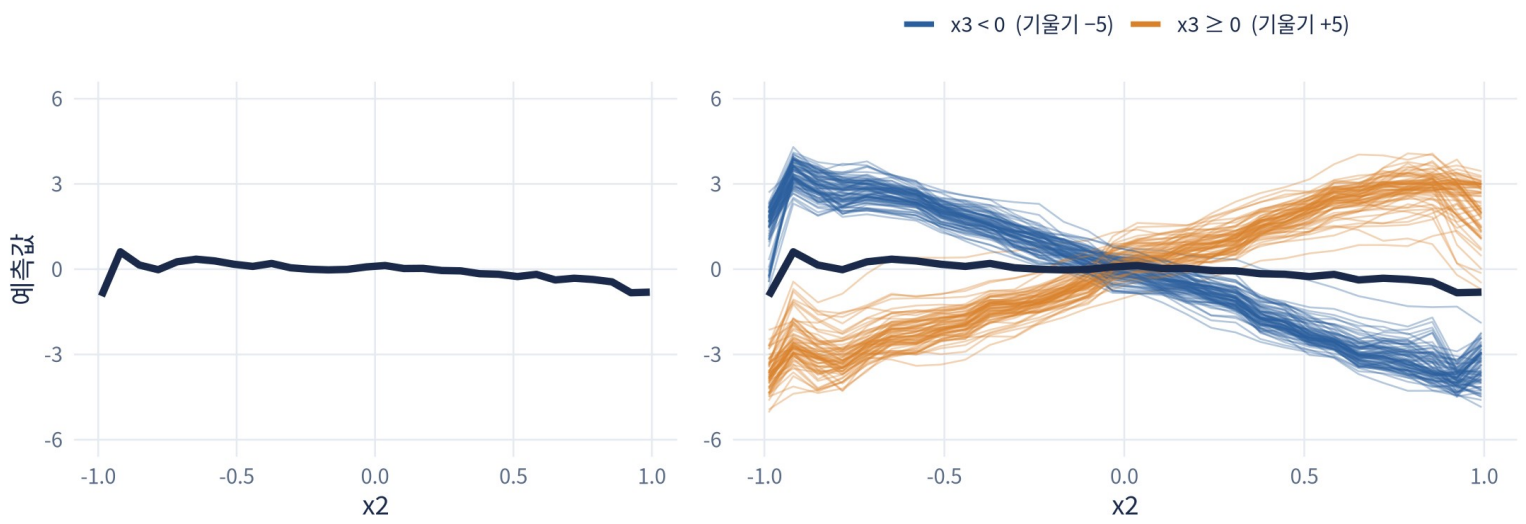
$$\text{ICE: } f^{(i)}_j(z) = f(z, x_C^{(i)}),\ i = 1, \ldots, n \qquad \text{PDP} = (1/n)\ \Sigma_i\ f^{(i)}_j(z)$$

PDP만 보면

x2는 효과가 없어 보인다

ICE를 그려 보면

x3에 따라 정반대 방향 → 상호작용



시뮬레이션

- $y = 0.2x_1 - 5x_2 + 10x_2 \cdot I(x_3 \geq 0) + \varepsilon$
- $x_3 \geq 0$ 이면 x_2 의 기울기 +5, $x_3 < 0$ 이면 −5
- 평균하면 0 → PDP 는 평평
- ICE 는 두 갈래 → x_2 와 x_3 의 상호작용

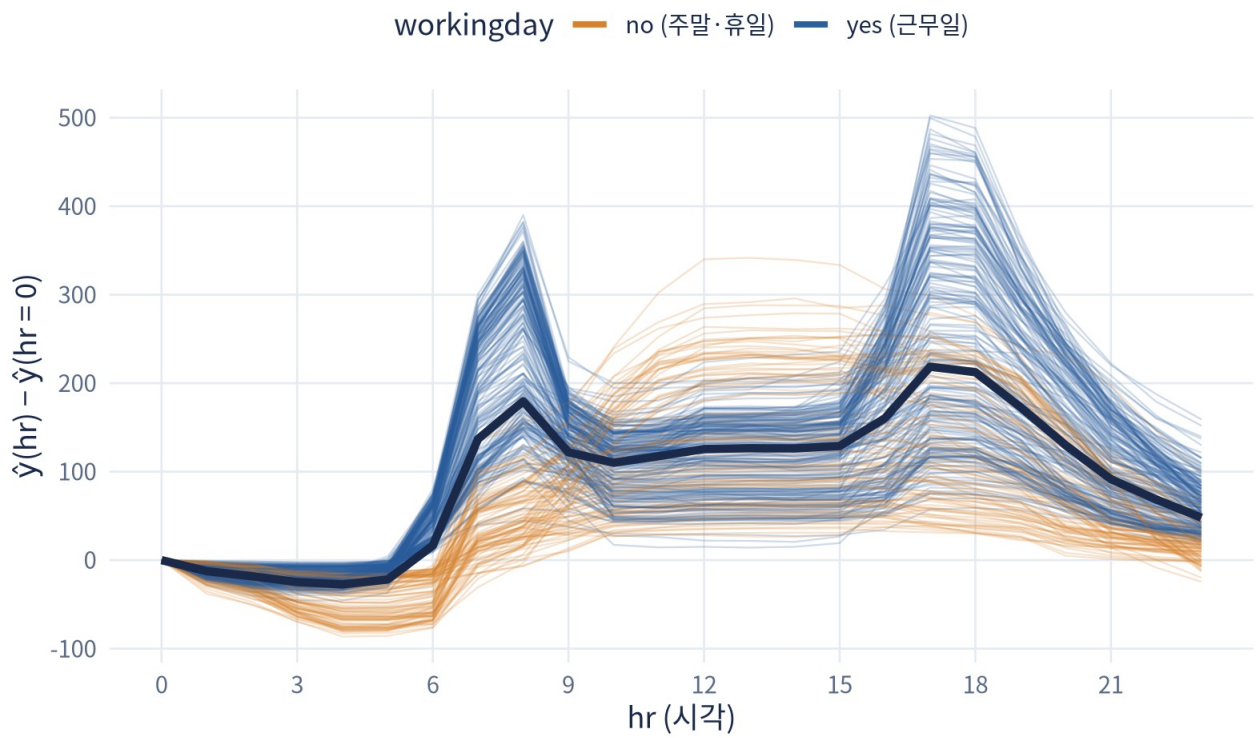
Goldstein et al. (2015) 의 예 . Random Forest (n = 1,000), ICE 는 150 개 관측치

곡선들이 평행하면 상호작용 없음 · 서로 엇갈리거나 갈래가 생기면 상호작용

CENTERED ICE

c-ICE: 출발점을 맞추면 “모양의 차이”만 남는다

c-ICE: $f^{(i)}_j(z) - f^{(i)}_j(z_min)$ (모든 곡선이 0 에서 출발)



Bike Sharing 데이터의 hr c-ICE (Part 5 에서 자세히). 근무일 (파랑) 과 주말 · 휴일 (주황) 이 다른 모양

1 왜 필요한가

ICE 는 높이가 제각각이라 모양 비교가 어렵다

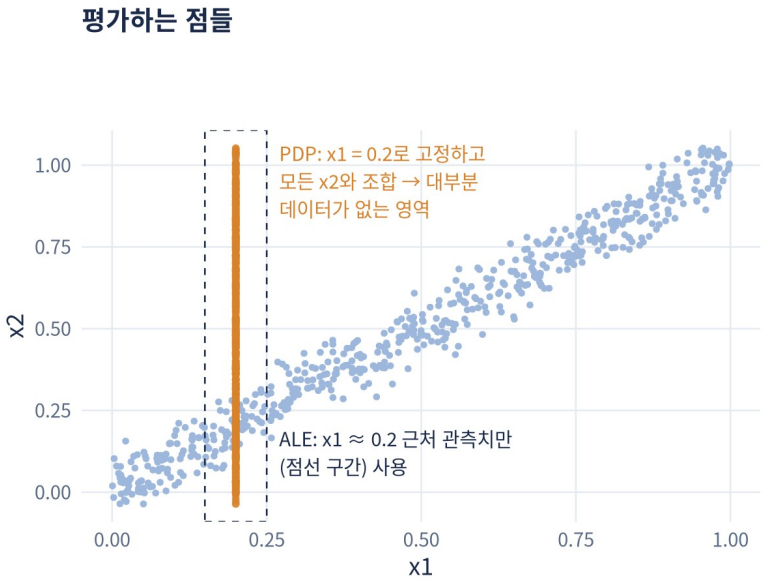
2 읽는 법

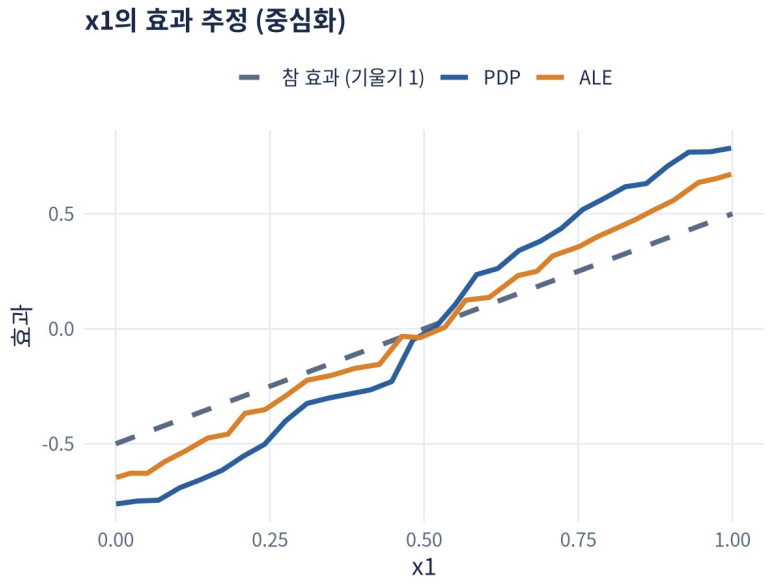
한 묶음 → 가법적 , 여러 갈래 → 상호작용

실무 팁

곡선 100~500 개 , 의심 변수로 색칠 (왼쪽 : workingday)

ALE: 상관된 변수에서 PDP 의 외삽을 피하는 방법





시뮬레이션

- $x_2 = x_1 +$ 잡음 , 상관 0.987
- $y = x_1 + 3x_2 + \varepsilon \rightarrow x_1$ 의 참 기울기 1
- RF 적합 후 추정 기울기 : PDP 1.76, ALE 1.37
- PDP 는 x_2 의 효과를 x_1 에 섞어 넣는다

$$\mathrm{ALE}_j(z) = \Sigma_\{k:\ z_k \le z\}\ (1/n_k)\ \Sigma_\{i \in \text{구간}\ k\}\ [\ f(z_k,\ x_C^{(i)}) - f(z_\{k-1\},\ x_C^{(i)})\ ]\ -\ \text{상수}$$

아이디어 : x_j 를 작은 구간으로 나누고 , 각 구간 안에 실제로 있는 관측치만 구간의 양 끝으로 조금씩 움직여 예측 “변화량” 을 구한 뒤 누적한다 . 데이터가 있는 곳 근처에서만 예측하므로 외삽이 적다 . 다만 상관이 매우 강하면 ALE 도 완전하지 않다 (1.37 ≠ 1)

PDP 와 ALE 비교

	PDP	ALE
평가하는 점	$x_j = z$ 와 모든 관측치의 x_C 조합 (현실에 없는 조합 포함)	구간 k 안의 관측치를 구간 경계로만 이동 (데이터 근처)
무엇을 평균하나	예측값 $\hat{f}$ 자체	예측값의 차이 (국소 효과) 를 평균 후 누적
상관이 강할 때	외삽 때문에 다른 변수 효과가 섞일 수 있음	더 안정적 (그래도 완벽하지는 않음)
y 축 해석	평균 예측값 (단위 그대로)	평균 대비 효과 (0 중심)
계산량	$n \cdot G$ 번 예측	약 $2n$ 번 예측 (훨씬 빠름)
범주형 변수	자연스럽다	범주 순서가 필요 (iml 은 유사도로 정렬)
R	pdp::partial(), iml (method = "pdp")	iml::FeatureEffect(method = "ale"), ALEPlot

권장 : PDP 와 ALE 를 함께 그려 보고 , 둘이 다르면 그 변수와 상관된 변수를 의심한다

Friedman 의 H- 통계량 : 상호작용의 크기를 숫자로

$$H^2_{jk} = \Sigma_i \left[PD_{jk}(x_j^{(i)}, x_k^{(i)}) - PD_j(x_j^{(i)}) - PD_k(x_k^{(i)}) \right]^2 \;/\; \Sigma_i \, PD_{jk}(x_j^{(i)}, x_k^{(i)})^2$$

PDP 들은 모두 평균 0 으로 중심화 . 분자 = 2 차원 PDP 중 1 차원 PDP 두 개의 합으로 설명되지 않는 부분

1 2 변수 H_{jk}

x_j 와 x_k 사이 상호작용이 2 차원 PDP 변동에서 차지하는 비율 . 0 이면 가법적 , 1 이면 전부 상호작용

2 전체 H_j

x_j 와 나머지 모든 변수 사이의 상호작용 크기 : $\hat{f} - PD_j - PD_\{-j\}$ 의 변동 비율 . 먼저 H_j 로 후보를 찾고 H_{jk} 로 짝을 찾는다

3 주의

계산량이 n^2 에 비례 → 관측치 수백 개를 표본추출 . 표본에 따라 값이 흔들리고 , 상관된 변수에서는 PDP 처럼 외삽 문제

R · iml

```
pred <- Predictor$new(rf.fit, data = X[sample(nrow(X), 400), ])
Interaction$new(pred);  Interaction$new(pred, feature = "hr")     # 전체 H, hr 과의 2 변수 H
```

PART 4

SHAP: 예측 하나를 변수별로 나누기

게임 이론의 Shapley 값 — 국소 설명에서 전역 해석까지

Shapley 값 : 협동 게임의 상금을 공정하게 나누는 방법

게임 이론	모형 해석
플레이어	설명변수 $x_1, \ldots, x_p$
팀이 받은 상금	$\hat{f}(x) - E[\hat{f}(X)]$ (이 관측치의 예측 − 평균 예측)
연합 S 의 가치 v(S)	S 의 변수만 알 때의 예측 : $E[\hat{f}(X) \mid X_S = x_S]$
각자의 몫 ϕ_j	변수 j 의 기여 (SHAP 값)

$$\varphi_j = \sum_{S \subseteq \{1..p\} \setminus \{j\}} |S|!(p-|S|-1)!/p! \cdot [\, v(S \cup \{j\}) - v(S) \,]$$

= 변수들을 넣는 모든 순서 (p! 가지) 에서 j 를 넣을 때 생기는 예측 변화의 평균

Shapley 값만 만족하는 성질

가법성 (효율성)

$\hat{f}(x) = \phi_0 + \sum_j \phi_j$, ϕ_0 = 평균 예측 . 남김없이 나눠진다

대칭성

기여가 같은 두 변수는 같은 몫

더미

예측에 영향 없는 변수의 몫은 0

가법 결합

모형의 합의 SHAP = SHAP 의 합 (앙상블에 자연스러움)

SHAP (Lundberg & Lee, 2017): Shapley 값을 예측 설명에 적용 + 빠른 계산법 (TreeSHAP, KernelSHAP)

변수 2 개로 직접 계산해 보기

어떤 관측치 : 오전 8 시 (hr), 근무일 (wd). 각 연합에서의 예측 v(S) (가상의 값)

v(∅) = 100

아무것도 모를 때 = 평균 예측

v({hr}) = 250

시각만 알 때

v({wd}) = 130

근무일만 알 때

v({hr, wd}) = 300

둘 다 알 때 = 이 관측치의 예측

순서 ① hr → wd

- hr 추가 : 250 − 100 = +150
- wd 추가 : 300 − 250 = +50

순서 ② wd → hr

- wd 추가 : 130 − 100 = +30
- hr 추가 : 300 − 130 = +170

$$\varphi_\mathrm{hr} = (150 + 170)/2 = 160, \quad \varphi_\mathrm{wd} = (50 + 30)/2 = 40, \quad 100 + 160 + 40 = 300 \checkmark$$

순서에 따라 몫이 다르다 (wd 의 기여 +50 vs +30) — hr 과 wd 사이에 상호작용이 있기 때문 . 한 순서만 쓰는 방법이 Break-down, 모든 순서를 평균하는 것이 Shapley 값

SHAP 계산 방법과 전역 해석으로 모으기

TreeSHAP

- 트리 구조를 이용한 정확한 계산
- XGBoost · LightGBM 내장 (predcontrib)
- R: shapviz(xgb.fit, X_pred = X)

KernelSHAP

- 모형 무관 근사 (가중 회귀)
- 배경 데이터 100~200 개 필요 , 느림
- R: kernelshap(), fastshap::explain()

v(S) 의 정의

- 빠진 변수를 배경 데이터 값으로 채워 평균 (주변분포)
- 상관된 변수에서는 PDP 와 같은 외삽 문제를 공유

n 개 관측치의 SHAP 행렬 (n × p) 을 모으면 전역 해석이 된다

중요도

mean $|\phi_j|$: 평균적으로 예측을 얼마나 움직이나 (예측 단위)

꿀벌 떼 그림 (beeswarm)

점 = 관측치 , 색 = 변수값 → 방향과 퍼짐을 한 번에

의존도 그림 (dependence)

x_j vs ϕ_j 산점도 . PDP 와 비슷하되 퍼짐 = 상호작용

다른 국소 설명 : Break-down 과 LIME

B Break-down (DALEX)

- 평균 예측에서 시작해 변수를 하나씩 x 의 값으로 고정하며 예측 변화를 기록 (폭포 그림)
- 계산이 빠르고 그림이 직관적
- 변수를 넣는 순서에 따라 결과가 달라짐 → 상호작용이 있으면 불안정
- SHAP = Break-down 을 여러 순서로 평균한 것

L LIME (Ribeiro et al., 2016)

- x 주변에 가짜 데이터를 만들어 예측하고 , x 와 가까운 점일수록 큰 가중치로 단순한 선형모형을 적합
- 그 선형모형의 계수 = 국소 설명
- “ 주변” 의 범위 (커널 폭) 와 무작위성에 따라 결과가 흔들림
- R: lime 패키지

왜 요즘 SHAP 을 가장 많이 쓰나 ?
가법성 (합 = 예측 – 평균) 이 보장되고 , 같은 값으로 국소 설명과 전역 해석 (중요도 , 의존도) 을 모두 만들 수 있으며 , 트리 모형에서는 정확하고 빠르게 계산된다

SUMMARY TABLE

해석 도구 한눈에 비교

도구	답하는 질문	범위	상관된 변수	R 패키지
순열 중요도 (VIP)	어떤 변수가 중요한가	전역	중요도가 나뉨 · 외삽	vip, iml, DALEX
불순도 중요도	트리가 어떤 변수로 많이 나눴나	전역	나뉨 · 값 많은 변수 편향	randomForest, xgboost
PDP	x_j 에 따른 평균 예측	전역	외삽 위험	pdp, iml
ICE / c-ICE	관측치별 반응이 같은가	국소 → 전역	외삽 위험	pdp, iml
ALE	x_j 의 국소 효과 누적	전역	상대적으로 안정	iml, ALEPlot
H- 통계량	상호작용이 얼마나 큰가	전역	외삽 위험	iml
SHAP	이 예측은 왜 ? (모으면 전역)	국소 + 전역	주변분포 SHAP 은 외삽	shapviz, kernelshap, fastshap
Break-down / LIME	이 예측은 왜 ?	국소	순서 · 커널에 민감	DALEX, lime

주황 행 : 이 강의의 핵심 도구 (VIP, PDP)

PART 5

실제 데이터 분석 : Bike Sharing

워싱턴 D.C. 공공자전거 시간별 대여량 — 적합에서 해석까지 전 과정 (R)

DATA

실습 데이터 : Capital Bikeshare 시간별 대여량 (ISLR2::Bikeshare)

8,645
시간 단위 관측치 (2011 년)

11
설명변수 p

144
평균 대여량 (bikers)

0.99
temp 와 atemp 의 상관

변수	설명
hr, mnth, weekday	시각 (0~23), 월 (1~12), 요일 (0~6)
season, holiday, workingday	계절 , 공휴일 , 근무일 (주말 · 공휴일 아님) 여부
weathersit	날씨 : clear / cloudy·misty / light rain·snow
temp, atemp	기온 , 체감기온 (°C)
hum, windspeed	습도 (%), 풍속

전처리

- 반응변수 : bikers (시간당 대여 건수)
- casual + registered = bikers → 누수이므로 제외
- day(1 년 중 일) 는 mnth 와 중복 → 제외
- hr, mnth 는 수치형 , 정규화된 기온 · 습도는 원래 단위로
- 70% 학습 (6,052) / 30% 테스트 (2,593)

STEP 1 · FIT

먼저 성능 확인 : 해석할 가치가 있는 모형인가 ?

모형	테스트 RMSE	테스트 R^2
선형회귀 (lm)	104.1	0.396
Random Forest (mtry = 4, 500 trees)	40.6	0.908
XGBoost (η = 0.05, depth 6, 600 rounds)	31.8	0.944

R CONSOLE

```
rf.fit <- randomForest(bikers ~ ., data = train,
                       ntree = 500, mtry = 4,
                       importance = TRUE)
rmse(test$bikers, predict(rf.fit, test))   # 40.6
```

선형회귀는 왜 이렇게 나쁜가 ?

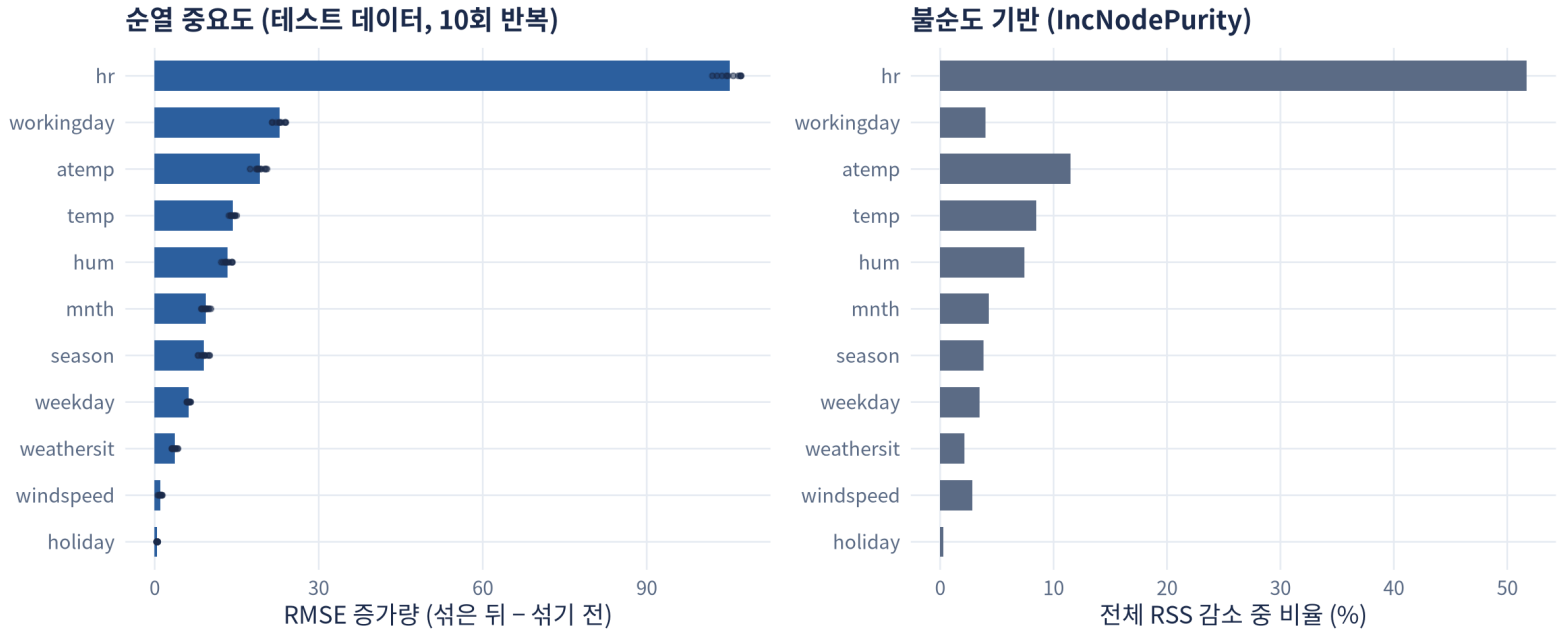
대여량은 시각에 따라 출퇴근 봉우리가 있는 비선형 패턴이고 , 그 모양이 근무일인지에 따라 달라진다 (상호작용). 직선 하나로는 표현 불가

이후 해석의 대상

VIP · PDP · ICE · ALE · H: Random Forest (지난 시간 실습과 같은 패키지)

SHAP: XGBoost (TreeSHAP) · 국소 설명 : RF

변수 중요도 : hr 이 압도적 , 두 방법의 순위는 다르다

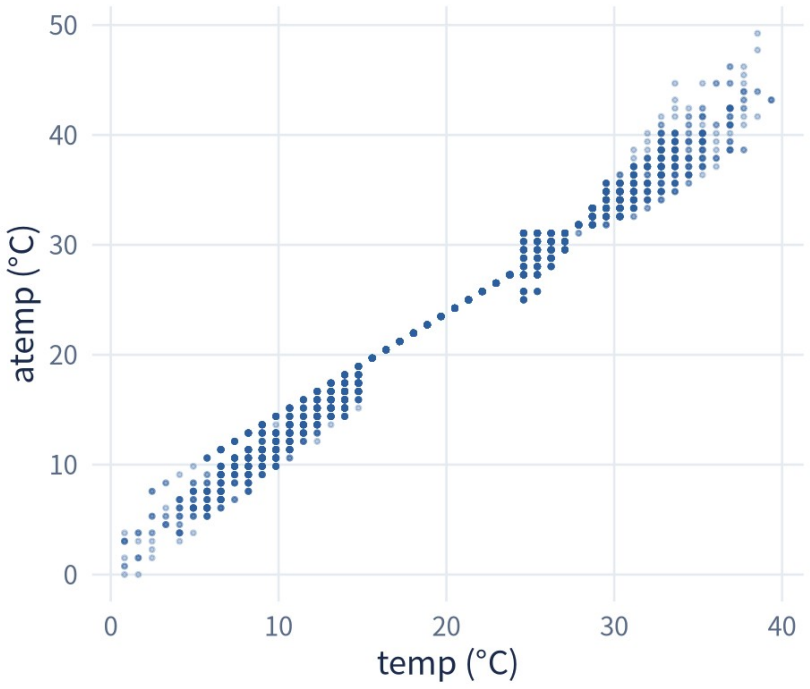


순열 중요도 (테스트)

- hr 을 섞으면 RMSE 가 40.6 → 145.8 (+105.2)
- 2 위 workingday +22.9
- windspeed +1.0, holiday +0.5: 거의 무관
- 10 번 반복의 점들이 촘촘 → 순위 안정적

workingday: 순열 2 위 ↔ 불순도 6 위
0/1 변수는 분할점이 하나뿐이라 불순도 합이 작게 나온다 (값이 많은 연속형 temp · atemp · hum 이 유리). “ 섞으면 얼마나 나빠지나” 로 보면 근무일 여부는 기온보다 중요하다 — 불순도 편향의 실제 사례

temp 와 atemp: 상관 0.99 인 두 변수가 중요도를 나눠 갖는다



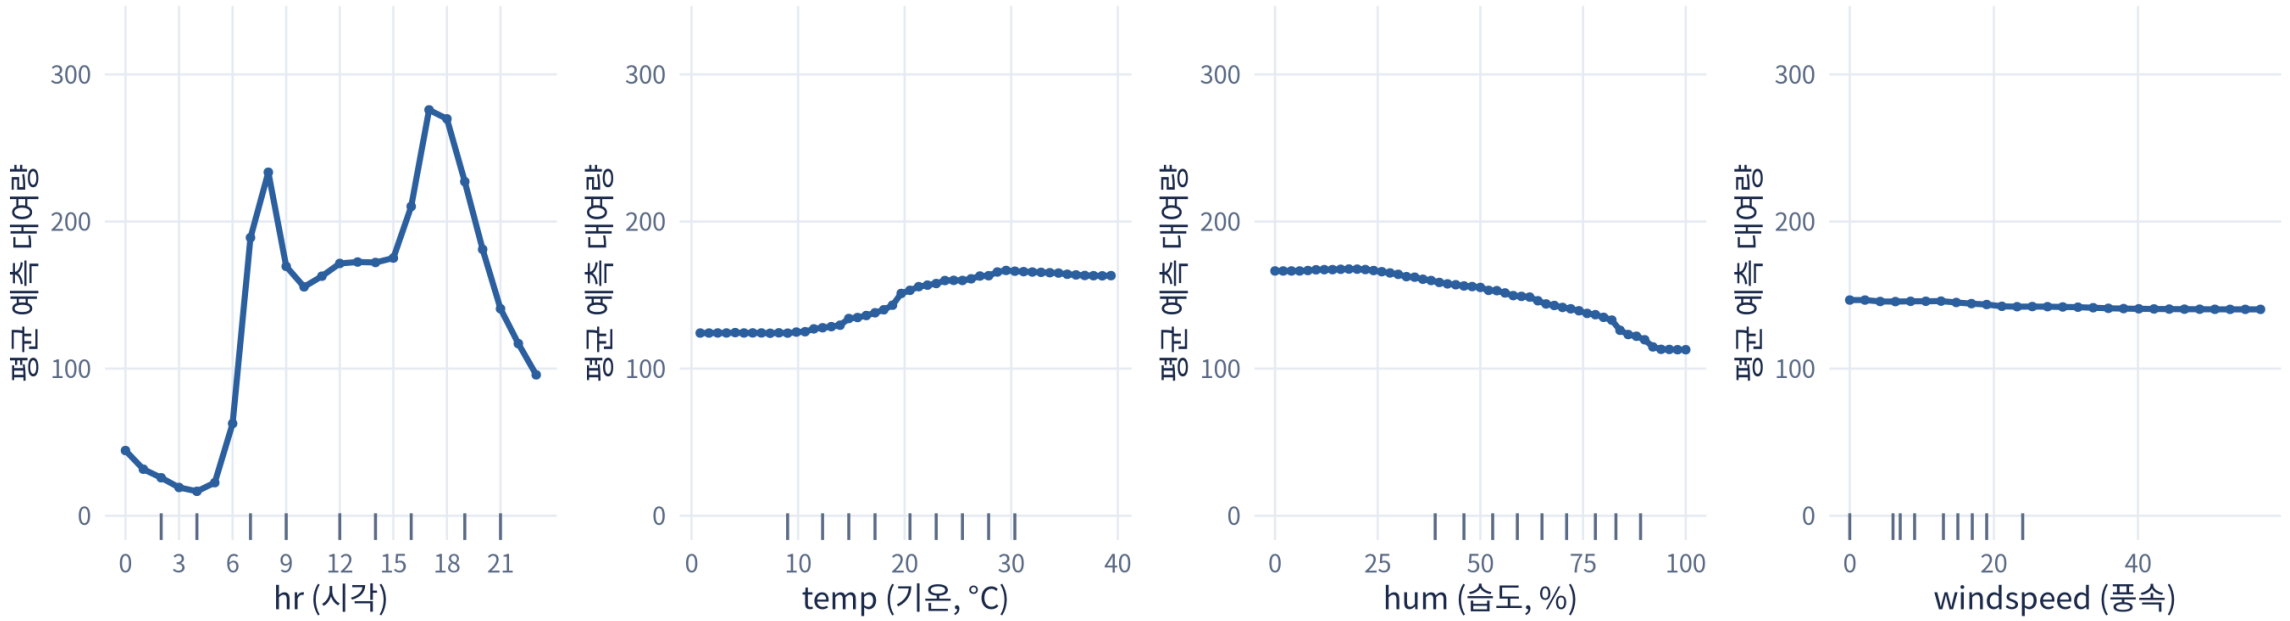
순열 중요도 (RMSE 증가)	둘 다 사용	atemp 제거 후 재적합
temp	14.3	36.8
atemp	19.2	—
테스트 RMSE	40.6	37.8

해석

따로 보면 각각 4 위 · 3 위지만, 하나만 남기면 temp 는 hr 다음 2 위 (36.8). 기온 정보 자체는 매우 중요

교훈 : 중요도가 낮게 나온 변수도 상관된 짝이 있으면 다시 본다
거의 같은 정보의 변수는 하나만 쓰거나 묶어서 해석한다. 이 데이터에서는 atemp 를 빼도 성능이 오히려 조금 좋아졌다

부분 의존도 : 각 변수가 평균 예측을 어떻게 움직이나



hr

두 봉우리 : 8 시 (233) 와 17~18 시 (276). 새벽 4 시는 17 → 출퇴근 이용

temp

10°C 이하 약 124, 25~30°C 까지 증가해 약 165, 그 위는 평평

hum

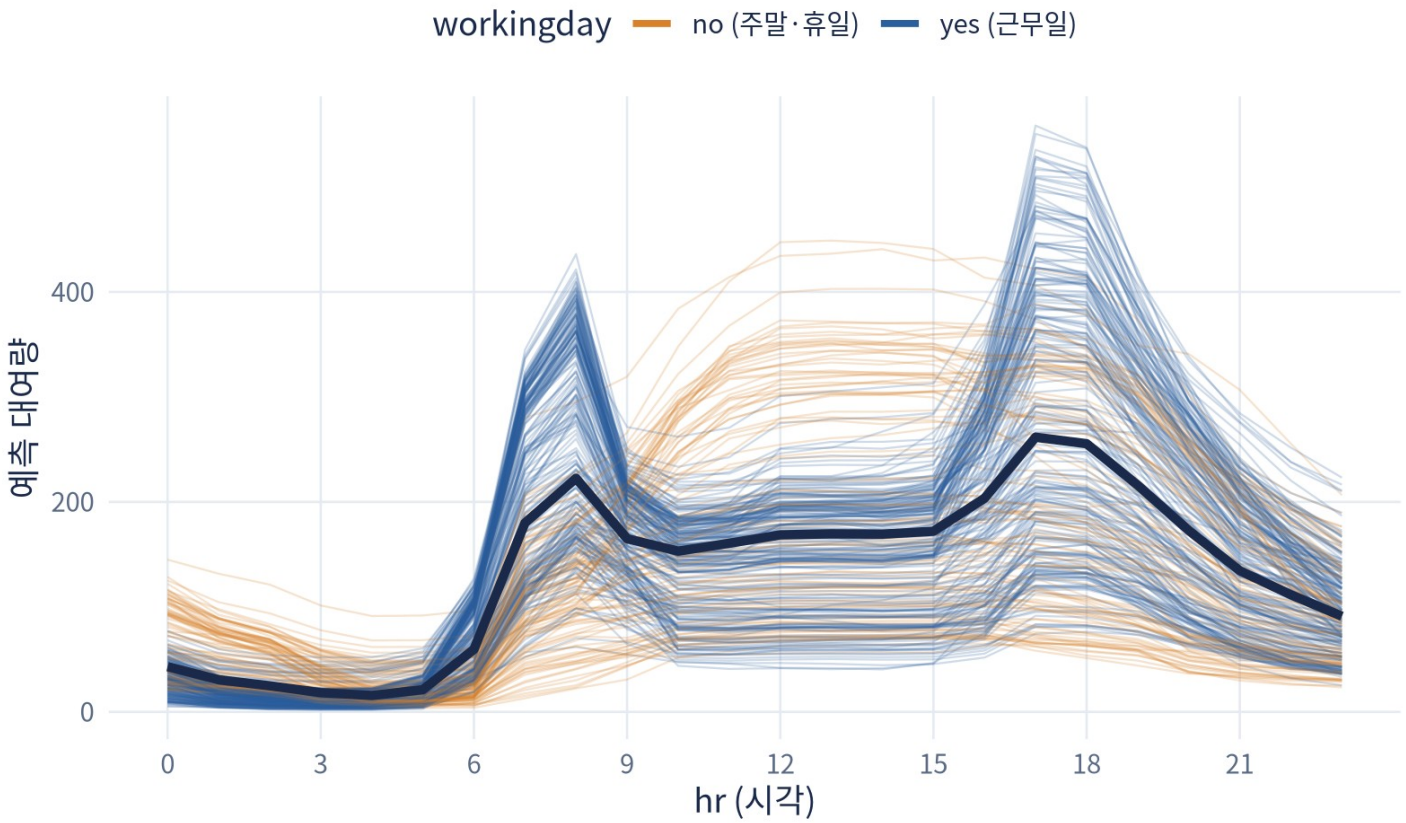
40% 이하는 거의 일정 , 그 위로 감소 : 100% 에서 113

windspeed

140 ~ 147: 사실상 평평 → VIP 와 일치

아래 눈금 (rug) = 각 변수의 십분위수 (10%, 20%, ⋯, 90%). 양 끝의 모양은 데이터가 적어 덜 믿을 만하다

ICE: 시각별 곡선이 두 무리로 갈라진다



학습 데이터에서 무작위 300 개 관측치 . pdp::partial(..., ice = TRUE)

파랑 : 근무일

8 시와 17~18 시에 뾰족한 출퇴근 봉우리 , 낮 시간은 낮다

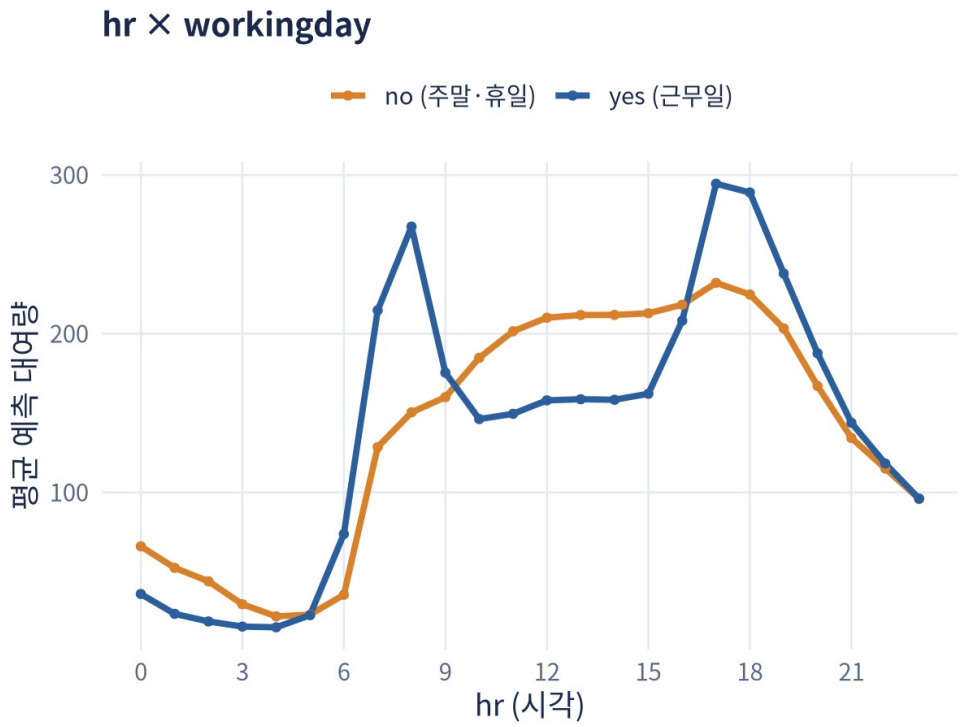
주황 : 주말 · 공휴일

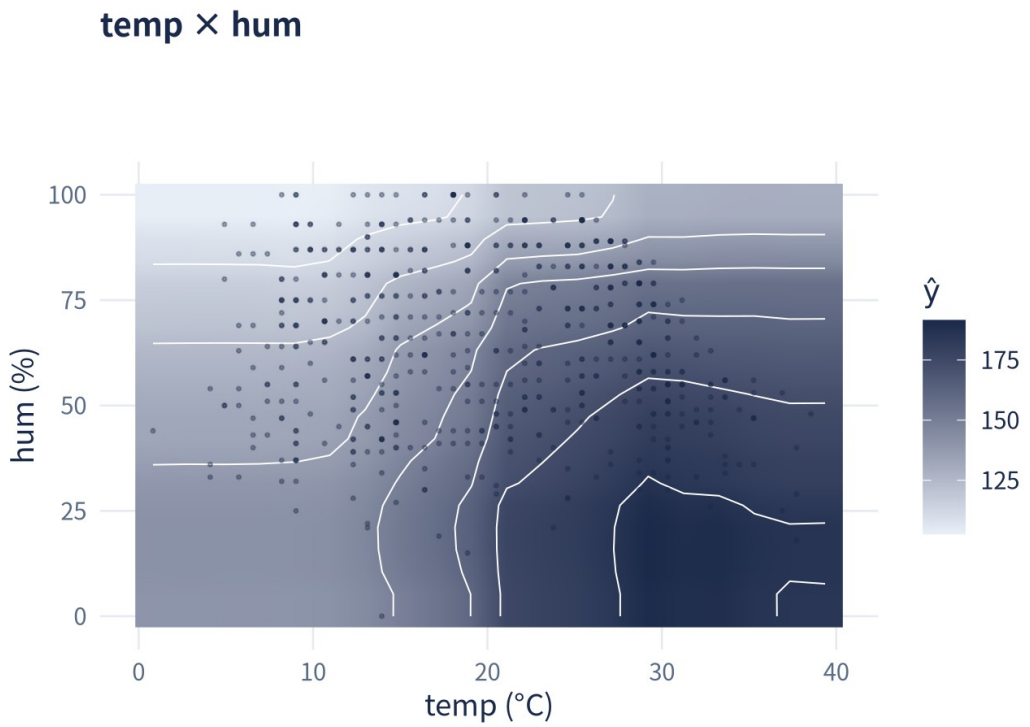
봉우리 없이 10~17 시에 완만한 언덕 (여가용 이용)

검은 선 = PDP

두 패턴의 가중 평균 . 근무일이 약 68% 라 출퇴근 모양이 우세

2 차원 PDP: hr × workingday, temp × hum

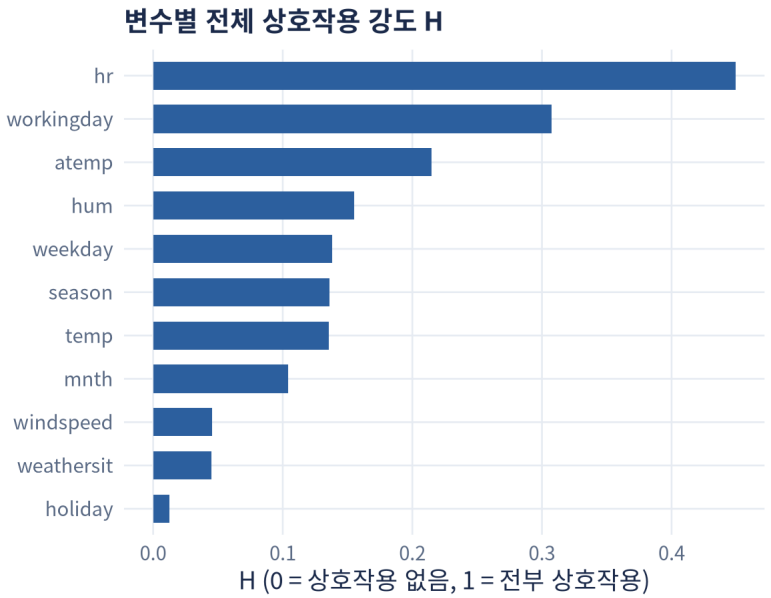


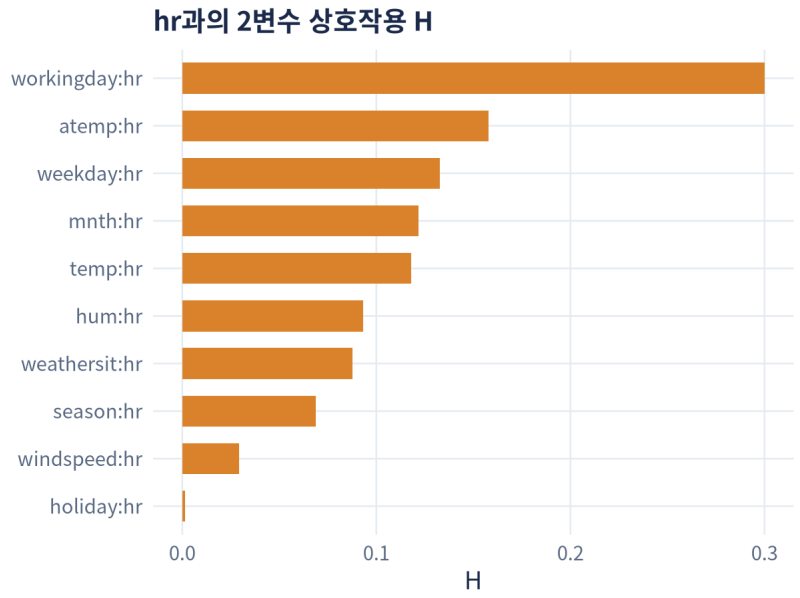


평균 예측	08 시	13 시	17 시
근무일 (yes)	267	159	294
주말 · 휴일 (no)	150	212	232

hr × workingday: 두 선의 모양이 다르다 = 상호작용 . 13 시에는 주말이 더 많다 . **temp × hum:** 따뜻하고 건조할수록 많음 . 등고선이 거의 세로 → temp 효과가 주 , 상호작용은 약함

H- 통계량 : hr × workingday 가 가장 강한 상호작용





읽기

- hr 의 전체 H = 0.45: hr 효과의 상당 부분이 다른 변수에 따라 달라짐
- hr 과의 짝 중 workingday 0.30 이 1 위
- ICE · 2D PDP 에서 본 것과 일치

세 도구가 같은 이야기를 한다 : ICE(그림) · 2D PDP(평균 곡선) · H(숫자)
H 는 400 개 관측치 표본으로 계산 → 표본에 따라 소수 둘째 자리는 달라질 수 있다 . 순위와 크기를 대략적으로 본다

ALE vs PDP: 상관된 temp 와 atemp 에서 결과가 갈린다

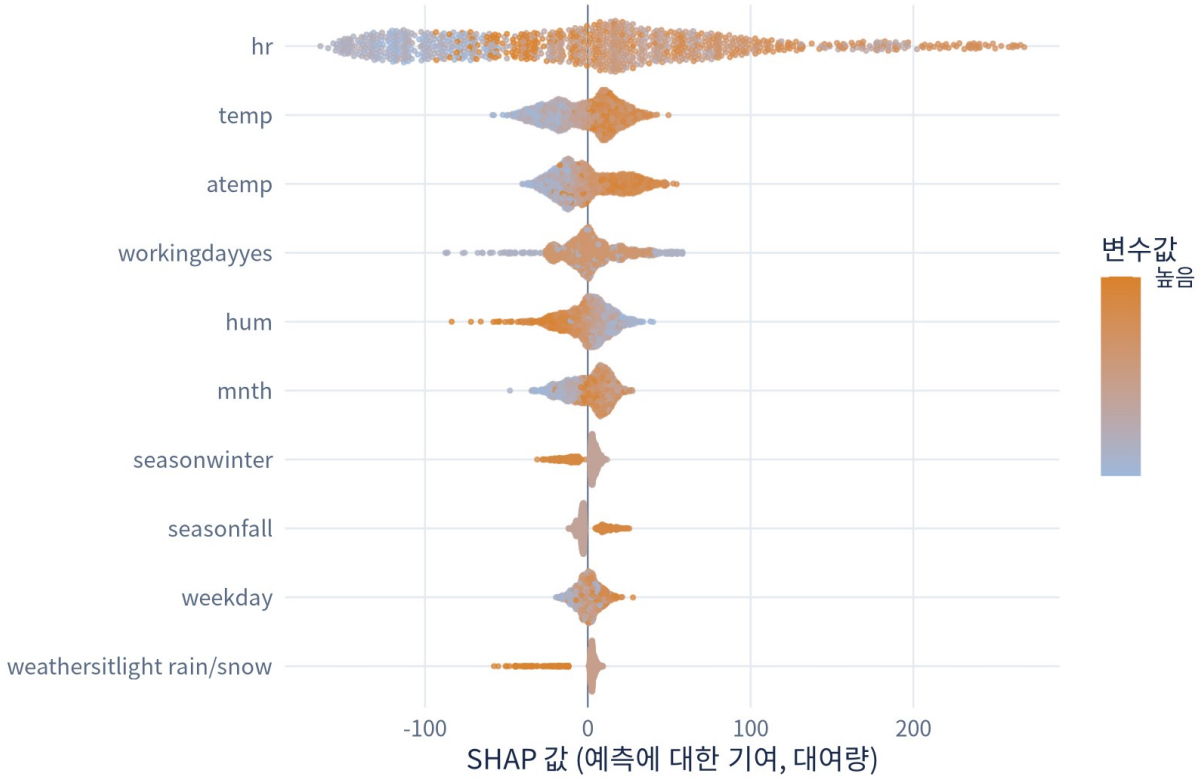


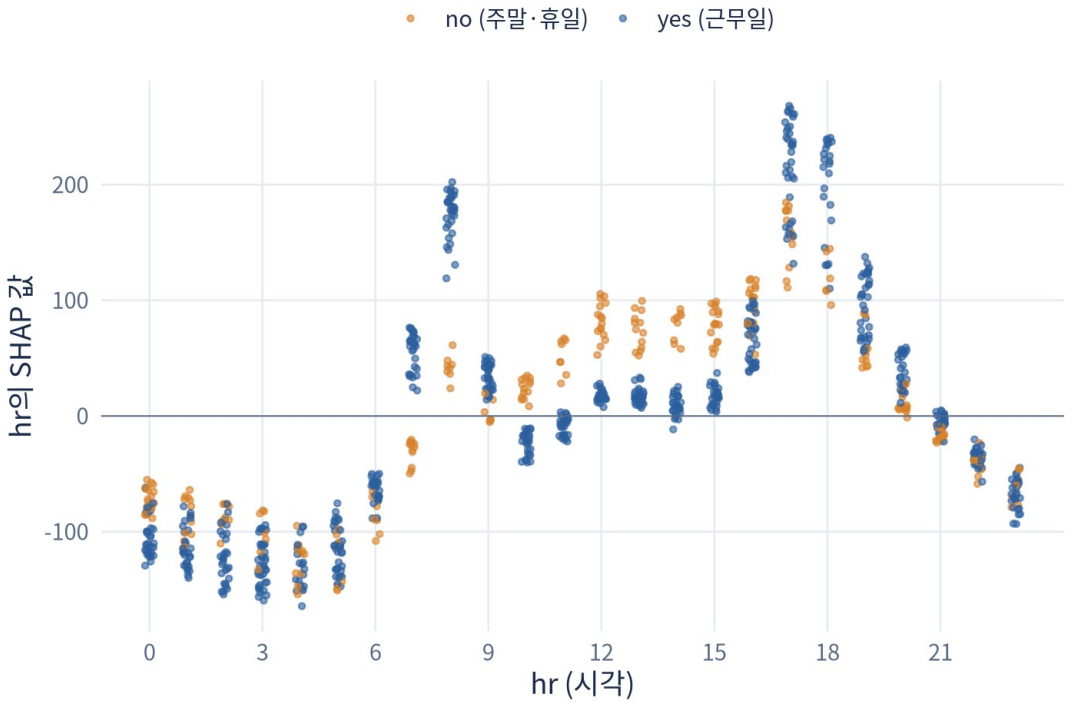
어디서 다른가 ?

- 25°C 이하 : 두 방법이 거의 같다
- 30°C 이상 : PDP 는 평평 , ALE 는 감소
- PDP 의 고온 구간은 “ temp 35, atemp 10” 같은 없는 조합의 예측이 섞인 값

해석 : “ 아주 더우면 대여가 줄어든다” 는 신호가 ALE 에서만 보인다
단 , 학습 데이터에서 30°C 넘는 시간은 약 12% 뿐이라 이 구간은 불확실하다 . 두 방법이 다를 때는 상관된 변수 (atemp) 를 의심하고 , 결론은 조심스럽게

SHAP (XGBoost, TreeSHAP): 방향과 퍼짐까지 한 번에



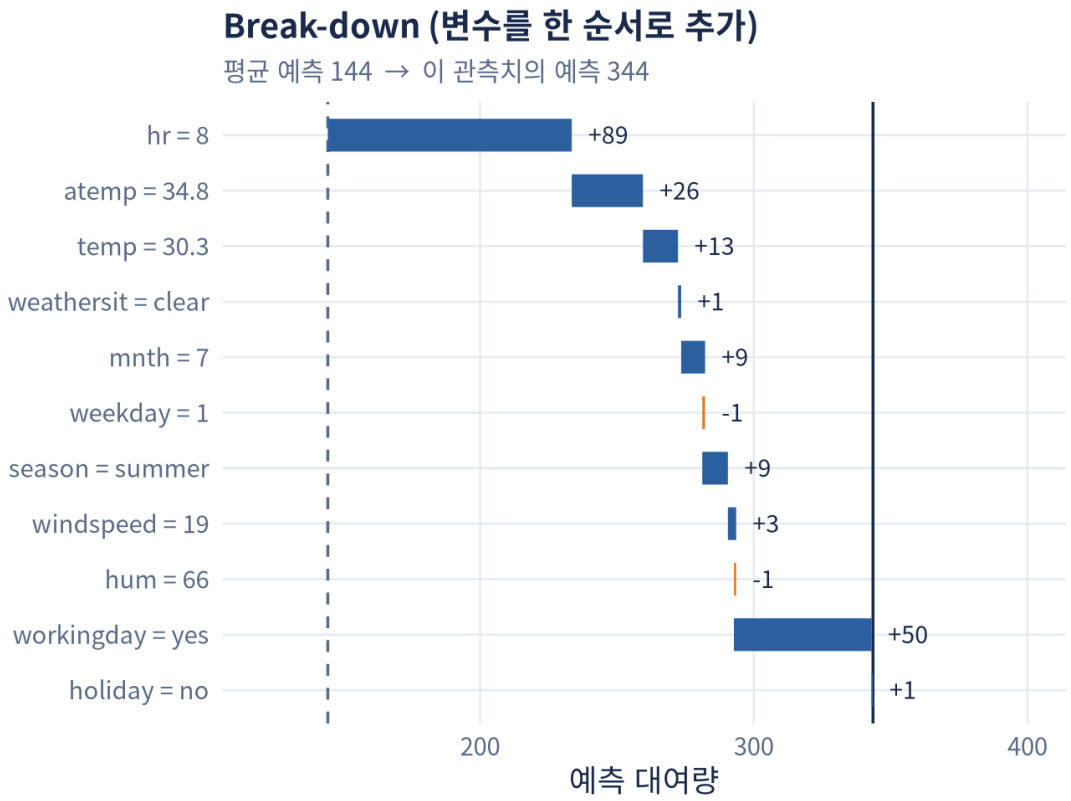


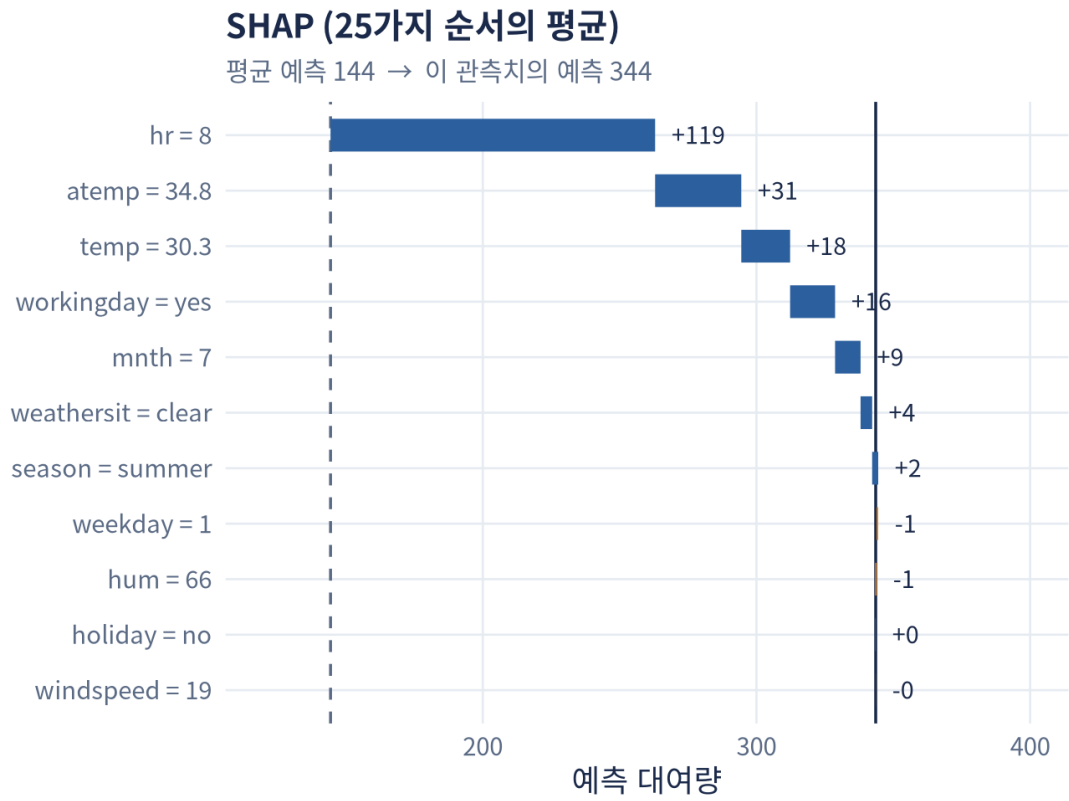
hr 의 SHAP 의존도 — 같은 시각에서도 근무일 여부로 갈린다

mean |SHAP|: hr 76.3 ≫ temp 16.9 ≈ atemp 15.9 > workingday 13.9 > hum 11.1 · **방향 :** 기온↑ → 기여 +, 습도↑ → 기여 −, 비 · 눈 → 크게 −. RF 의 VIP · PDP 와 같은 결론 → 모형이 달라도 해석이 일관됨

테스트 데이터 1,000 개 관측치의 SHAP. 범주형은 더미 변수별로 표시 (workingdayyes 등)

관측치 하나 설명하기 : 7 월 어느 월요일 오전 8 시





관측치 : 근무일 · 맑음 · 30.3°C · 습도 66% · 실제 420 대 , RF 예측 344. **Break-down(순서 : hr → … → workingday)** 에서 workingday +50 이지만 , **SHAP** 에서는 +16. hr 과 workingday 의 상호작용 몫이 순서에 따라 다르게 배분되기 때문 — 앞의 2 변수 예와 같은 현상

R CODE

해석 과정 전체 코드 요약 (iml · shapviz · DALEX)

R CONSOLE

```
# ICE ( 근무일로 색칠 )
ice.hr <- partial(rf.fit, pred.var = "hr",
                  train = ice.sub, ice = TRUE,
                  grid.resolution = 24)
plot(ice.hr, alpha = 0.2, center = TRUE)

# ALE vs PDP, H-통계량 (iml)
X <- train[, names(train) != "bikers"]
pred.rf <- Predictor$new(rf.fit, data = X,
                         y = train$bikers)
plot(FeatureEffect$new(pred.rf, "temp",
                       method = "ale"))
plot(Interaction$new(pred.sub, feature = "hr"))
```

R CONSOLE

```
# SHAP: XGBoost + TreeSHAP (shapviz)
shp <- shapviz(xgb.fit, X_pred = X.explain)
sv_importance(shp)                  # mean|SHAP|
sv_importance(shp, kind = "beeswarm")
sv_dependence(shp, v = "hr",
              color_var = "workingdayyes")
sv_waterfall(shp, row_id = 1)

#  국소 설명 : Break-down vs SHAP (DALEX)
ex <- DALEX::explain(rf.fit, data = X,
                     y = train$bikers)
predict_parts(ex, obs, type = "break_down")
predict_parts(ex, obs, type = "shap", B = 25)
```

전체 코드 : Model_Interpretation_BikeSharing.R (데이터 준비 → 적합 → VIP → PDP → ICE → ALE · H → SHAP → Break-down)

FINDINGS

분석 결과 정리 : 모형이 학습한 대여 패턴

1 시각이 가장 중요하다

hr 을 섞으면 RMSE 가 2.6 배 (40.6 → 145.8). 하루 두 번의 출퇴근 봉우리 (8 시 , 17~18 시)

2 시각의 효과는 근무일에 따라 다르다

근무일 : 출퇴근형 봉우리 , 주말 · 휴일 : 낮 시간 언덕형 . ICE · 2D PDP · H(0.30) · SHAP 모두 같은 결론

3 날씨 : 따뜻하고 건조하고 맑을수록

기온 25~30°C 까지 증가 , 습도 40% 이상에서 감소 , 비 · 눈은 큰 감소 . 풍속은 영향이 거의 없음

4 기온 변수는 하나로 충분

temp · atemp 는 상관 0.99 로 중요도를 나눠 가짐 . 고온 구간 효과는 PDP 와 ALE 가 달라 불확실

주의 : 이것은 “모형이 이렇게 예측한다”는 설명 . 실제 정책 효과 (인과) 를 말하려면 별도의 설계가 필요

SUMMARY

오늘의 핵심 정리

1	VIP	순열 중요도 = 섞었을 때 오차 증가 . 테스트 데이터에서 , 반복해서 . 불순도 중요도는 값 많은 변수에 편향
2	PDP	$PD_j(z) = (1/n) \Sigma \hat{f}(z, x_C^{(i)})$: 다른 변수를 평균한 x_j 의 효과 . 가법적이면 정확 , 상호작용은 평균됨
3	ICE · H	ICE = 평균 전의 곡선 , 갈래가 보이면 상호작용 . H- 통계량으로 그 크기를 숫자로
4	ALE	상관된 변수에서 PDP 의 외삽을 줄인다 . PDP 와 다르면 상관된 변수를 의심
5	SHAP	예측 – 평균을 변수별로 공정하게 나눈다 (모든 순서의 평균). 모으면 전역 중요도 · 의존도

순서 : 성능 확인 → VIP → PDP → ICE · H 로 상호작용 → ALE 로 상관 점검 → SHAP 으로 개별 예측 설명