Support Vector Machines (SVM)

학부 4 학년 · 분류모형 강의 · Logistic Regression / LDA / QDA 다음 차시

확률을 추정할 것인가 ,
분류 경계를 직접 찾을 것인가 ?

Maximum margin · Soft margin · Kernel trick · Decision score · R 실습

오늘의 학습 목표

- Margin 과 support vector 의 의미 설명하기
- Soft margin, C, hinge loss 의 관계 이해하기
- SVM score 와 확률 $P(Y=1|x)$ 를 구분하기
- Kernel 의 직관 이해하고 R 로 학습 · 평가하기

지금까지 배운 모형과 무엇이 다를까 ?

Logistic Regression

조건부 확률
$P(Y=1 \mid x)$ 를 직접 모델링

LDA / QDA

클래스별 X 의 분포 가정
→ Bayes 정리로 사후확률

SVM

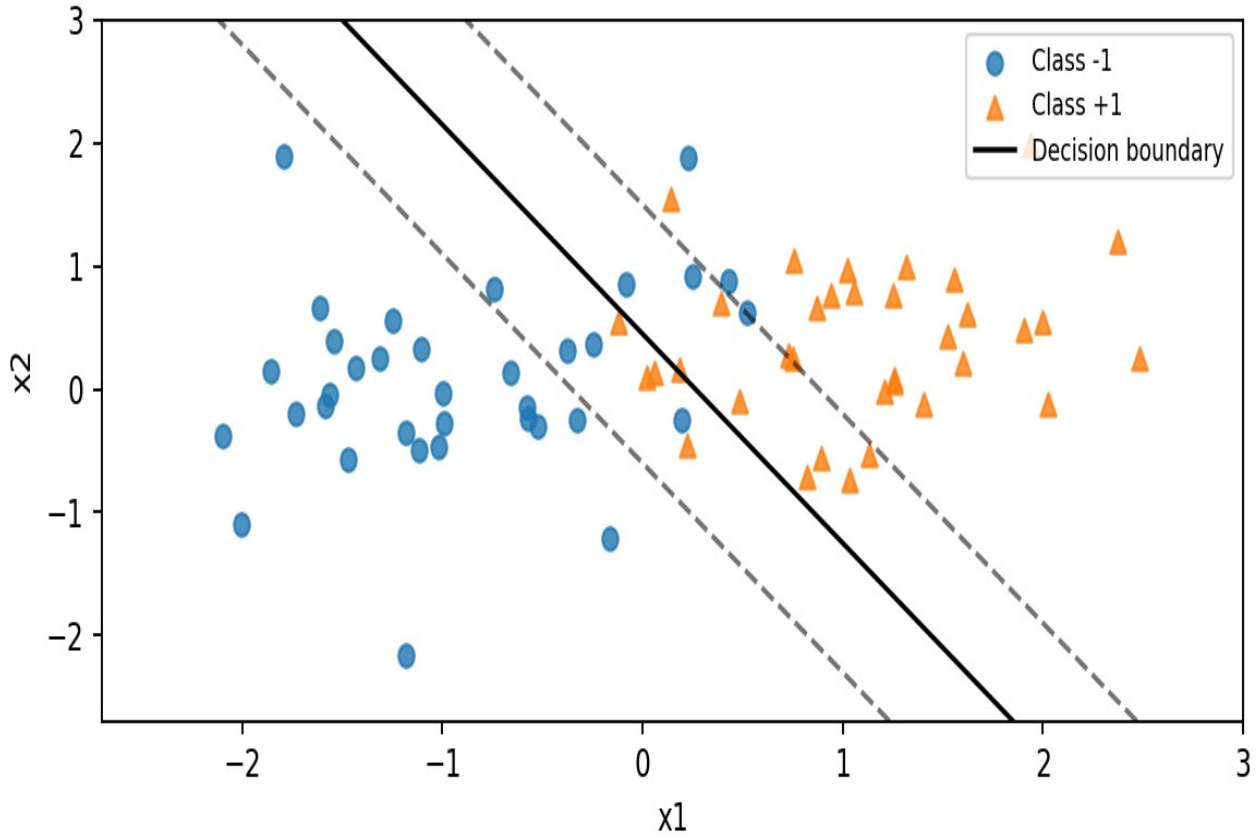
확률 대신 decision score
→ 좋은 분류 경계를 탐색

핵심 : 분류를 잘하는 것과 확률을 정확하게 추정하는 것은 다른 목표다 .

선형 decision boundary 는 하나만 있는가 ?

- 선형으로 분리 가능한 자료에도 가능한 경계는 여러 개
- SVM 은 그중 가장 가까운 관측치와의 간격을 최대화
- 경계를 결정하는 핵심 관측치 = Support vectors

Maximum margin 의 기하학적 의미



세 개의 평면

Decision boundary: f(x) = 0
Margin boundaries: f(x) = ±1
기하학적 거리 : |f(x)| / ||w||

Maximum margin → 최적화 문제

$$f(x) = w^T x + b$$

두 margin 평면 사이 거리 = 2 / ||w||

$$\min \tfrac{1}{2}\|w\|^2 \quad \text{subject to} \quad y_i(w^T x_i + b) \geq 1$$

Hard margin 의 문제점

- 완벽히 선형 분리되어야 한다는 강한 조건
- 이상치 한두 개가 decision boundary 를 크게 바꿀 수 있음
- 현실 자료는 클래스가 겹치는 일이 일반적
- → 위반을 허용하는 Soft margin 이 필요

Soft margin: 잘못 분류하면 비용을 부과

$$y_i\, f(x_i) \geq 1 - \xi_i, \qquad \xi_i \geq 0$$

$$\min \ \tfrac{1}{2}\|w\|^2 + C \sum \xi_i$$

ξ_i : margin 위반 정도 · C : margin 위반에 대한 벌점의 크기

Soft margin 의 중요한 세 경우

$y\,f(x) \geq 1$

올바른 분류 + margin 바깥
→ Hinge loss = 0

$0 < y\,f(x) < 1$

맞게 분류했지만 margin 내부
→ Hinge loss > 0

$y\,f(x) \leq 0$

경계 위 또는 오분류
→ Hinge loss ≥ 1

주의 : 오분류된 데이터뿐 아니라 margin 내부의 정분류 데이터에도 벌점을 준다 .

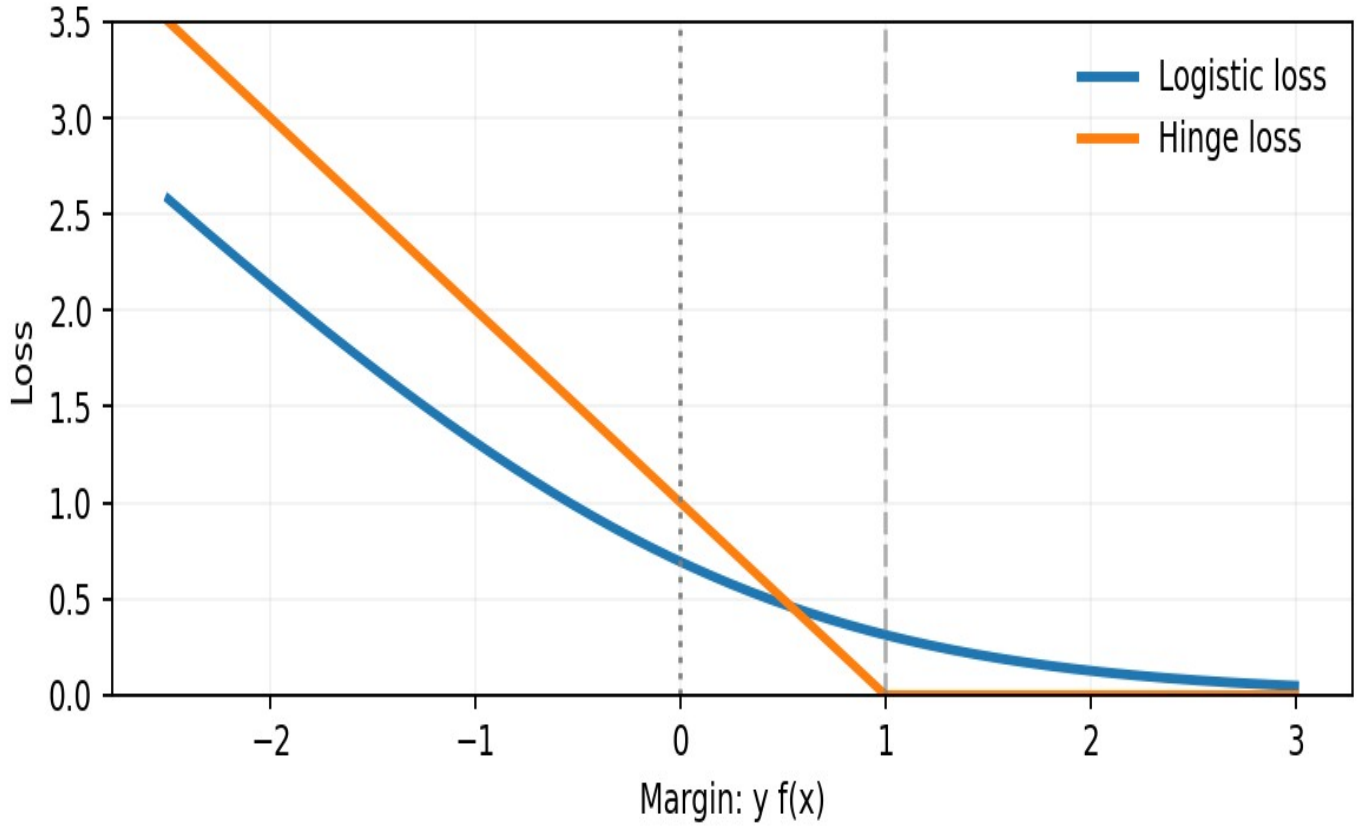
Hinge loss 와 Regularization

$$L_{hinge}(y, f) = \max(0, 1 - y\,f)$$

$$\min \ \tfrac{1}{2}\|w\|^2 + C \sum \max(0, 1 - y_i\, f(x_i))$$

C ↑: 위반에 엄격 / C ↓: 규제를 더 강조, 유연하게 위반 허용

Logistic loss vs Hinge loss



차이를 기억하자

Logistic: loss 가 계속 감소

Hinge: margin ≥ 1 이면 loss = 0

둘 다 분류 목적의 surrogate loss

Kernel trick 은 왜 필요한가 ?

- 원래 X 공간에서 직선으로 구분할 수 없는 경우
- 새로운 특징 $\varphi(x)$ 를 만들면 고차원에서 선형 분리 가능
- 고차원 공간의 선형 경계가 원래 공간에서는 비선형 경계
- 복잡한 Hilbert space 이론은 여기서 다루지 않음

Kernel trick: 딱 하나의 식

$$K(x, z) = \varphi(x)^T \varphi(z)$$

특징을 직접 모두 만들지 않아도 , 고차원 특징 간 내적을 계산한다 .

예 : $x_1^2 + x_2^2$ 같은 특징을 쓰면 원형 구조를 구분하기 쉬워질 수 있다 .

대표적인 kernel

Linear

$K(x,z) = x^T z$

원래 공간에서 선형 경계

Polynomial

$K(x,z) = (\gamma x^T z + r)^d$

다항식 · 상호작용 특징

RBF / Gaussian

$K(x,z) = \exp(-\gamma||x-z||^2)$

가까운 관측치의 유사성

RBF 의 γ 와 C 는 교차검증으로 튜닝한다 .

SVM score 는 확률이 아니다

$$f(x) > 0 \rightarrow \text{Positive} \quad / \quad f(x) < 0 \rightarrow \text{Negative}$$

- f(x) 는 실수값의 signed decision score
- 점수 1.5 를 “positive 확률 90%” 라고 해석할 수 없음
- 선형 SVM 의 기하학적 거리는 f(x) / ||w||
- 그러나 score 만으로도 ROC-AUC 는 계산 가능

확률이 필요한 경우 : Calibration

$$P(Y=1 \mid f) \approx 1 / \{1 + \exp(A\, f + B)\}$$

- Platt scaling 은 SVM score 에 sigmoid 를 사후 적합
- 보정용 자료 또는 out-of-fold 점수 이용
- 확률을 사용하려면 Brier score, log-loss 등도 평가

학습과 평가 시 주의할 점

- 표준화 : 변수 단위가 거리 ·kernel 에 영향
- C 와 γ 는 training 내부 교차검증으로 선택
- Accuracy / F1 등은 예측 클래스 , AUC 는 연속형 score
- Class weight ≠ 실제 오분류 비용
- 최종 test set 은 튜닝에 사용하지 않기

R 실습 : 목표와 데이터

- iris 데이터에서 versicolor(0) vs virginica(1)
- Training 70% / Test 30% 로 분할
- Linear SVM 과 RBF SVM 을 5-fold CV 로 튜닝
- 혼동행렬 · Accuracy · F1 · AUC 비교

R 실습 ① 데이터 준비

```
# install.packages('e1071')
library(e1071)
set.seed(2026)
dat <- subset(iris, Species != 'setosa')
dat$Species <- droplevels(dat$Species)
idx <- sample(seq_len(nrow(dat)), floor(.7*nrow(dat)))
train <- dat[idx,]
test <- dat[-idx,]
```

R 실습 ② Linear / RBF 튜닝

```
lin <- tune.svm(Species ~ ., data = train,
 kernel= 'linear', cost= 2^(-3:5),
 scale = TRUE,
 tunecontrol= tune.control(cross = 5))

rbf<- tune.svm(Species ~ ., data = train,
 kernel= 'radial', cost= 2^(-3:5),
 gamma = 2^(-7:2), scale = TRUE,
 tunecontrol= tune.control(cross = 5))
lin$best.parameters
rbf$best.parameters
```

R 실습 ③ 예측 및 Confusion Matrix

```
pred_lin <- predict(lin$best.model, newdata = test)
pred_rbf <- predict(rbf$best.model, newdata = test)

# rows = actual, columns = predicted
table(True = test$Species, Pred = pred_lin)
table(True = test$Species, Pred = pred_rbf)

# levels: versicolor (negative), virginica (positive)
```

R 실습 ④ Base R 성능지표

```
metrics <- function(actual, pred, positive='virginica'){
  tp <- sum(actual==positive & pred==positive)
  tn <- sum(actual!=positive & pred!=positive)
  fp <- sum(actual!=positive & pred==positive)
  fn <- sum(actual==positive & pred!=positive)
  safe <- function(a,b) if(b==0) NA_real_ else a/b
  rec <- safe(tp, tp+fn); spec <- safe(tn, tn+fp)
  c(Accuracy = safe(tp+tn, tp+tn+fp+fn),
    Precision = safe(tp, tp+fp), Sensitivity = rec,
    Specificity = spec, F1 = safe(2*tp, 2*tp+fp+fn),
    Balanced_Accuracy = mean(c(rec, spec)))
}
metrics(test$Species, pred_lin)
metrics(test$Species, pred_rbf)
```

R 실습 ⑤ ROC-AUC 함수 (1/2)

```
roc_auc <- function(actual, score, positive = 'virginica',
                    draw = TRUE) {
  stopifnot(length(actual) == length(score),
            !anyNA(actual), !anyNA(score),
            is.numeric(score), all(is.finite(score)))
  y <- actual == positive; n1 <- sum(y); n0 <- sum(!y)
  if (n1 == 0 || n0 == 0) stop('Both classes required')
  ord <- order(score, decreasing = TRUE)
  s <- score[ord]; yy <- y[ord]
  ends <- which(!duplicated(s, fromLast = TRUE))
  tpr <- c(0, cumsum(yy)[ends] / n1)
  fpr <- c(0, cumsum(!yy)[ends] / n0)
```

R 실습 ⑤ ROC-AUC 함수 (2/2)

```
  auc <- sum(diff(fpr) *
        (head(tpr,-1) + tail(tpr,-1))/2)
  if(draw){
    plot(fpr, tpr, type='s', xlim=c(0,1), ylim=c(0,1),
       xlab='1 - Specificity', ylab='Sensitivity',
       main=sprintf('ROC (AUC=%.3f)', auc), lwd=2)
    abline(0,1, lty=2, col='gray')
  }
  list(AUC=auc, ROC=data.frame(FPR=fpr, TPR=tpr,
       threshold=c(Inf, s[ends])))
}
```

R 실습 ⑥ SVM 확률 보정과 AUC

```
prob_model<-svm(Species~.,data=train,
 kernel='radial',
 cost=rbf$best.parameters$cost,
 gamma=rbf$best.parameters$gamma,
 scale=TRUE,probability=TRUE)

prob_pred<-predict(prob_model,test,probability=TRUE)
pr<-attr(prob_pred,'probabilities')[,'virginica']
result<-roc_auc(test$Species,pr)
result$AUC
head(result$ROC)
```

생각해 볼 질문

- Logistic Regression 과 Linear SVM 의 경계는 왜 다를까 ?
- 정분류 관측치가 hinge loss 를 가질 수 있을까 ?
- C 를 크게 하면 test accuracy 가 반드시 좋아질까 ?
- SVM score 는 확률이 아닌데 왜 AUC 계산이 가능할까 ?
- 확률이 중요한 의사결정이라면 무엇을 추가 평가할까 ?

오늘의 핵심 정리

- SVM 은 확률 대신 분류 경계와 margin 을 최적화한다
- Soft margin 은 오분류와 margin 위반에 비용을 부과한다
- Kernel 을 이용하면 비선형 decision boundary 를 만들 수 있다
- Decision score 와 확률은 다르다 — 필요하면 calibration
- 최종 모델 평가는 목적에 맞는 지표와 test set 으로

참고문헌 및 다음 차시

- Cortes & Vapnik (1995), Support-Vector Networks
- Hastie, Tibshirani & Friedman, ESL, Chapter 12
- R package e1071: svm(), tune.svm()
- 다음 차시 : Classification Tree → Bagging → Random Forest → Boosting